School of
Information Technology
King Mongkut's Institute of Technology Ladkrabang

CHAPTER 14
EVALUATION METRICS

Presented by

- **Pitawas Narongsak**
- **Janya Onpans**
- **Witchaya Chimsa**
- **Chetsadaporn Traivinidsreesuk**
- **Chinnatip Taemkaeo**

Advisor Asst. Prof. Dr. Taravichet Titijaroonroj

Topics

1. Classification
2. Object Detection
3. Image Segmentation
4. Video Processing
5. Regression
6. Retrieval-Augmented Generation (RAG)

Classification

Confusion Matrix

ตารางสรุปผลการทำนายเปรียบเทียบกับค่าจริง (Actual vs. Predicted)

Actual Value \ Predicted Value	ป่วยโควิด	ไม่ป่วยโควิด
ป่วยโควิด	True Positive (TP)	False Negative (FN)
ไม่ป่วยโควิด	False Positive (FP)	True Negative (TN)

ตัวอย่าง: COVID Classification

Positive = ผู้ป่วยที่ติดโควิด
Negative = ผู้ป่วยที่ไม่ติดโควิด

TP = โมเดลทำนายว่า เป็น โควิด และผู้ป่วย เป็น จริง
TN = โมเดลทำนายว่า ไม่เป็น โควิด และผู้ป่วย ไม่เป็น จริง
FP = โมเดลทำนายว่า ติด โควิด แต่จริง ๆ ไม่เป็น
FN = โมเดลทำนายว่า ไม่เป็น โควิด แต่จริง ๆ เป็น

Confusion Matrix

ตารางสรุปผลการทำนายเปรียบเทียบกับค่าจริง (Actual vs. Predicted)

Actual Value \ Predicted Value	ป่วยโควิด	ไม่ป่วยโควิด
ป่วยโควิด	80 True Positive (TP)	20 False Negative (FN)
ไม่ป่วยโควิด	15 False Positive (FP)	885 True Negative (TN)

ประโยชน์ของ Confusion Matrix

- แสดงผลการทำนายอย่างละเอียด
- เป็นพื้นฐานของตัวชี้วัดประสิทธิภาพ
  - Accuracy
  - Precision
  - Recall
- ช่วยวิเคราะห์ประเภทของความผิดพลาด

Confusion Matrix

ตารางสรุปผลการทำนายเปรียบเทียบกับค่าจริง (Actual vs. Predicted)

Actual Value \ Predicted Value	หมา	แมว	เสือ
หมา	100	0	0
แมว	0	70	30
เสือ	0	50	50

Accuracy

โมเดลทำนายถูกต้องกี่เปอร์เซ็นต์ของข้อมูลทั้งหมด

Predicted Value

Actual Value

True Positive (TP)	False Negative (FN)
False Positive (FP)	True Negative (TN)

Accuracy
สัดส่วนของจำนวนตัวอย่างที่โมเดลทำนายได้ถูกต้องทั้งหมด
เมื่อเทียบกับจำนวนตัวอย่างทั้งหมด

$$Accuracy = \frac{TP + TN}{TP + FP + FN + TN}$$

มักมีค่าอยู่ในช่วง 0 ถึง 1
Accuracy สูง หมายความว่าโมเดลทำนายถูกต้องโดยรวมเป็นสัดส่วนสูง
Accuracy ต่ำ หมายความว่าโมเดลทำนายผิดพลาดจำนวนมาก

Accuracy

ปัญหาของ Accuracy เมื่อข้อมูล Imbalanced

Actual Value	Predicted Value: ป่วยโควิด	Predicted Value: ไม่ป่วยโควิด
ป่วยโควิด	0 True Positive (TP)	100 False Negative (FN)
ไม่ป่วยโควิด	0 False Positive (FP)	900 True Negative (TN)

ตัวอย่าง: COVID Classification

ตัวอย่างข้อมูลผู้ป่วย 1000 คน

- ป่วยโควิด - 100 คน
- ไม่ป่วยโควิด - 900 คน (Imbalanced)

$$Accuracy = \frac{TP + TN}{TP + FP + FN + TN}$$

$$Accuracy = \frac{0 + 900}{0 + 0 + 100 + 900}$$

$$Accuracy = \frac{900}{1000} = 0.9 = 90\%$$

Recall

จากเคสที่เป็น Positive ทั้งหมด โมเดลสามารถตรวจพบได้ครบไหม

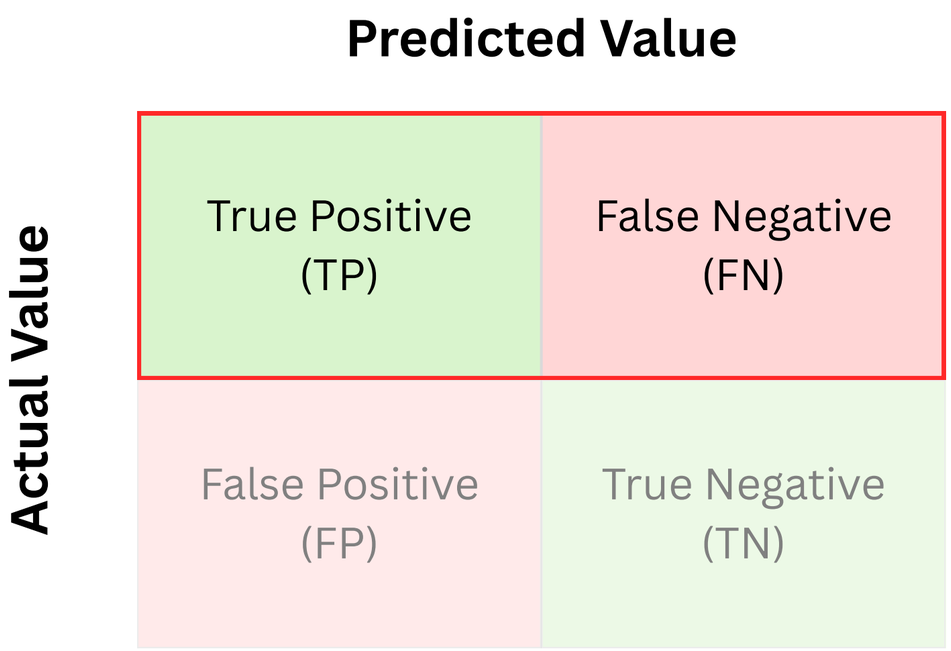

Recall

สัดส่วนของตัวอย่างที่เป็น Positive จริง ซึ่งโมเดลสามารถตรวจพบได้ถูกต้อง หรือ ความสามารถในการตรวจพบผลบวกทั้งหมด

$$Recall = \frac{TP}{TP + FN}$$

มักมีค่าอยู่ในช่วง 0 ถึง 1

Recall สูง

- โมเดลสามารถตรวจพบตัวอย่าง Positive ครบถ้วน
- โอกาสพลาดเคสสำคัญต่ำ
- มี False Negative (FN) น้อย

Recall ต่ำ

- โมเดลตรวจพบ Positive ได้ไม่ครบ
- โมเดลพลาดตัวอย่างที่ควรตรวจพบ
- มี False Negative (FN) จำนวนมาก

Recall

ตัวอย่างงานที่ให้ความสำคัญกับ Recall

Malware Detection

Defect Detection

Medical Screening

Precision

เมื่อโมเดลบอกว่าเป็น Positive มีโอกาสถูกต้องกี่เปอร์เซ็นต์

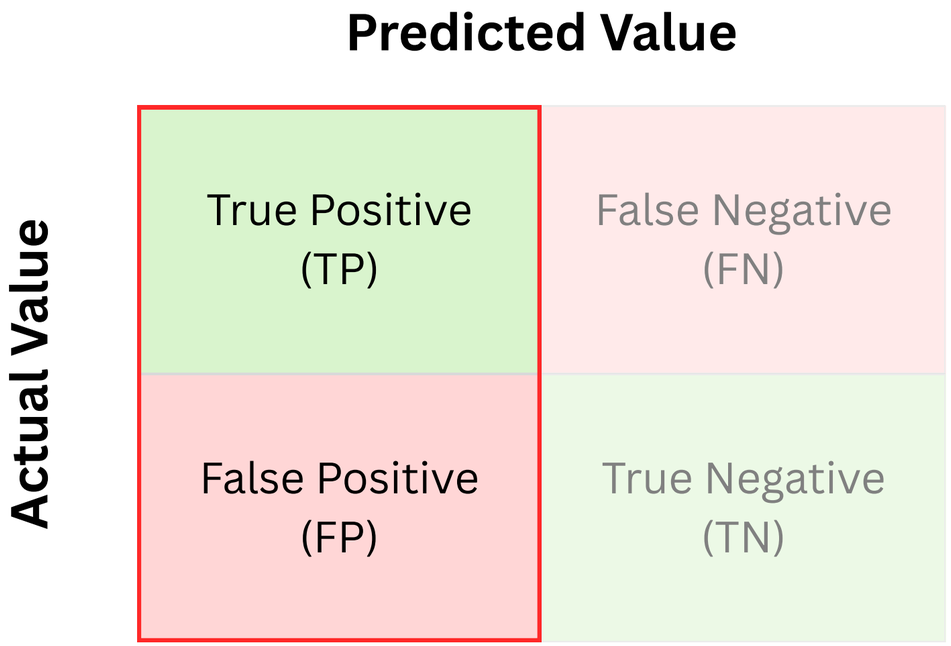

Precision

สัดส่วนของตัวอย่างที่โมเดลทำนายว่าเป็น Positive แล้วเป็น Positive จริง หรือ ความน่าเชื่อถือของการทำนายผลบวก

$$Precision = \frac{TP}{TP + FP}$$

มักมีค่าอยู่ในช่วง 0 ถึง 1

Precision สูง

- โมเดลทำนายว่าเป็น Positive ได้อย่างแม่นยำ
- โมเดลมีความน่าเชื่อถือสูง
- มี False Positive (FP) น้อย

Precision ต่ำ

- โมเดลทำนายว่าเป็น Positive บ่อยเกินจริง
- โมเดลมีการทำนายผิดจำนวนมาก
- มี False Positive (FP) จำนวนมาก

Precision

ตัวอย่างงานที่ให้ความสำคัญกับ Precision

Email Spam Detection

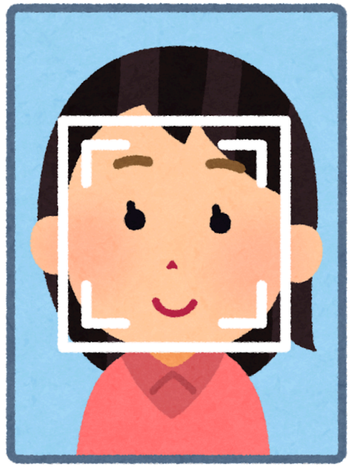

Face Recognition

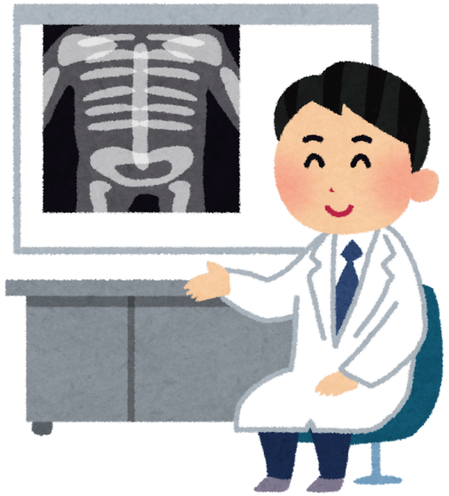

Medical Confirmatory Test

F1 Score

โมเดลมีความสมดุลระหว่าง Precision และ Recall มากน้อยแค่ไหน

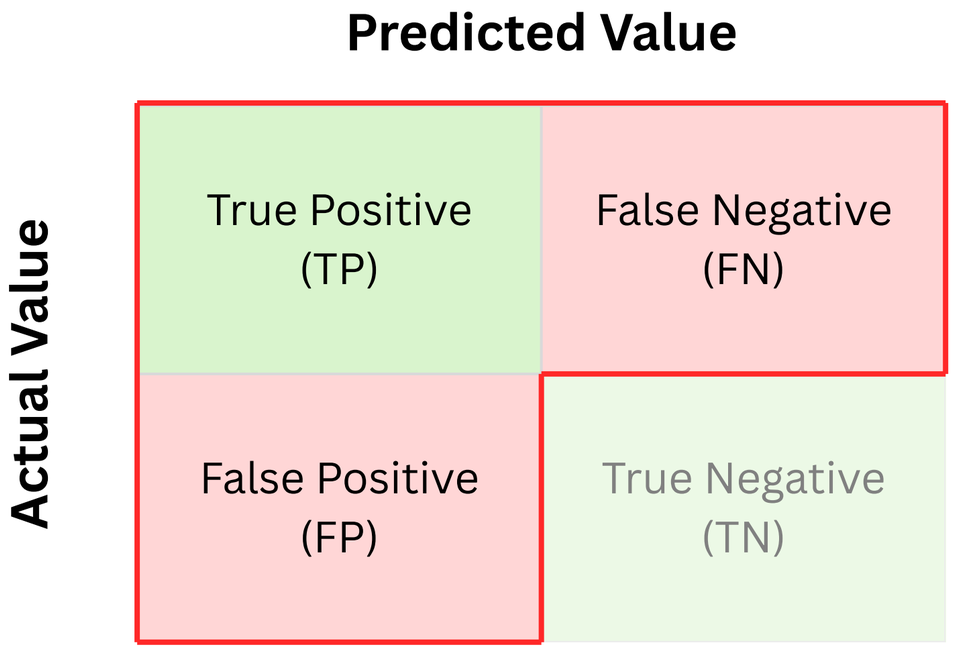

F1 Score

ค่าเฉลี่ยแบบ Harmonic Mean ของ Precision และ Recall

$$F1Score = \frac{2 \times Precision \times Recall}{Precision + Recall}$$

$$F1Score = \frac{2TP}{2TP + FP + FN}$$

มักมีค่าอยู่ในช่วง 0 ถึง 1

F1 Score สูง

- โมเดลมี Precision และ Recall ดีทั้งคู่
- โมเดลสามารถทำนาย Positive ได้อย่างแม่นยำและครบถ้วน
- มีทั้ง False Positive (FP) และ False Negative (FN) ในระดับต่ำ

F1 Score ต่ำ

- อย่างน้อยหนึ่งในสองตัวชี้วัด (Precision หรือ Recall) มีค่าต่ำ
- ประสิทธิภาพโดยรวมของโมเดลยังไม่สมดุล
- มีทั้ง False Positive (FP) และ False Negative (FN) สูง

F1 Score

ตัวอย่างงานที่ให้ความสำคัญกับ F1 Score

Medical

Recall ต้องสูง

- ลดการพลาดผู้ป่วย
- เพิ่มโอกาสรักษาได้ทันท่วงที
- ลดความรุนแรงของโรคในระยะยาว
- ลดความเสี่ยงต่อการเสียชีวิต

Precision ต้องสูง

- ลดการวินิจฉัยผิด
- ได้การรักษาโดยไม่จำเป็น
- คนไข้เกิดความเครียดและความกังวล
- ลดต้นทุนและใช้ทรัพยากรทางการแพทย์

ROC Curve (Receiver Operating Characteristic Curve)

โมเดลสามารถแยกตัวอย่าง Positive ออกจาก Negative ได้ดีแค่ไหน

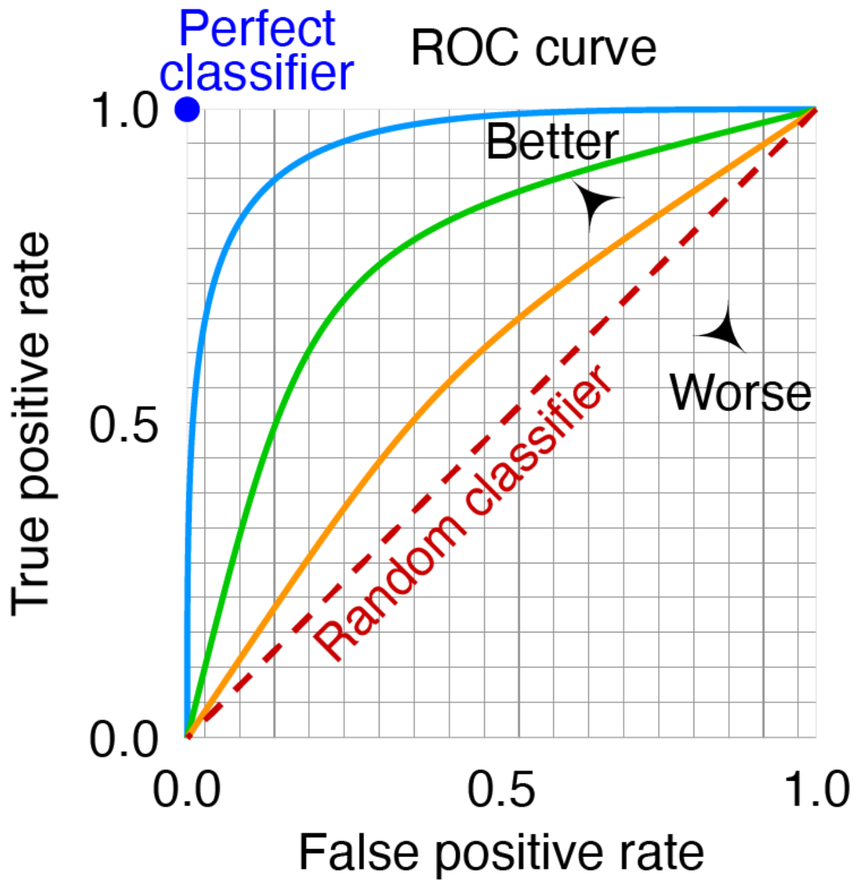

image source: https://commons.wikimedia.org/w/index.php?curid=109730045

ROC Curve

กราฟที่ใช้ประเมินประสิทธิภาพของโมเดล Classification โดยแสดงความสัมพันธ์ระหว่าง True Positive Rate (TPR) และ False Positive Rate (FPR) เมื่อปรับค่า Threshold ของโมเดล

$$TPR = \frac{TP}{TP + FN} \qquad FPR = \frac{FP}{FP + TN}$$

ลักษณะกราฟ ROC Curve ที่ดี

- เส้นอยู่ใกล้มุมซ้ายบน
- TPR สูง FPR ต่ำ

AUC (Area Under the Curve)

โมเดลสามารถแยกตัวอย่าง Positive ออกจาก Negative ได้ดีแค่ไหน

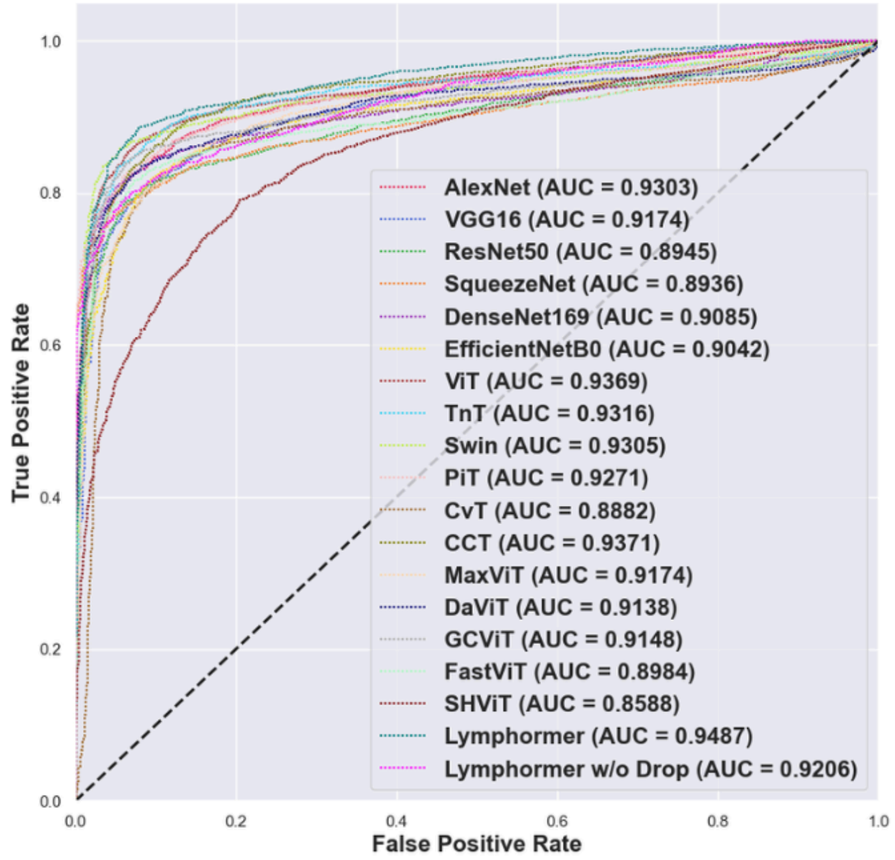

AUC (Area Under the Curve)
พื้นที่ใต้เส้น ROC Curve และใช้วัดว่าโมเดลสามารถ แยกกลุ่ม Positive กับ Negative ได้ดีแค่ไหน

$$AUC = \sum \left(\frac{(x_2 - x_1) \times (y_1 + y_2)}{2} \right)$$

ความหมายของ AUC

- ค่า AUC เข้าใกล้ 1 หมายถึงแบบจำลองแยกได้ดีมาก
- ค่า AUC เท่ากับ 0.5 หมายถึงแยกไม่ได้ ดีกว่าการสุ่มไม่มาก
- ค่า AUC ต่ำกว่า 0.5 หมายถึงแบบจำลองแยกผิดทิศทาง

Object Detection

Object Detection

Object Detection คือ กระบวนการระบุตำแหน่งของวัตถุที่สนใจภายในภาพโดยประมาณ พร้อมทั้งจำแนกประเภทของวัตถุนั้น

ผลลัพธ์ที่ได้จาก Object Detection ประกอบด้วย

Bounding Box แสดงตำแหน่งของวัตถุ

Class Label ระบุประเภทของวัตถุ

Confidence Score แสดงระดับความมั่นใจของโมเดล

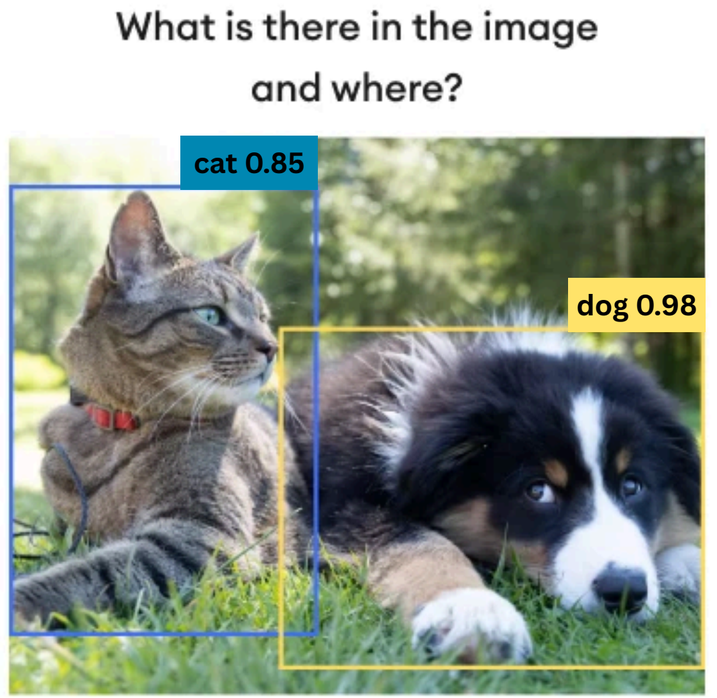

Ground Truth ของ Object Detection

Ground Truth ของ Object Detection ประกอบด้วย

- Bounding Box
- Class Label

Bounding Box มีรูปแบบการกำหนดพิกัดได้หลายแบบ

- Corner coordinates $(x_{min}, y_{min}, x_{max}, y_{max})$
  - กำหนดพิกัดมุมซ้ายบนและมุมขวาล่าง
- Center and Width/Height (x_c, y_c, h, w)
  - กำหนดพิกัดจุดกึ่งกลาง, ความกว้าง และความสูง
- Top-left and Width/Height (x, y, w, h)
  - กำหนดพิกัดมุมซ้ายบน, ความกว้าง และความสูง

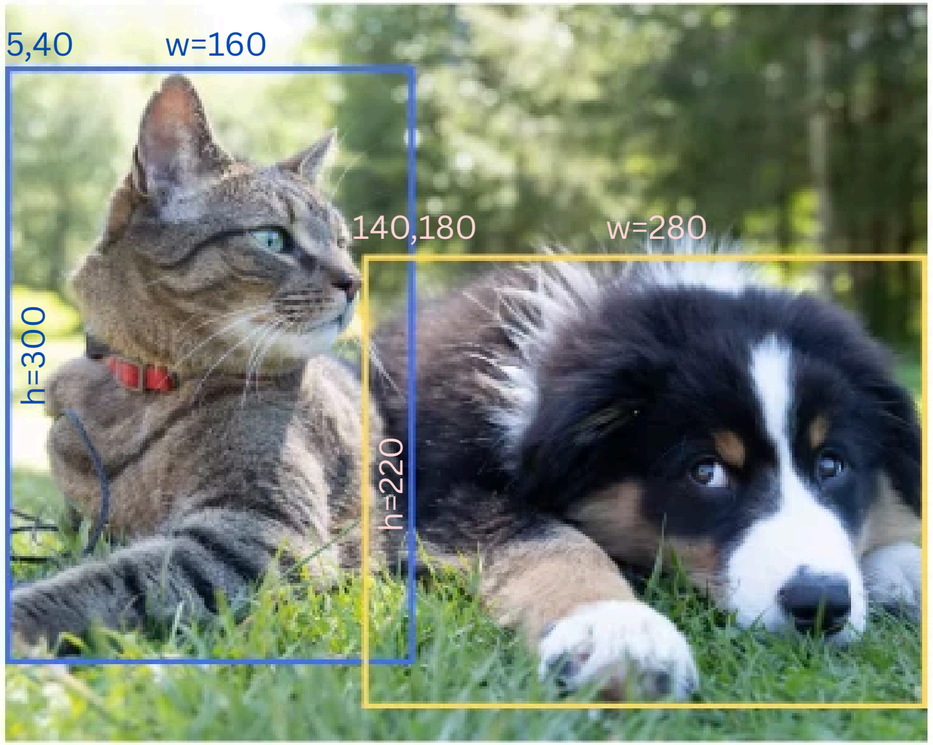

ตัวอย่าง กำหนด Bounding Box แบบ Top-left and Width/Height

Class	x	y	w	h
Cat	5	40	160	300
Dog	140	180	280	220

Evaluation Metrics สำหรับ Object Detection

- Intersection over Union (IoU)
- TP, FP, FN, and TN
- Precision
- Recall
- F1-Score
- Average Precision (AP)
- Mean Average Precision (mAP)

Intersection over Union (IoU)

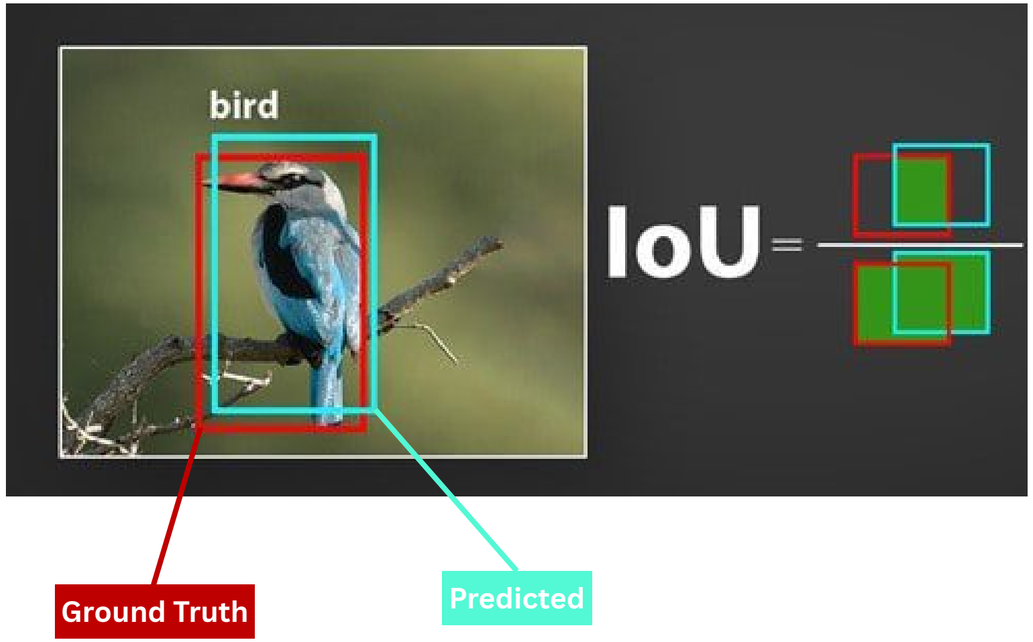

IoU ใช้วัดความซ้อนทับระหว่าง Bounding Box ที่โมเดลทำนาย (Prediction) และ Bounding Box จริง (Ground Truth)

$$IoU = \frac{\text{Area of Overlap}}{\text{Area of Union}}$$

IoU มีค่าอยู่ในช่วง 0 ถึง 1 โดย ค่ายิ่งสูงยิ่งดี แสดงว่าโมเดลสามารถระบุตำแหน่งของวัตถุได้อย่างแม่นยำ

ตัวอย่าง

- Area of Overlap = 85 pixel
- Area of Union = 100 pixel

$$IoU = \frac{85}{100} = 0.850$$

กำหนด IoU Threshold เป็นเกณฑ์ในการตัดสิน

- ถ้า IoU ≥ 0.5 (หรือค่า Threshold ที่กำหนด) และทำนายคลาสถูก → **ถือว่าตรวจจับถูกต้อง**
- ถ้า IoU ต่ำกว่า Threshold → **ถือว่าตรวจจับไม่ถูกต้อง**

TP, FP, FN, and TN

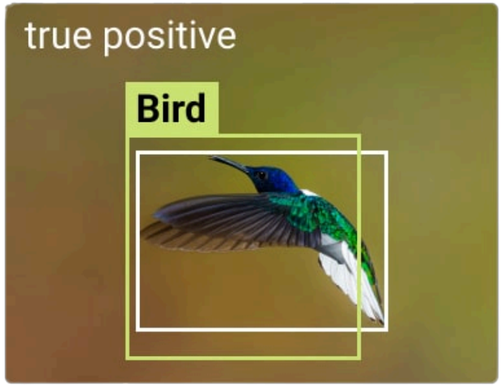

TP (True Positive):
ทำนายพบวัตถุ ถูกคลาส
และ IoU ≥ Threshold

FN (False Negative):
มีวัตถุจริง แต่โมเดลตรวจไม่พบ

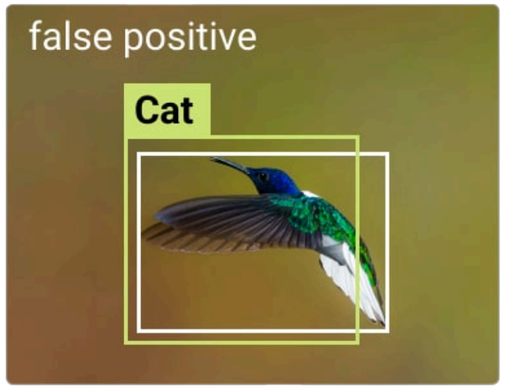

FP (False Positive):
ทำนายพบวัตถุ แต่คลาสผิด
หรือ IoU < Threshold หรือไม่มีวัตถุจริง

True Negative (TN):
ไม่มีวัตถุจริง และโมเดลก็ไม่ได้ตรวจพบวัตถุในบริเวณนั้น แต่มักไม่นำ TN มาใช้ เพราะจำนวนพื้นที่ที่ไม่มีวัตถุมีมากและไม่สามารถกำหนดได้ชัดเจน

Precision

- **Precision** ใช้วัดความแม่นยำ โดยพิจารณาจากวัตถุที่โมเดลตรวจพบทั้งหมด มีจำนวนเท่าใดที่ตรวจพบถูกต้อง

$$Precision = \frac{TP}{TP + FP}$$

- มีค่าอยู่ในช่วง 0 ถึง 1 ค่าสูงแสดงว่า Bounding Box ที่โมเดลตรวจพบส่วนใหญ่ถูกต้อง

ตัวอย่าง โมเดลตรวจพบ bird 12 ตัว
- ถูกต้อง 10 ตัว
- ผิด 2 ตัว

$$Precision = \frac{10}{10 + 2} = 0.833$$

Recall

- **Recall** ใช้วัดความสามารถในการตรวจพบวัตถุ โดยพิจารณาจากวัตถุจริงทั้งหมด โมเดลสามารถตรวจพบได้กี่ตัว

$$Recall = \frac{TP}{TP + FN}$$

- มีค่าอยู่ในช่วง 0 ถึง 1 ค่าสูงแสดงว่า โมเดลสามารถตรวจพบวัตถุจริงได้ครบถ้วน

ตัวอย่าง มี bird จริงทั้งหมด 15 ตัว

- ตรวจพบถูกต้อง 10 ตัว
- พลาดหรือไม่พบ 5 ตัว

$$Recall = \frac{10}{10 + 5} = 0.667$$

F1-Score

- **F1-Score** เป็นค่าเฉลี่ยแบบ Harmonic Mean ของ Precision และ Recall ใช้สำหรับวัดสมดุลระหว่างความแม่นยำ (Precision) และความสามารถในการตรวจพบวัตถุ (Recall)

$$F1\text{-}Score = \frac{2 \times Precision \times Recall}{Precision + Recall} \quad \text{หรือ} \quad F1 - Score = \frac{2 \times Precision \times Recall}{Precision + Recall}$$

- มีค่าอยู่ในช่วง 0 ถึง 1 ค่าสูงแสดงว่าโมเดลมีความสมดุลระหว่างการตรวจจับได้ถูกต้องและการตรวจจับได้ครบถ้วน

ตัวอย่าง

- Precision = 0.833
- Recall = 0.667

$$F1\text{-}Score = \frac{2(0.833)(0.667)}{0.833 + 0.667} = 0.741$$

Average Precision (AP)

- **เมื่อต้องการวัดว่าโมเดลมีประสิทธิภาพอย่างไรภายใต้ Confidence Threshold ที่แตกต่างกัน**
- **Average Precision (AP)** พิจารณาทั้ง Precision และ Recall พร้อมกัน โดยคำนวณจากผลการตรวจจับเมื่อเปลี่ยนค่า Confidence Threshold หลาย ๆ ค่า
- AP คือ พื้นที่ใต้กราฟ Precision–Recall Curve ที่ใช้ประเมินประสิทธิภาพของโมเดล Object Detection สำหรับวัตถุหนึ่งคลาส

$$AP = \int_0^1 Precision(Recall)\, dRecall$$

- มีค่าอยู่ในช่วง 0 ถึง 1 ยิ่งค่าสูงแสดงว่าสามารถรักษาทั้ง Precision และ Recall ให้อยู่ในระดับสูงได้ดี

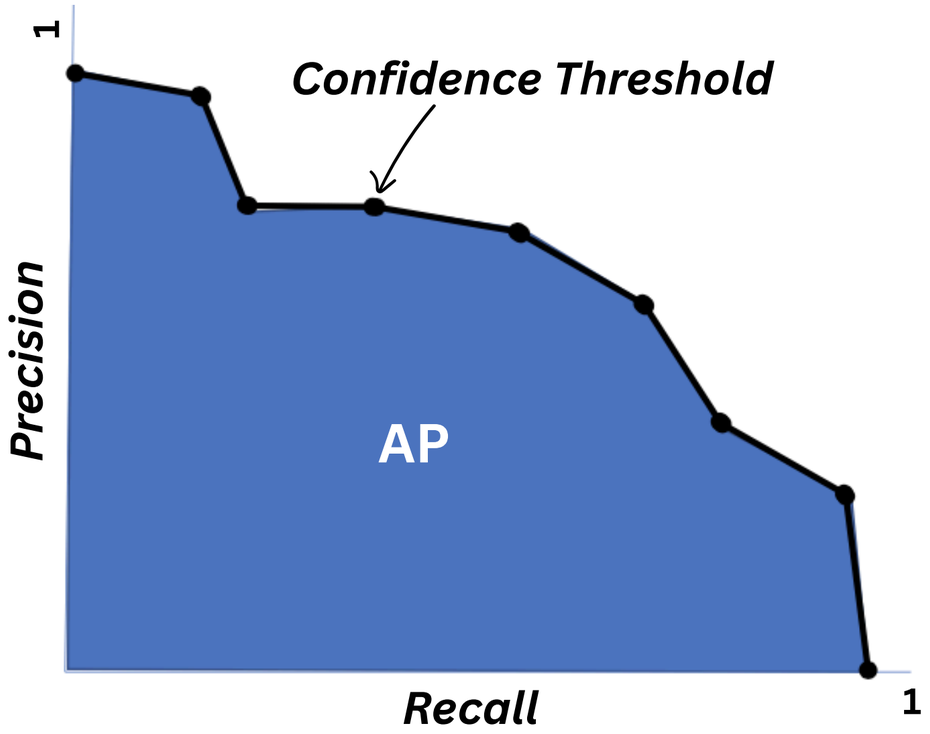

Average Precision (AP)

ตัวอย่าง กำหนดให้มี bird จริงทั้งหมด 20 ตัว

Confidence Threshold	TP	FP	FN	Precision	Recall
≥ 0.95	2	0	18	1.00	0.10
≥ 0.90	4	0	16	1.00	0.20
≥ 0.85	6	1	14	0.86	0.30
≥ 0.80	8	2	12	0.80	0.40
≥ 0.75	10	3	10	0.77	0.50
≥ 0.70	12	5	8	0.71	0.60
≥ 0.65	14	7	6	0.67	0.70
≥ 0.60	16	10	4	0.62	0.80
≥ 0.50	18	14	2	0.56	0.90
≥ 0.40	20	20	0	0.50	1.00

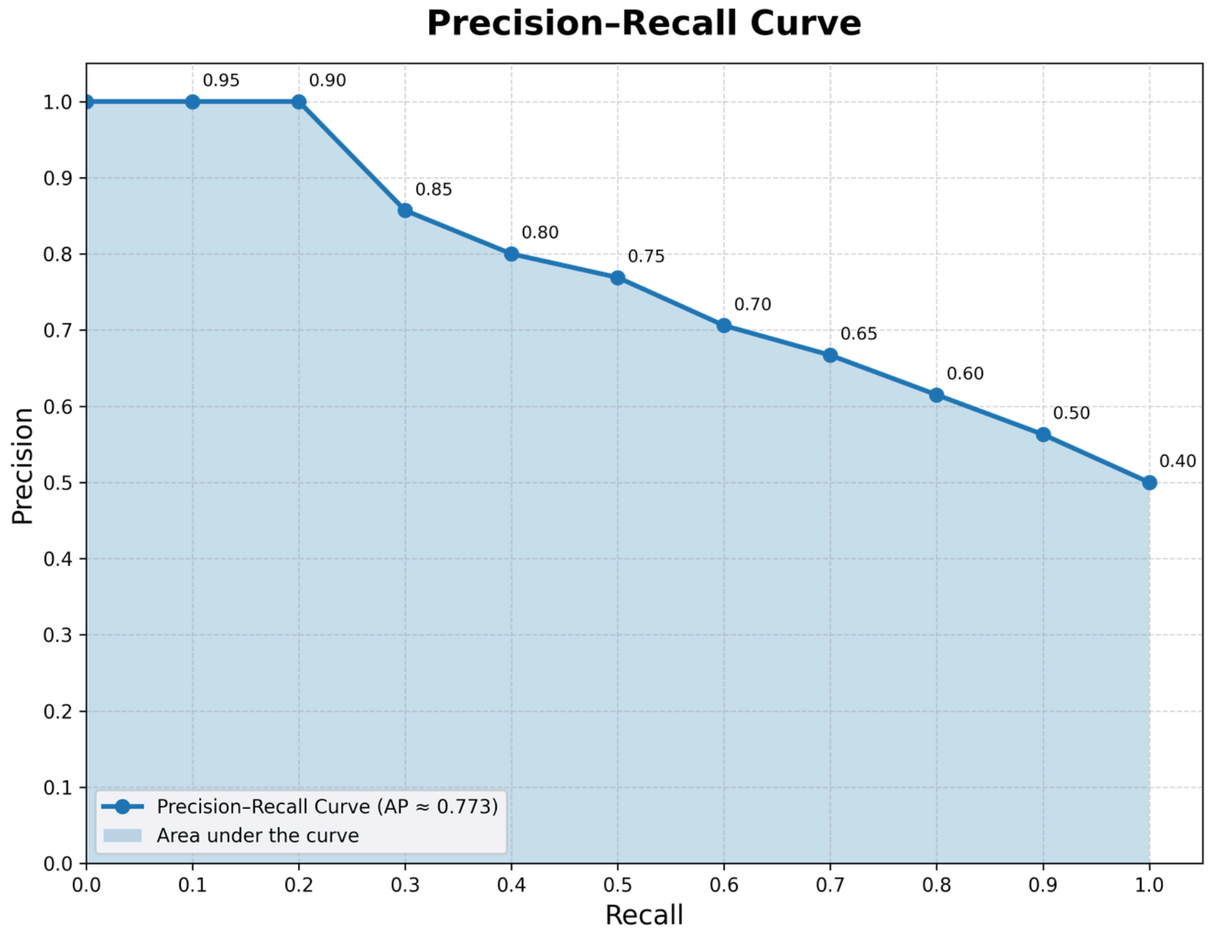

$$AP = \int_0^1 Precision(Recall)\, dRecall = 0.773$$

Mean Average Precision (mAP)

Mean Average Precision (mAP) คือ ค่าเฉลี่ยของ AP ทุกคลาส

$$mAP = \frac{\sum AP_i}{N}$$

ตัวอย่าง

คำนวณ AP แยกแต่ละคลาส และหาค่าเฉลี่ย

Class	AP
Bird	0.773
Car	0.883
Dog	0.842

$$mAP = \frac{0.773 + 0.883 + 0.842}{3} = 0.833$$

Image Segmentation

Image Segmentation

Image Segmentation คือ การจำแนกหรือกำหนดคลาสให้แต่ละ Pixel ในภาพ เพื่อให้สามารถระบุรูปร่างและขอบเขตของวัตถุได้อย่างละเอียด

ผลลัพธ์ที่ได้จาก Image Segmeatation คือ Pixel Mask

- Pixel Mask คือการกำหนด Label ให้กับแต่ละ Pixel เพื่อบอกว่า Pixel นั้นเป็นของคลาสอะไร
- ตำแหน่งของแต่ละ Pixel ใน Mask จะสอดคล้องกับตำแหน่งในภาพต้นฉบับ

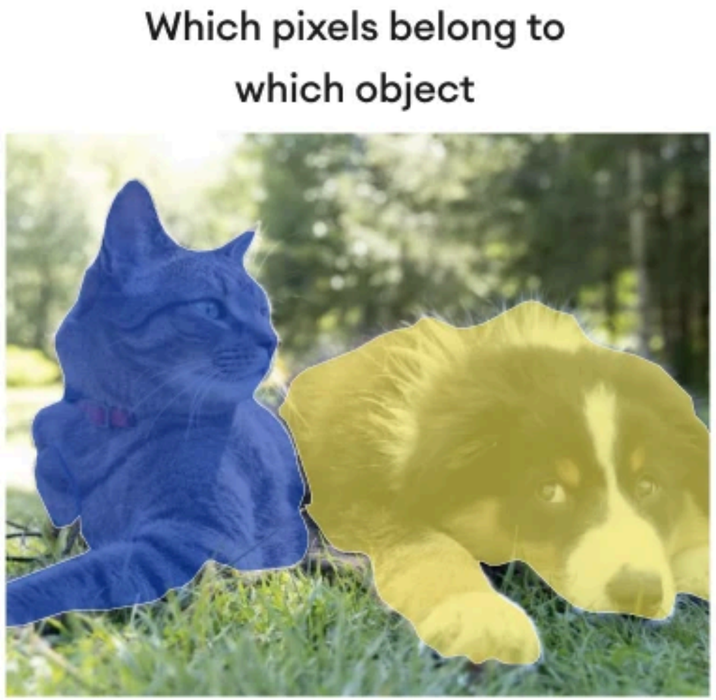

Label Settings in Image Segmentation

Label Setting	หลักการ	ตัวอย่าง
Binary Segmentation	แบ่ง Pixel เป็น 2 คลาส เช่น Object / Background	
Multi-class Segmentation	มีหลายคลาส และแต่ละ Pixel เป็นได้เพียง **1 คลาส**	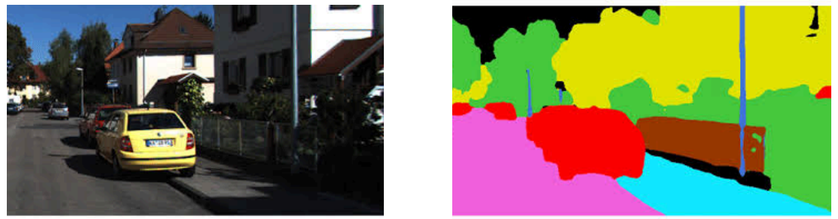
Multi-label Segmentation	แต่ละ Pixel สามารถมีได้ **มากกว่า 1 คลาส** **พร้อมกัน**	

**Multi-label Evaluation:* ประเมินแต่ละคลาสแยกกันแบบ *Binary Segmentation*

Ground Truth ของ Image Segmentation

Ground Truth ของ Segmentation เรียกว่า Pixel Mask ทุกพิกเซลจะถูกกำหนดคลาส

ตัวอย่าง Multi-class Segmentation

0: background
1: cat
2: dog

0	0	0	0	0	0	0	0	0	0
0	0	1	0	1	0	0	0	0	0
0	0	1	1	1	0	0	0	0	0
0	0	1	1	1	2	2	2	2	0
0	0	1	1	1	2	2	2	2	0
0	1	1	1	1	2	2	2	2	2
0	1	1	1	1	2	2	2	2	2
1	1	1	1	0	0	2	0	2	2
0	0	0	0	0	0	0	0	0	0

Evaluation Metrics สำหรับ Image Segmentation

- TP, FP, FN, and TN
- Pixel Accuracy
- Intersection over Union (IoU)
- Precision
- Recall
- F1-Score
- ตัวอย่าง
  - Binary Segmentation
  - Multi-class Segmentation

TP, FP, FN, and TN

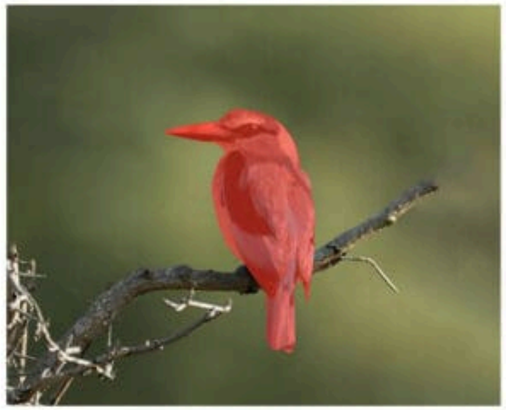

Ground Truth Mask

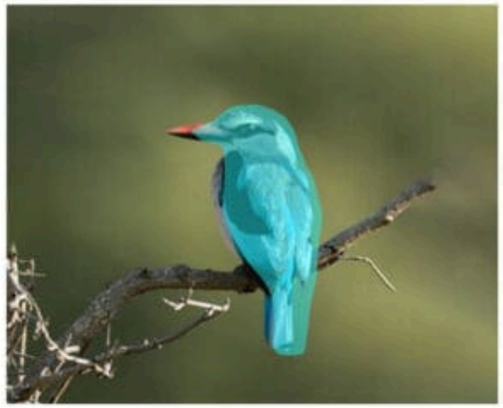

Predicted Mask

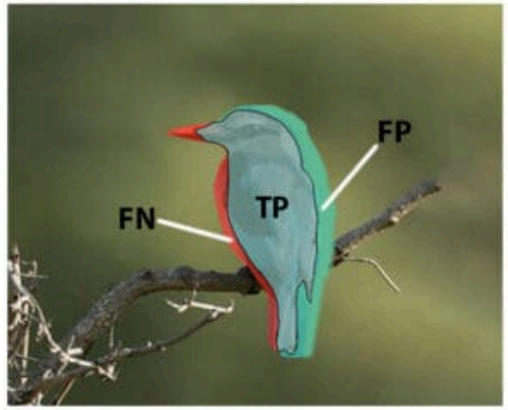

Metric	ความหมาย
True Positive (TP)	พิกเซลที่เป็น **วัตถุจริง** (Ground Truth) และโมเดลทำนายว่าเป็น **วัตถุ** ได้
False Positive (FP)	พิกเซลที่เป็น **พื้นหลังจริง** แต่โมเดลทำนายว่าเป็น **วัตถุ**
False Negative (FN)	พิกเซลที่เป็น **วัตถุจริง** แต่โมเดลทำนายว่าเป็น **พื้นหลัง**
True Negative (TN)	พิกเซลที่เป็น **พื้นหลังจริง** และโมเดลทำนายว่าเป็น **พื้นหลัง** ได้ถูกต้อง

Evaluation Metrics

Metric	สมการ	ความหมาย
Pixel Accuracy	$Pixel\ Accuracy = \frac{\text{Correct Pixels}}{\text{Total Pixels}}$	Pixel ทั้งหมด โมเดลทำนายถูกมีสัดส่วนเท่าไร
Precision	$Precision = \frac{TP}{TP + FP}$	Pixel ที่โมเดลทำนายว่าเป็นวัตถุ มีสัดส่วนที่ถูกต้องเท่าไร
Recall	$Recall = \frac{TP}{TP + FN}$	Pixel ของวัตถุจริง โมเดลสามารถตรวจพบได้ครบแค่ไหน
F1-score	$F1\text{-}Score = \frac{2TP}{2TP + FP + FN}$	วัดความสมดุลระหว่าง Precision และ Recall
IoU	$IoU = \frac{TP}{TP + FP + FN}$	วัดความซ้อนทับระหว่าง Prediction และ Ground Truth

- โดย Metrics เหล่านี้มีค่าอยู่ในช่วง 0 ถึง 1 ค่ายิ่งสูง แสดงว่าโมเดลมีประสิทธิภาพในการ Segmentation ที่ดีขึ้น

Binary Segmentation

ตัวอย่าง 1 = Object (Cat)
0 = Background

1	1	0	0
1	1	1	0
0	1	1	0
0	0	0	0

Ground Truth (Actual)

1	0	0	0
1	1	1	0
0	1	0	0
0	0	1	0

Prediction

		Predicted	
		1	0
Ground Truth	1	TP	FN
	0	FP	TN

Confusion Matrix

Binary Segmentation

ตัวอย่าง 1 = Object (Cat)
0 = Background

1	1	0	0
1	1	1	0
0	1	1	0
0	0	0	0

Ground Truth (Actual)

1	0	0	0
1	1	1	0
0	1	0	0
0	0	1	0

Prediction

Ground Truth \ *Predicted*	1	0
1	TP=5	FN
0	FP	TN

Confusion Matrix

Binary Segmentation

ตัวอย่าง 1 = Object (Cat)
0 = Background

1	1	0	0
1	1	1	0
0	1	1	0
0	0	0	0

Ground Truth (Actual)

1	0	0	0
1	1	1	0
0	1	0	0
0	0	1	0

Prediction

Ground Truth \ *Predicted*	1	0
1	TP=5	FN=2
0	FP	TN

Confusion Matrix

Binary Segmentation

ตัวอย่าง 1 = Object (Cat)
0 = Background

1	1	0	0
1	1	1	0
0	1	1	0
0	0	0	0

Ground Truth (Actual)

1	0	0	0
1	1	1	0
0	1	0	0
0	0	1	0

Prediction

Ground Truth \ *Predicted*	1	0
1	TP=5	FN=2
0	FP=1	TN

Confusion Matrix

Binary Segmentation

ตัวอย่าง 1 = Object (Cat)
0 = Background

1	1	0	0
1	1	1	0
0	1	1	0
0	0	0	0

Ground Truth (Actual)

1	0	0	0
1	1	1	0
0	1	0	0
0	0	1	0

Prediction

		Predicted	
		1	0
Ground Truth	1	TP=5	FN=2
	0	FP=1	TN=8

Confusion Matrix

Binary Segmentation

1	1	0	0
1	1	1	0
0	1	1	0
0	0	0	0

Ground Truth (Actual)

1	0	0	0
1	1	1	0
0	1	0	0
0	0	1	0

Prediction

		Predicted	
		1	0
Ground Truth	1	TP=5	FN=2
	0	FP=1	TN=8

$$Pixel\ Accuracy = \frac{\text{Correct Pixels}}{\text{Total Pixels}} = \frac{13}{16} = 0.813$$

$$Precision = \frac{TP}{TP + FP} = \frac{5}{5 + 1} = 0.833$$

$$Recall = \frac{TP}{TP + FN} = \frac{5}{5 + 2} = 0.714$$

$$F1\text{-}Score = \frac{2TP}{2TP + FP + FN} = \frac{10}{10 + 1 + 2} = \frac{10}{13} = 0.769$$

$$IoU = \frac{TP}{TP + FP + FN} = \frac{5}{5 + 1 + 2} = \frac{5}{8} = 0.625$$

Multi-class Segmentation

- คำนวณ TP, FP, FN และ TN แยกสำหรับแต่ละคลาสแบบ One-vs-All
- จากนั้นจึงหาค่าเฉลี่ยของแต่ละ Metric เช่น Mean Precision, Mean Recall, Mean F1-score, และ Mean IoU

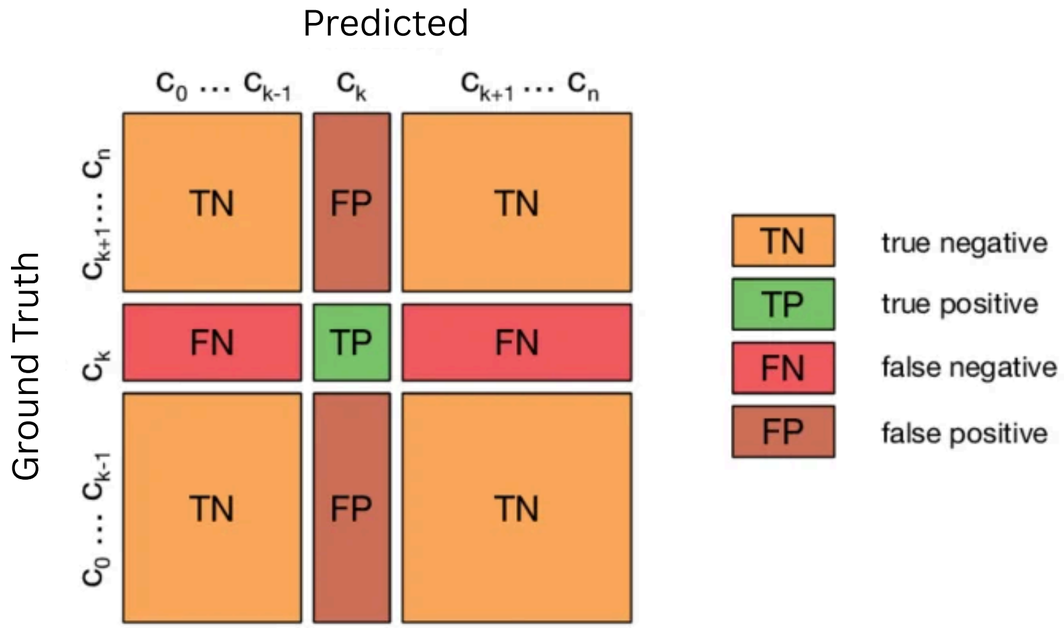

Multi-class Segmentation

ตัวอย่าง

0 = Background
1 = Cat
2 = Dog

1	1	0
1	2	2
0	0	2

Ground Truth (Actual)

1	0	0
1	2	0
0	2	2

Prediction

Ground Truth \ *Predicted*	0	1	2
0	2	0	1
1	1	2	0
2	1	0	2

Confusion Matrix

Multi-class Segmentation

ตัวอย่าง Confusion Matrix ของคลาส Background (0)

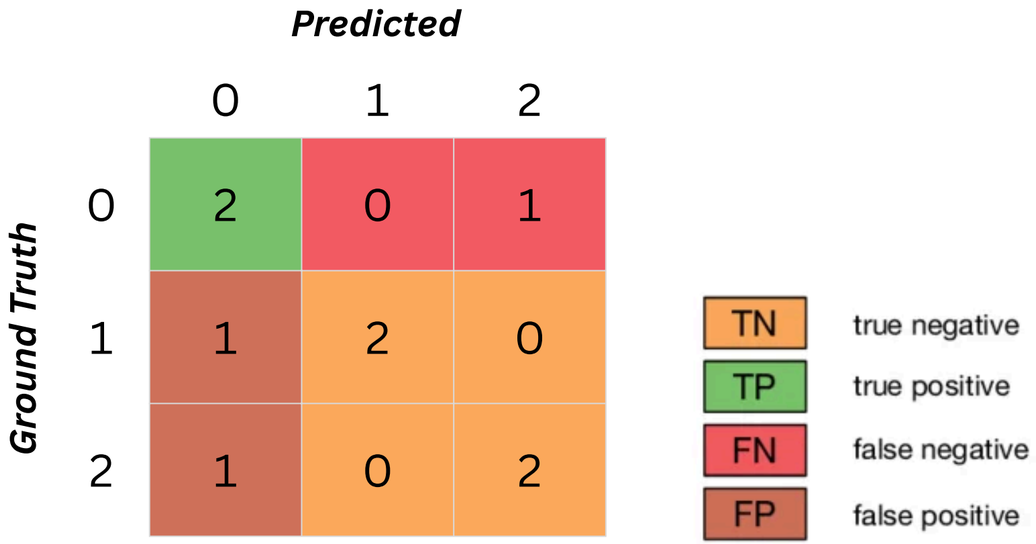

Confusion Matrix

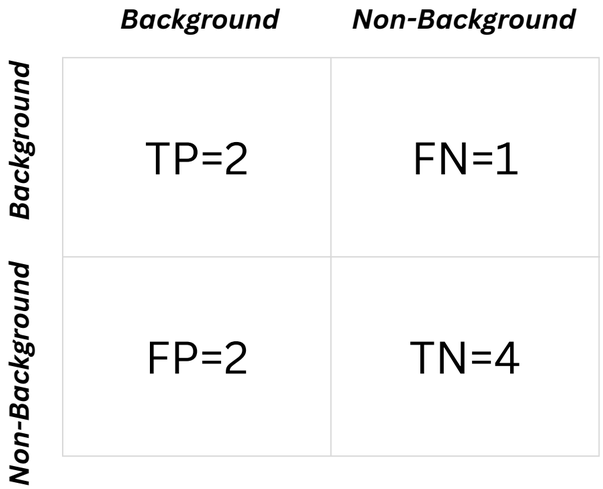

Confusion Matrix ของคลาส Background (0)

Multi-class Segmentation

ตัวอย่าง Confusion Matrix ของคลาส Cat (1)

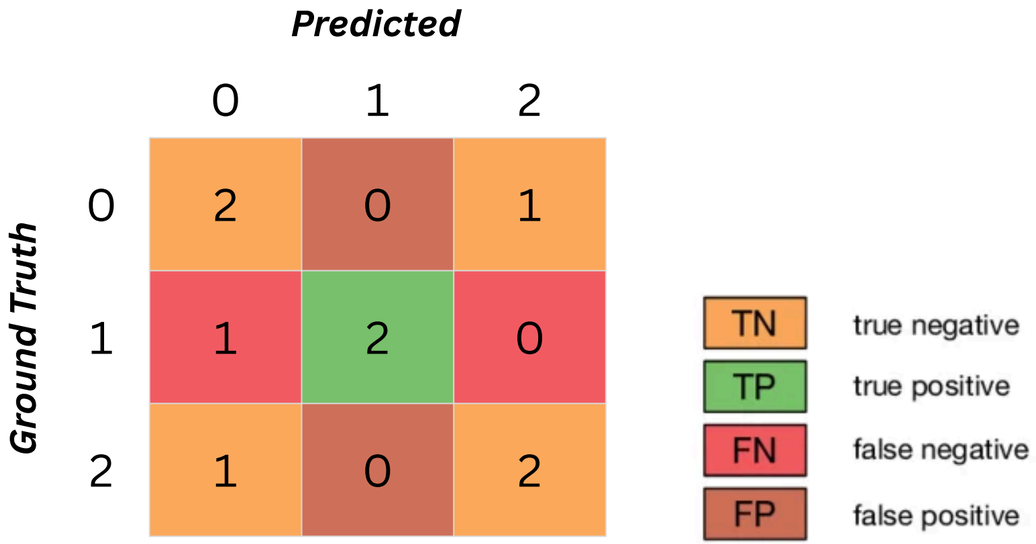

Confusion Matrix

		Cat	*Non-Cat*
Cat		TP=2	FN=1
Non-Cat		FP=0	TN=6

Confusion Matrix ของคลาส Cat (1)

Multi-class Segmentation

ตัวอย่าง Confusion Matrix ของคลาส Dog (2)

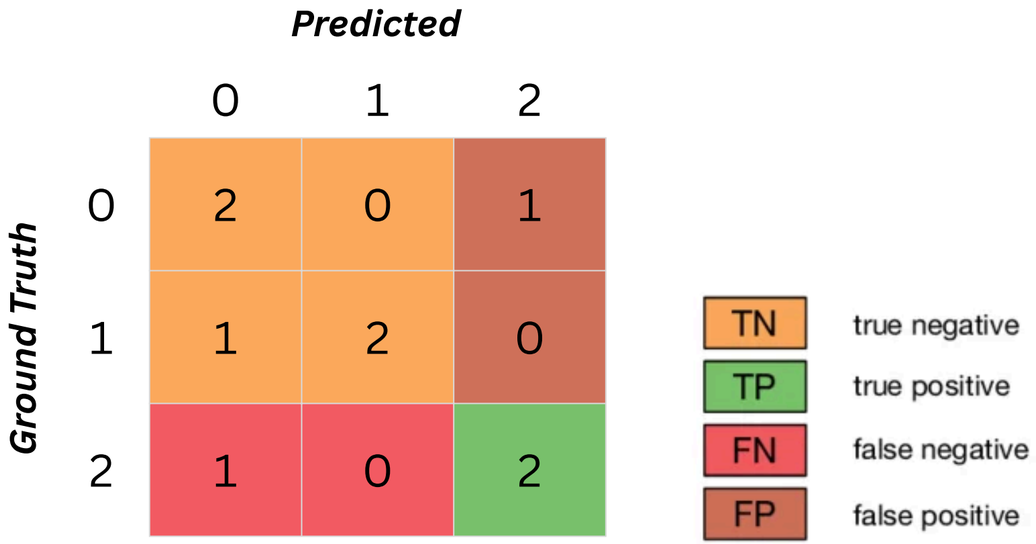

Confusion Matrix

		Dog	Non-Dog
Ground Truth	*Dog*	TP=2	FN=1
	Non-Dog	FP=1	TN=5

Confusion Matrix ของคลาส Dog (2)

Multi-class Segmentation

ตัวอย่าง

0 = Background
1 = Cat
2 = Dog

1	1	0
1	2	2
0	0	2

Ground Truth (Actual)

1	0	0
1	2	0
0	2	2

Prediction

$$Pixel\ Accuracy = \frac{\text{Correct Pixels}}{\text{Total Pixels}} = \frac{6}{9} = 0.667$$

Multi-class Segmentation

ตารางผลแต่ละคลาส

Class	TP	FP	FN	IoU	Precision	Recall	F1-Score
Background	2	2	1	0.400	0.500	0.667	0.571
Cat	2	0	1	0.667	1.000	0.667	0.800
Dog	2	1	1	0.500	0.667	0.667	0.667

ตารางสรุปค่าเฉลี่ย

Metric	Value
Pixel Accuracy	0.667
mIoU	0.522
mPrecision	0.722
mRecall	0.667
mF1-Score	0.679

$$mIoU = \frac{0.400 + 0.667 + 0.500}{3} = 0.522$$

Video Processing

จากงานภาพสู่งานวิดีโอ

Image Classification
ภาพนี้คือภาพอะไร?

1 ภาพ → 1 คลาส

Object Detection
วัตถุอะไรและอยู่ตรงไหน?

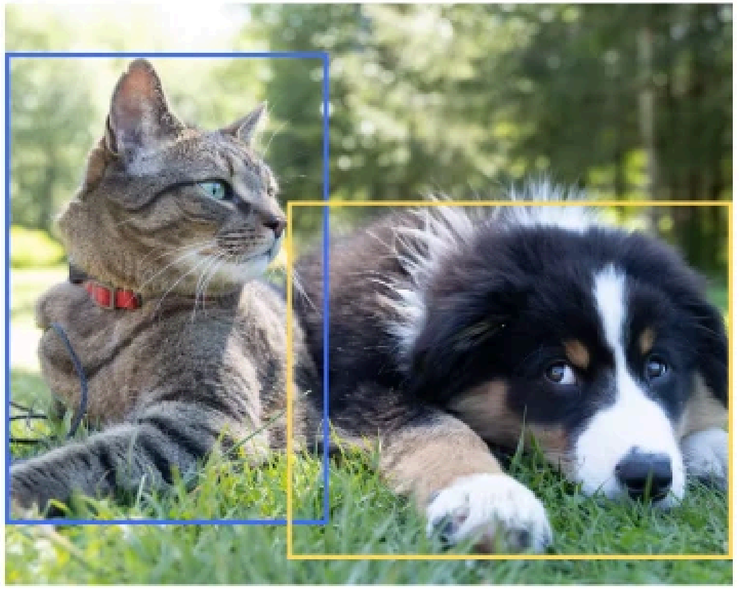

คลาสของวัตถุ + ตำแหน่ง

Image Segmentation
แต่ละพิกเซลคืออะไร?

ทุกพิกเซล → 1 คลาส

คำถามต่างกัน → Ground truth และ Output ต่างกัน

source: https://www.superannotate.com/blog/image-segmentation-for-machine-learning

ความแตกต่างของภาพและวิดีโอ

ภาพ		วิดีโอ
		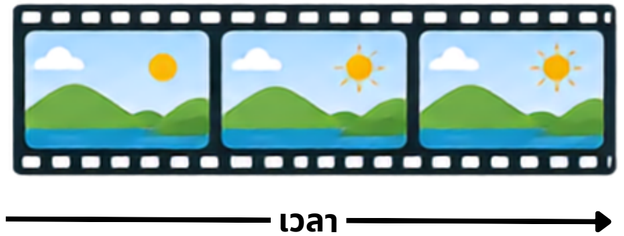
1 เฟรม	**จำนวนข้อมูล**	หลายเฟรม
ไม่มี	**เวลา**	มี ⭐
ไม่สำคัญ	**ลำดับ**	สำคัญ ⭐
Spatial	**บริบท**	Spatial + **Temporal**
ระดับภาพ / พิกเซล / วัตถุ	**ผลลัพธ์**	ระดับคลิปวิดีโอ / เฟรม / ช่วงเวลา

ความแตกต่างของภาพและวิดีโอ

ภาพ

วิดีโอ

กำลังนั่งลง

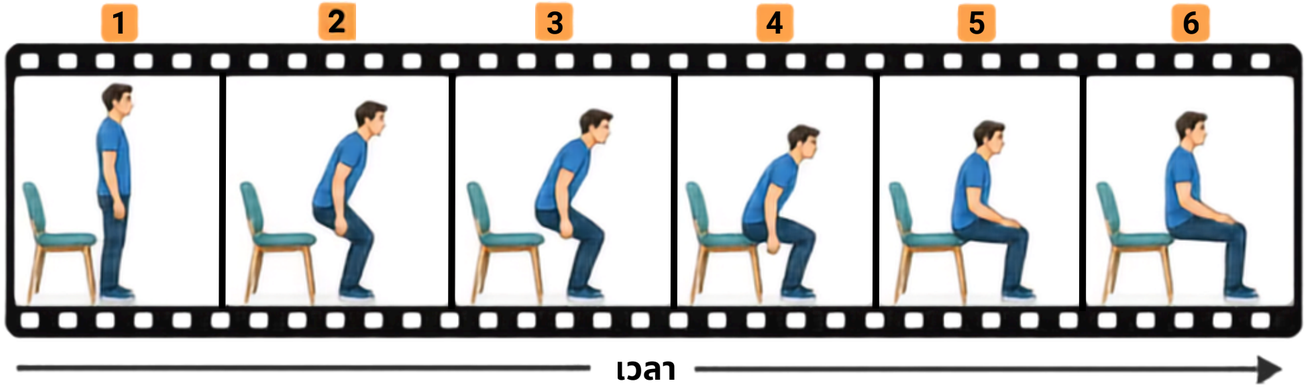

กำลังลุกขึ้น

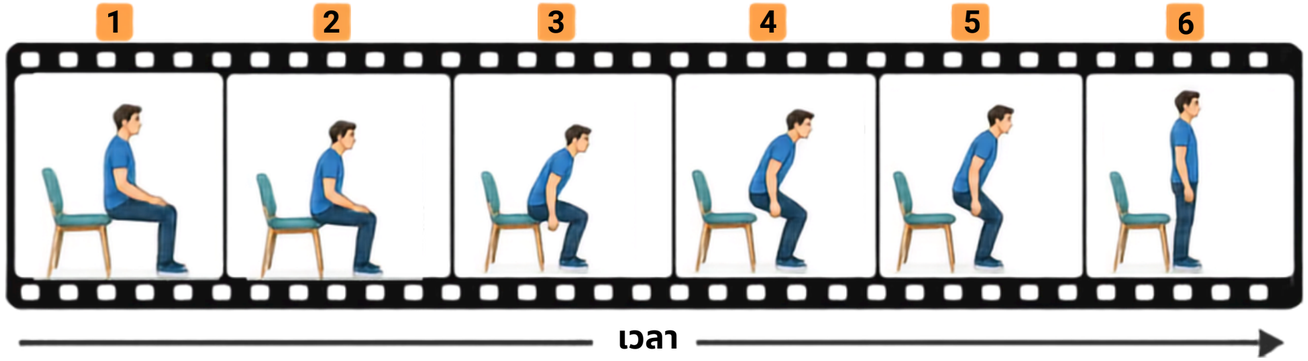

ประเภทของงานวิดีโอ

1. Video Classification
2. Temporal Action Segmentation
3. Temporal Action Localization
4. Regression

งานภาพ + เวลา = มุมมองของงานวิดีโอ

1 Image Classification

กำหนด label ให้ภาพเดียว

ผลลัพธ์

ว่ายน้ำ

(label เดียว)

VS

Video Classification

รับข้อมูลหลายเฟรม และกำหนด label เดียวให้ทั้งวิดีโอ

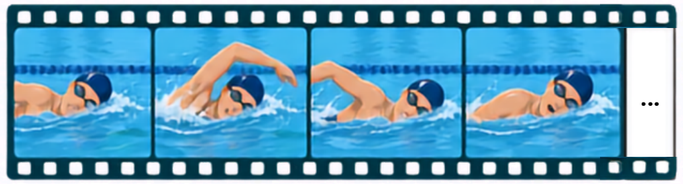

เวลา

ผลลัพธ์

ว่ายน้ำ

(label เดียว)

2 Image Segmentation

กำหนด label ให้ทุกพิกเซลในภาพ

กำหนด label ให้พิกเซล

- ถนน
- รถ
- อาคาร
- ต้นไม้
- ท้องฟ้า
- ทางเท้า

VS

Temporal Action Segmentation

กำหนด label ให้ทุกตำแหน่งเวลา (ทุกเฟรม)

เวลา

ผลลัพธ์ : label ทุกเฟรม

เตรียมอาหาร	หั่น	ทำอาหาร	จัดจาน

เวลา

3 Object Detection

กำหนดกรอบ (bounding box) ให้ทุกวัตถุในภาพ

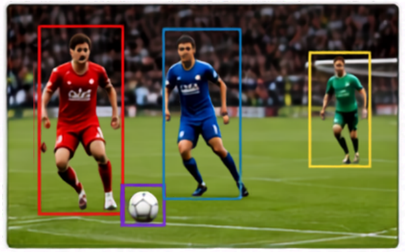

ผลลัพธ์

- นักเตะ
- นักเตะ
- ผู้รักษาประตู
- ลูกบอล
- ...

VS

Temporal Action Localization

กำหนดช่วงเวลาของแต่ละการกระทำ (ช่วงบน timeline) ไม่จำเป็นต้อง label ทุกเฟรม

เวลา

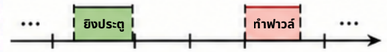

ผลลัพธ์ : ช่วงเวลาของแต่ละการกระทำ

การกระทำ	ช่วงเวลา [เริ่ม-จบ]	ค่าความมั่นใจ
ยิงประตู	[00:01:15 – 00:01:20]	0.87
ทำฟาวล์	[00:02:42 – 00:02:48]	0.92

1 Video Classification

Goal	จำแนกว่าวิดีโอทั้งคลิปคือคลาสอะไร
Input	วิดีโอ/คลิปหนึ่งคลิป โดยมักเป็น trimmed clip หรือคลิปที่มีเนื้อหาหลักชัดเจน
Ground Truth	1 class label ต่อ 1 คลิป เช่น ว่ายน้ำ, ยิงธนู, วิ่ง เป็นต้น
Focus	ทั้งคลิปวิดีโอ

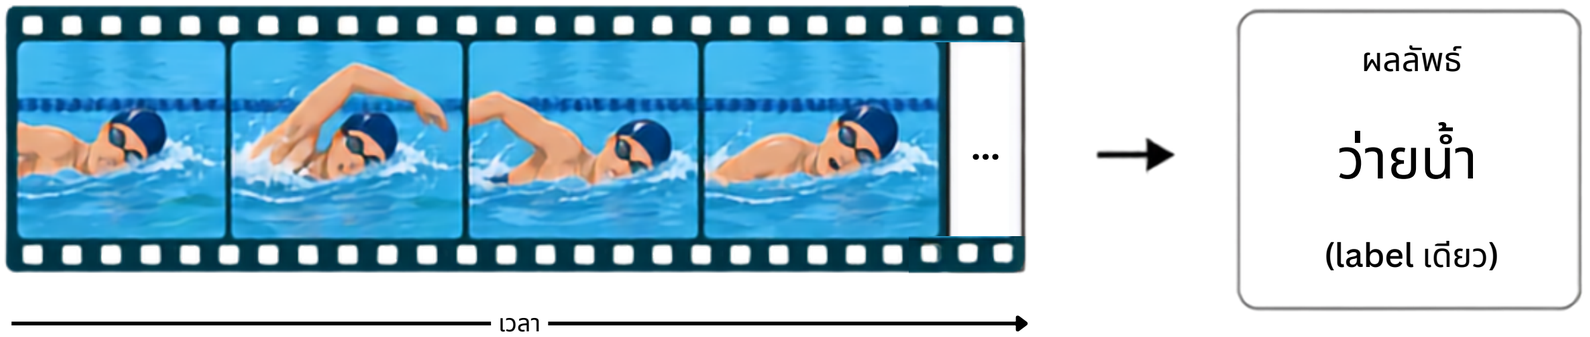

Evaluation Metrics สำหรับ Video Classification

Evaluate ทำนาย คลาสของทั้งวิดีโอ ถูกต้องหรือไม่

Metrics **Accuracy** - สัดส่วนวิดีโอที่ทำนายคลาสได้ถูกต้องจากทั้งหมด

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

ตัวอย่าง จากวิดีโอทั้งหมด 20 วิดีโอ

- TP = 8 : เป็น ว่ายน้ำ และโมเดลทาย ว่ายน้ำ
- FP = 2 : ไม่ใช่ ว่ายน้ำ แต่โมเดลทาย ว่ายน้ำ
- FN = 1 : เป็น ว่ายน้ำ แต่โมเดลทายเป็นคลาสอื่น
- TN = 9 : ไม่ใช่ ว่ายน้ำ และโมเดลไม่ทาย ว่ายน้ำ

มักมีช่วงค่าอยู่ในช่วง 0-1
ค่าสูง: ทายถูกโดยรวมมาก
ค่าต่ำ: ทายผิดโดยรวมมาก

$$Accuracy = \frac{8 + 9}{20} = 0.85 = 85\%$$

Evaluation Metrics สำหรับ Video Classification

Evaluate ทำนาย คลาสของทั้งวิดีโอ ถูกต้องหรือไม่

Metrics **Precision** - จากที่โมเดลทำนายว่าเป็นคลาสนั้น มีจำนวนที่ถูกจริงเท่าไร
- สิ่งที่โมเดลทำนายออกมา เชื่อถือได้แค่ไหน

$$Precision = \frac{TP}{TP + FP}$$

ตัวอย่าง จากวิดีโอทั้งหมด 20 วิดีโอ

- TP = 8 : เป็น ว่ายน้ำ และโมเดลทาย ว่ายน้ำ
- FP = 2 : ไม่ใช่ ว่ายน้ำ แต่โมเดลทาย ว่ายน้ำ
- FN = 1 : เป็น ว่ายน้ำ แต่โมเดลทายเป็นคลาสอื่น
- TN = 9 : ไม่ใช่ ว่ายน้ำ และโมเดลไม่ทาย ว่ายน้ำ

มักมีช่วงค่าอยู่ในช่วง 0-1
ค่าสูง: False alarm หรือ FP น้อย
ค่าต่ำ: โมเดลทำนายผิดเป็น Positive มาก

$$Precision = \frac{8}{8 + 2} = 0.80 = 80\%$$

Evaluation Metrics สำหรับ Video Classification

Evaluate ทำนาย คลาสของทั้งวิดีโอ ถูกต้องหรือไม่

Metrics **Recall** - จากตัวอย่างของคลาสนั้นที่มีอยู่จริง โมเดลสามารถหาเจอได้เท่าไร

$$Recall = \frac{TP}{TP + FN}$$

ตัวอย่าง จากวิดีโอทั้งหมด 20 วิดีโอ

- TP = 8 : เป็น ว่ายน้ำ และโมเดลทาย ว่ายน้ำ
- FP = 2 : ไม่ใช่ ว่ายน้ำ แต่โมเดลทาย ว่ายน้ำ
- FN = 1 : เป็น ว่ายน้ำ แต่โมเดลทายเป็นคลาสอื่น
- TN = 9 : ไม่ใช่ ว่ายน้ำ และโมเดลไม่ทาย ว่ายน้ำ

มักมีช่วงค่าอยู่ในช่วง 0-1
ค่าสูง: หา Positive จริงได้ครบ
ค่าต่ำ: มี Positive จริงจำนวนมากที่โมเดลหาไม่เจอ

$$Recall = \frac{8}{8 + 1} = 0.889 = 88.9\%$$

Evaluation Metrics สำหรับ Video Classification

Evaluate ทำนาย คลาสของทั้งวิดีโอ ถูกต้องหรือไม่

Metrics **F1-Score** - ค่า Harmonic Mean ของ Precision และ Recall เพื่อดูความสมดุลของทั้งสองค่า

$$F1 - Score = \frac{2 \times Precision \times Recall}{Precision + Recall}$$

มักมีช่วงค่าอยู่ในช่วง 0-1
ค่าสูง: Precision และ Recall ดีทั้งคู่ 👍
ค่าต่ำ: Precision หรือ Recall อย่างน้อยหนึ่งด้านต่ำ

$$Precision = \frac{8}{8+2} = 0.80 = 80\%$$

$$Recall = \frac{8}{8+1} = 0.889 = 88.9\%$$

$$F1 - Score = \frac{2 \times 0.80 \times 0.889}{0.80 + 0.889} = 0.842 = 84.2\%$$

ตัวอย่างงาน Video Classification

จำแนกชนิดกีฬา

จำแนกกิจกรรมของคน

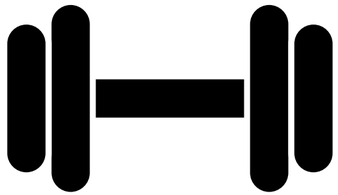

จำแนกท่าออกกำลังกาย

2 Temporal Action Segmentation

Goal	จำแนกว่าแต่ละช่วงเวลาหรือแต่ละเฟรมของวิดีโอกำลังทำ action อะไร
Input	วิดีโอยาวแบบ untrimmed ซึ่งภายในวิดีโอมีหลาย action ต่อเนื่องกัน
Ground Truth	Action label ทุก frame/time step ตลอดทั้งวิดีโอ เช่น เตรียมอาหาร, หั่น, ทำอาหาร, จัดจาน เป็นต้น
Focus	ทุกเฟรม

Evaluation Metrics สำหรับ Temporal Action Segmentation

Evaluate ทำนาย action ตลอด timeline ถูกต้อง และแบ่งช่วงของ action ได้ดีหรือไม่

Metrics

Frame-wise Accuracy
เปรียบเทียบว่าแต่ละเฟรมทำนาย action ถูกต้องหรือไม่

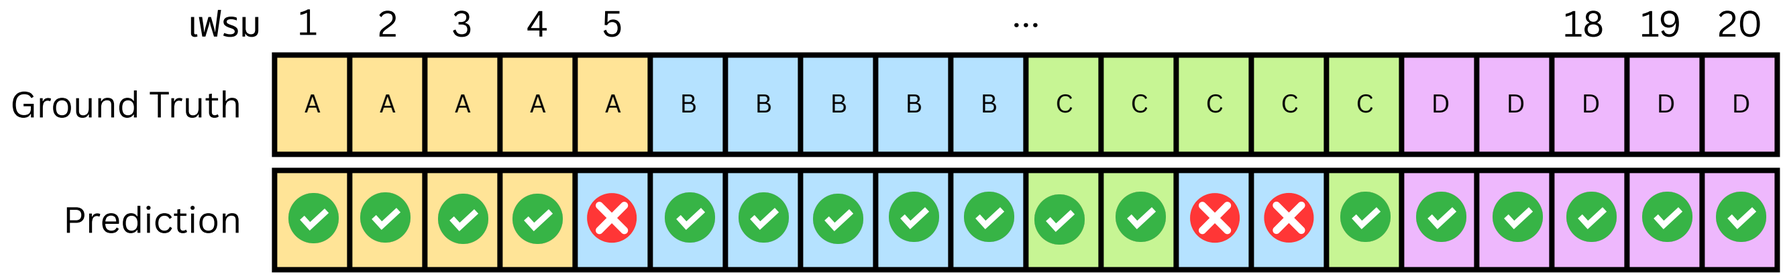

Frame-wise Accuracy = $\frac{\text{จำนวนเฟรมที่ทายถูก}}{\text{จำนวนเฟรมทั้งหมด}}$

$$Frame-wise Accuracy = \frac{17}{20} = 0.85 = 85\%$$

มักมีช่วงค่าอยู่ในช่วง 0-1

ค่าสูง: ทายถูกรายเฟรมโดยรวมมาก

ค่าต่ำ: ทายผิดรายเฟรมโดยรวมมาก

Evaluation Metrics สำหรับ Temporal Action Segmentation

Evaluate ทำนาย action ตลอด timeline ถูกต้อง และแบ่งช่วงของ action ได้ดีหรือไม่

Metrics

Edit score
วัดความถูกต้องของ ลำดับ action และช่วยสะท้อนปัญหาการแบ่ง action ย่อยมากเกินไป

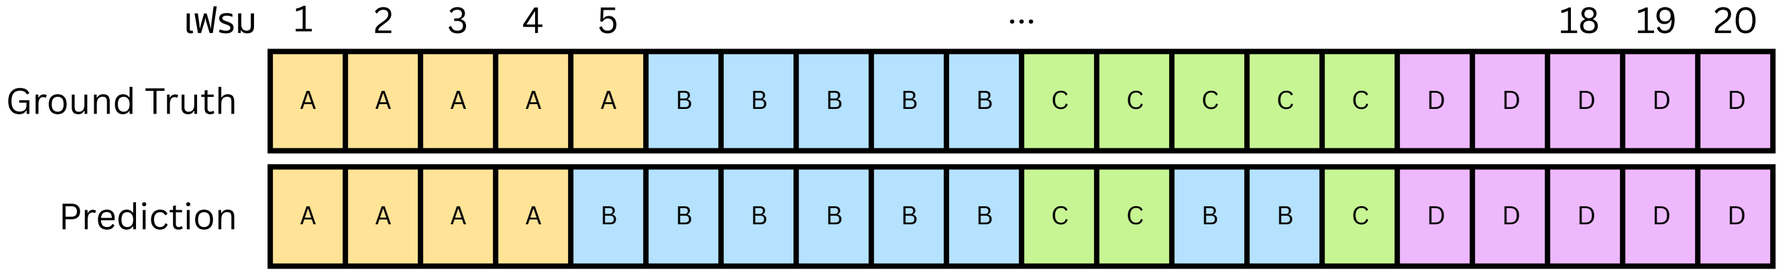

❶ ยุบรวม label ที่ซ้ำติดกันให้เหลือเป็น หนึ่ง action segment เพื่อให้เหลือเฉพาะลำดับของ action

Ground Truth	A → B → C → D
Prediction	A → B → C → B → C → D

Prediction มี action เกินเข้ามา ทำให้เกิด over-segmentation

Evaluation Metrics สำหรับ Temporal Action Segmentation

Evaluate ทำนาย action ตลอด timeline ถูกต้อง และแบ่งช่วงของ action ได้ดีหรือไม่

Metrics

Edit score
วัดความถูกต้องของ ลำดับ action และช่วยสะท้อนปัญหาการแบ่ง action ย่อยมากเกินไป

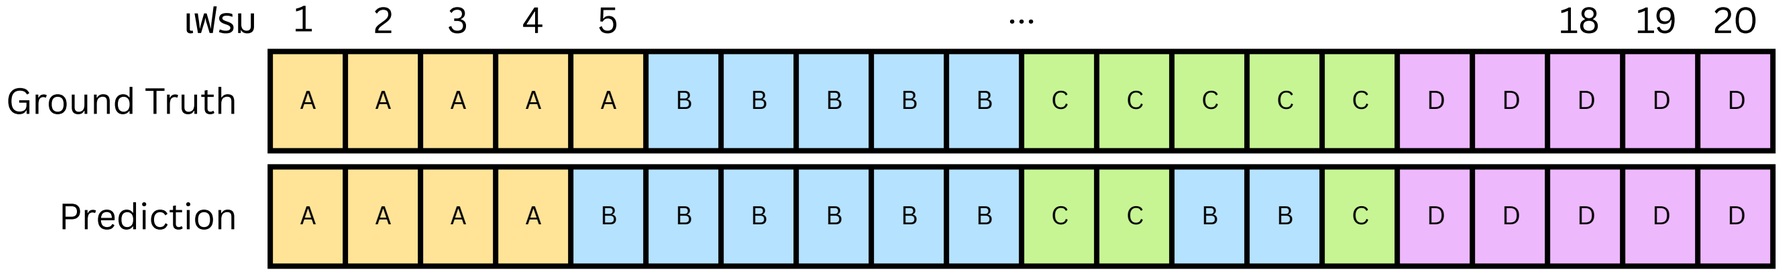

❷ คำนวณ Levenshtein distance - คำนวณจำนวนการแก้ไขขั้นต่ำที่ใช้เปลี่ยนลำดับ Prediction ให้เป็น Ground Truth โดยแบ่งเป็นการนับ 3 แบบ:

- Insertion = เพิ่ม action
- Deletion = ลบ action
- Substitution = เปลี่ยน action หนึ่งเป็นอีก action หนึ่ง

Ground Truth	A → B → C → D
Prediction	A → B → C → B → C → D

ลบ **2** action segments นี้ออก

Evaluation Metrics สำหรับ Temporal Action Segmentation

Evaluate ทำนาย action ตลอด timeline ถูกต้อง และแบ่งช่วงของ action ได้ดีหรือไม่

Metrics

Edit score
วัดความถูกต้องของ ลำดับ action และช่วยสะท้อนปัญหาการแบ่ง action ย่อยมากเกินไป

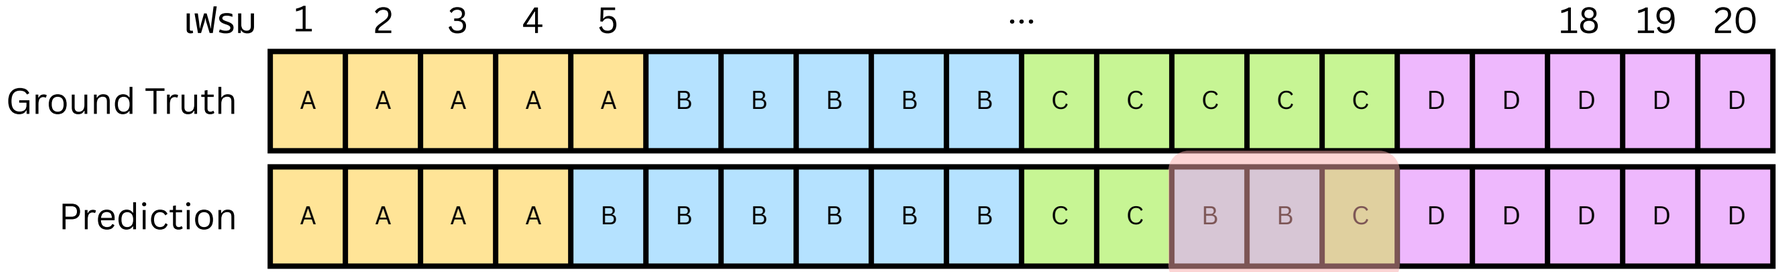

❸ นำ Levenshtein distance ไปปรับให้อยู่ในรูปคะแนนความเหมือน โดยหารด้วยความยาวของลำดับที่ยาวกว่า

$$Edit = \left(1 - \frac{D\left(P, G\right)}{max\left(N_{pred}, N_{gt}\right)}\right)$$

โดยที่ : D(P, G) คือ Levenshtein distance ระหว่าง predicted action sequence กับ ground-truth sequence
Npred คือ จำนวน action segments ของ Prediction หลังยุบรวม label
Ngt คือ จำนวน action segments ของ Ground Truth หลังยุบรวม label

Evaluation Metrics สำหรับ Temporal Action Segmentation

Evaluate ทำนาย action ตลอด timeline ถูกต้อง และแบ่งช่วงของ action ได้ดีหรือไม่

Metrics

Edit score
วัดความถูกต้องของ ลำดับ action และช่วยสะท้อนปัญหาการแบ่ง action ย่อยมากเกินไป

❸ นำ Levenshtein distance ไปปรับให้อยู่ในรูปคะแนนความเหมือน โดยหารด้วยความยาวของลำดับที่ยาวกว่า

$$Edit = \left(1 - \frac{D\left(P, G\right)}{max\left(N_{pred}, N_{gt}\right)}\right) \qquad Edit = \left(1 - \frac{2}{max\left(6, 4\right)}\right) = \left(1 - \frac{2}{6}\right) = 0.6667 = 66.67\%$$

มักมีช่วงค่าอยู่ในช่วง 0-1
ค่าสูง: ลำดับขั้นตอนใกล้เคียงกับเฉลยและมีการแตก segment เกินน้อย
ค่าต่ำ: action หาย เกิน สลับลำดับ หรือแตกเป็น segment จำนวนมาก

Evaluation Metrics สำหรับ Temporal Action Segmentation

Evaluate ทำนาย action ตลอด timeline ถูกต้อง และแบ่งช่วงของ action ได้ดีหรือไม่

Metrics

Segmental F1@k
วัดว่าแต่ละช่วง action ที่ทำนาย ซ้อนทับกับ Ground Truth มากพอหรือไม่ โดยกำหนด IoU threshold (k) เช่น 10%, 25% หรือ 50%

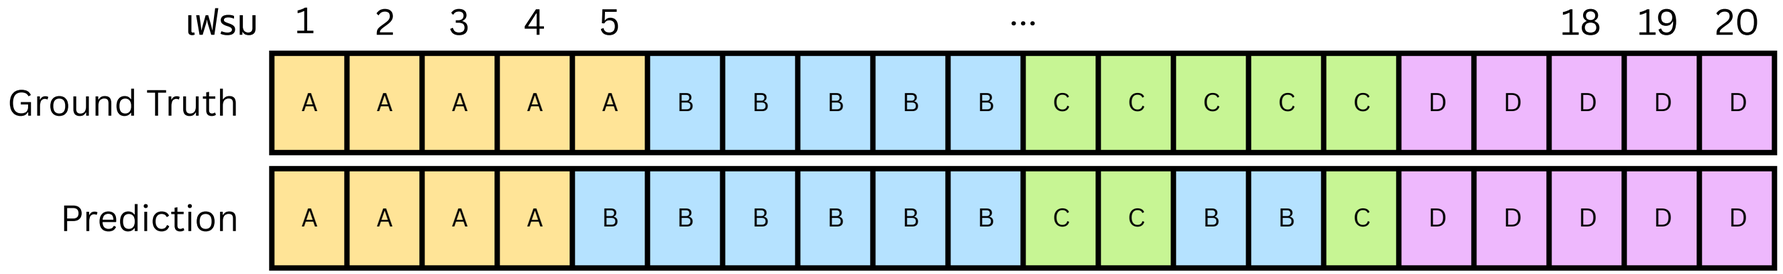

❶ กำหนด segments

GT Segments

Segments	Frames
A	1-5
B	6-10
C	11-15
D	16-20

Pred Segments

Segments	Frames
A	1-4
B	5-10
C	11-12
B	13-14
C	15
D	16-20

Evaluation Metrics สำหรับ Temporal Action Segmentation

Evaluate ทำนาย action ตลอด timeline ถูกต้อง และแบ่งช่วงของ action ได้ดีหรือไม่

Metrics

Segmental F1@k
วัดว่าแต่ละช่วง action ที่ทำนาย ซ้อนทับกับ Ground Truth มากพอหรือไม่ โดยกำหนด IoU threshold (k) เช่น 10%, 25% หรือ 50%

❷ คำนวณ IoU ระหว่าง GT Segments และ Pred Segments

Pred Segments	Frames	IoU กับ GT A (1-5)	IoU กับ GT B (6-10)	IoU กับ GT C (11-15)	IoU กับ GT D (16-20)
A	1-4	4/5 = 0.80	0	0	0
B	5-10	0	5/6 = 0.83	0	0
C	11-12	0	0	2/5 = 0.40	0
B	13-14	0	0	0	0
C	15	0	0	1/5 = 0.20	0
D	16-20	0	0	0	5/5 = 1.00

$$IoU = \frac{Intersection}{Union}$$

Evaluation Metrics สำหรับ Temporal Action Segmentation

Evaluate ทำนาย action ตลอด timeline ถูกต้อง และแบ่งช่วงของ action ได้ดีหรือไม่

Metrics

Segmental F1@k
วัดว่าแต่ละช่วง action ที่ทำนาย ซ้อนทับกับ Ground Truth มากพอหรือไม่ โดยกำหนด IoU threshold (k) เช่น 10%, 25% หรือ 50%

❸ จับคู่ Segments เพื่อพิจารณาค่า IoU ตาม Threshold (k) ต่าง ๆ ได้แก่ 10%, 25%, 50%

Threshold = 10% = 0.10

Pred Segments	GT Segments	IoU	≥ 0.10 ?	ผลลัพธ์
A (1-4)	A (1-5)	0.80	✓	TP
B (5-10)	B (6-10)	0.83	✓	TP
C (11-12)	C (11-15)	0.40	✓	TP
B (13-14)	-	0	✗	FP
C (15)	C (11-15)*	0.20	✓	FP (GT C ถูกจับคู่แล้ว)
D (16-20)	D (16-20)	1.00	✓	TP

Threshold = 25% = 0.25

Pred Segments	GT Segments	IoU	≥ 0.25 ?	ผลลัพธ์
A (1-4)	A (1-5)	0.80	✓	TP
B (5-10)	B (6-10)	0.83	✓	TP
C (11-12)	C (11-15)	0.40	✓	TP
B (13-14)	-	0	✗	FP
C (15)	C (11-15)*	0.20	✗	FP (ต่ำกว่า 25%)
D (16-20)	D (16-20)	1.00	✓	TP

Threshold = 50% = 0.50

Pred Segments	GT Segments	IoU	≥ 0.50 ?	ผลลัพธ์
A (1-4)	A (1-5)	0.80	✓	TP
B (5-10)	B (6-10)	0.83	✓	TP
C (11-12)	C (11-15)	0.40	✗	FP (ต่ำกว่า 50%)
B (13-14)	-	0	✗	FP
C (15)	C (11-15)*	0.20	✗	FP (ต่ำกว่า 50%)
D (16-20)	D (16-20)	1.00	✓	TP

*หมายเหตุ: GT 1 segment ถูกนับเป็น TP ได้เพียงครั้งเดียว เพื่อช่วยลงโทษ over-segmentation

Evaluation Metrics สำหรับ Temporal Action Segmentation

Evaluate ทำนาย action ตลอด timeline ถูกต้อง และแบ่งช่วงของ action ได้ดีหรือไม่

Metrics

Segmental F1@k
วัดว่าแต่ละช่วง action ที่ทำนาย ซ้อนทับกับ Ground Truth มากพอหรือไม่ โดยกำหนด IoU threshold (k) เช่น 10%, 25% หรือ 50%

❸ จับคู่ Segments เพื่อพิจารณาค่า IoU ตาม Threshold (k) ต่าง ๆ ได้แก่ 10%, 25%, 50%

Threshold = 10% = 0.10

Threshold = 25% = 0.25

Threshold = 50% = 0.50

FN = 1
เนื่องจาก GT C ไม่มี Prediction ที่ overlap ถึง 50%

Pred Segments	GT Segments	IoU	≥ 0.50 ?	ผลลัพธ์
A (1-4)	A (1-5)	0.80	✓	TP
B (5-10)	B (6-10)	0.83	✓	TP
C (11-12)	C (11-15)	0.40	✗	FP (ต่ำกว่า 50%)
B (13-14)	-	0	✗	FP
C (15)	C (11-15)*	0.20	✗	FP (ต่ำกว่า 50%)
D (16-20)	D (16-20)	1.00	✓	TP

*หมายเหตุ: GT 1 segment ถูกนับเป็น TP ได้เพียงครั้งเดียว เพื่อช่วยลงโทษ over-segmentation

Evaluation Metrics สำหรับ Temporal Action Segmentation

Evaluate ทำนาย action ตลอด timeline ถูกต้อง และแบ่งช่วงของ action ได้ดีหรือไม่

Metrics

Segmental F1@k
วัดว่าแต่ละช่วง action ที่ทำนาย ซ้อนทับกับ Ground Truth มากพอหรือไม่ โดยกำหนด IoU threshold (k) เช่น 10%, 25% หรือ 50%

❹ คำนวณ Precision, Recall และ F1@10,25,50

Metrics	F1@10 (IoU ≥ 0.10)	F1@25 (IoU ≥ 0.25)	F1@50 (IoU ≥ 0.50)
TP	4	4	3
FP	2	2	3
FN	0	0	1
Precision	0.667	0.667	0.500
Recall	1.000	1.000	0.750
F1-Score	0.800 (80%)	0.800 (80%)	0.600 (60%)

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$F1 - Score = \frac{2 \times Precision \times Recall}{Precision + Recall}$$

Evaluation Metrics สำหรับ Temporal Action Segmentation

Evaluate ทำนาย action ตลอด timeline ถูกต้อง และแบ่งช่วงของ action ได้ดีหรือไม่

Metrics

Segmental F1@k
วัดว่าแต่ละช่วง action ที่ทำนาย ซ้อนทับกับ Ground Truth มากพอหรือไม่ โดยกำหนด IoU threshold (k)
เช่น 10%, 25% หรือ 50%

4. คำนวณ Precision, Recall และ F1@10,25,50

Metrics	F1@10 (IoU ≥ 0.10)	F1@25 (IoU ≥ 0.25)	F1@50 (IoU ≥ 0.50)
TP	4	4	3
FP	2	2	3
FN	0	0	1
Precision	0.667	0.667	0.500
Recall	1.000	1.000	0.750
F1-Score	0.800 (80%)	0.800 (80%)	0.600 (60%)

มักมีช่วงค่าอยู่ในช่วง 0-1

- @10 ผ่อนปรนที่สุด: overlap อย่างน้อย 10%
- @25 ปานกลาง
- @50 เข้มงวดที่สุดในชุดนี้: ขอบเขตต้องซ้อนทับกันอย่างน้อยครึ่งหนึ่ง

ค่าสูง: action ซ้อนทับกันมาก
ค่าต่ำ: action ซ้อนทับกันน้อย

ตัวอย่างงาน Temporal Action Segmentation

วิเคราะห์
ขั้นตอนการผ่าตัด

วิเคราะห์
ขั้นตอนการทำอาหาร

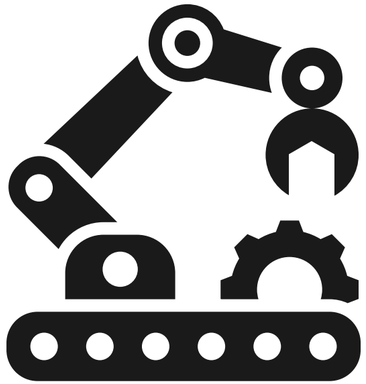

วิเคราะห์
ขั้นตอนการประกอบสินค้าในโรงงาน

3 Temporal Action Localization

Goal	ค้นหาว่า action ที่สนใจเกิดขึ้นเมื่อไร และเกิดขึ้นในช่วงเวลาใด
Input	วิดีโอยาวแบบ untrimmed ที่อาจมีหลายเหตุการณ์และช่วงเวลาที่ไม่สนใจ
Ground Truth	รายการ (class, start_time, end_time) ของแต่ละเหตุการณ์ที่สนใจ เช่น (ยิงประตู, 01.15, 01.20), (ทำฟาวล์, 02.42, 02.48) เป็นต้น
Focus	เฉพาะช่วงเหตุการณ์ที่สนใจ

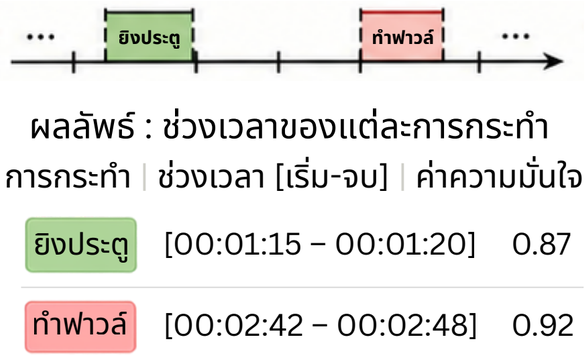

Evaluation Metrics สำหรับ Temporal Action Localization

Evaluate หา ประเภท action และช่วงเวลาเริ่ม–จบ ได้แม่นยำหรือไม่

Metrics **Temporal IoU (tIoU)** - วัดการซ้อนทับกันระหว่างช่วงเวลาที่โมเดลทำนายกับ Ground Truth

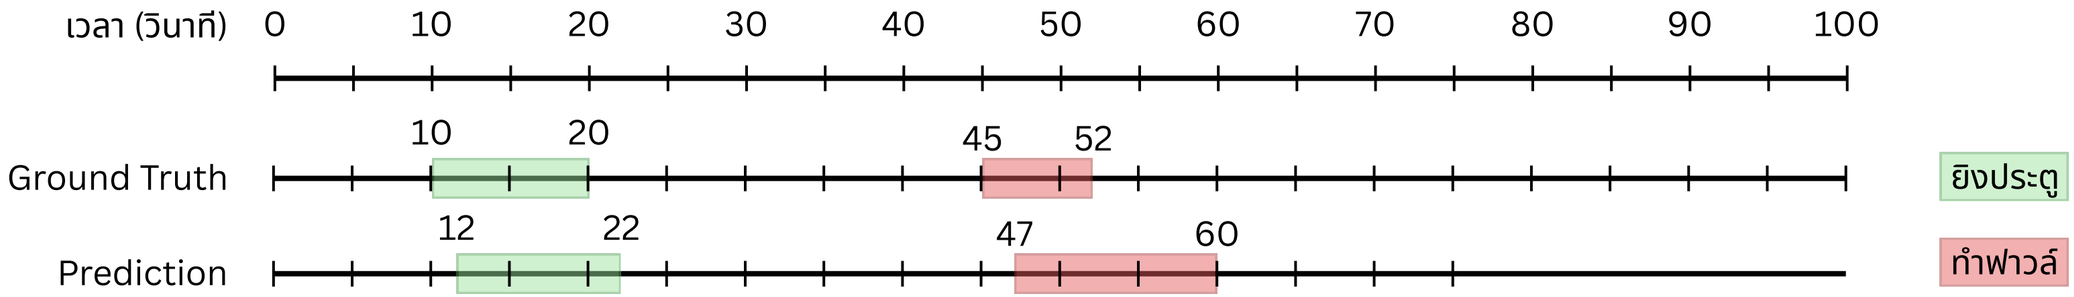

❶ คำนวณ Temporal IoU (tIoU)

$$tIoU = \frac{Intersection}{Union}$$

Prediction ยิงประตู

$$tIoU = \frac{20-12}{22-10} = \frac{8}{12} = 0.667 = 66.7\%$$

Prediction ทำฟาวล์

$$tIoU = \frac{52-47}{60-45} = \frac{5}{15} = 0.333 = 33.3\%$$

มักมีช่วงค่าอยู่ในช่วง 0-1 ค่าสูง: ช่วงเวลาทำนายซ้อนทับกับเฉลยมาก 👍 ค่าต่ำ: ช่วงเวลาทำนายซ้อนทับกับเฉลยน้อย

Evaluation Metrics สำหรับ Temporal Action Localization

Evaluate หา ประเภท action และช่วงเวลาเริ่ม–จบ ได้แม่นยำหรือไม่

Metrics **Temporal IoU (tIoU)** - วัดการซ้อนทับกันระหว่างช่วงเวลาที่โมเดลทำนายกับ Ground Truth

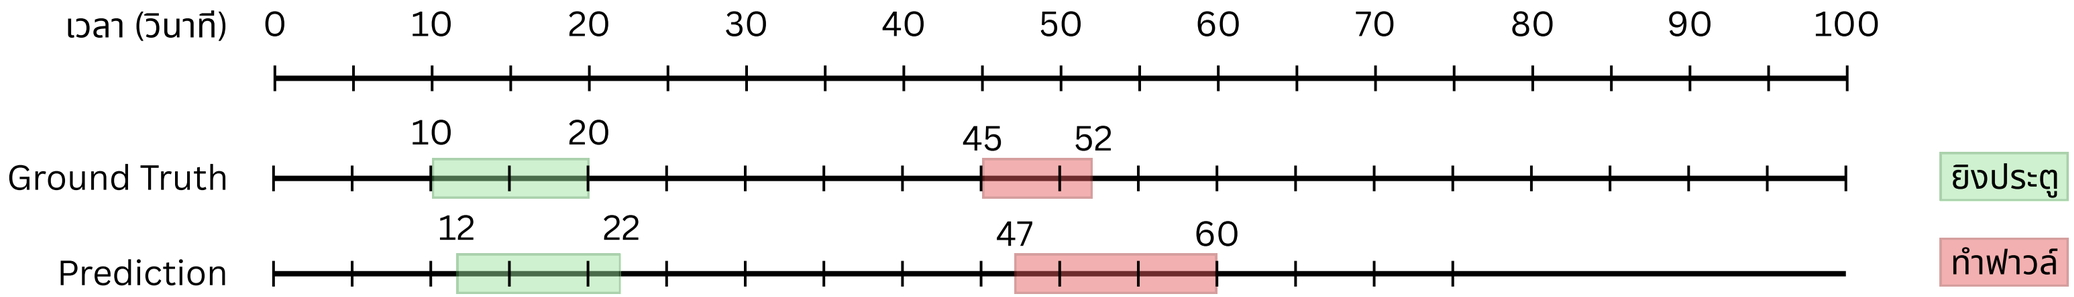

❷ พิจารณาว่าเป็น TP หรือ FP ด้วย tIoU threshold

ถ้าทำนาย Class ถูกต้อง และ tIoU ≥ threshold
จะนับเป็น → True Positive (TP)
ถ้าไม่ผ่าน → False Positive (FP)

tIoU threshold	ตัวอย่าง ยิงประตู (tIoU=0.667)	ตัวอย่าง ทำฟาวล์ (tIoU=0.333)
@0.3	0.667 ≥ 0.3 → TP	0.333 ≥ 0.3 → TP
@0.5	0.667 ≥ 0.5 → TP	0.333 < 0.5 → FP
@0.7	0.667 < 0.7 → FP	0.333 < 0.7 → FP

Evaluation Metrics สำหรับ Temporal Action Localization

Evaluate หา ประเภท action และช่วงเวลาเริ่ม–จบ ได้แม่นยำหรือไม่

Metrics

Average Precision (AP)
- วัดความแม่นยำในการตรวจจับ action ของแต่ละคลาส โดยพิจารณาทั้ง confidence และ tIoU
- AP คือ พื้นที่ใต้กราฟ Precision–Recall Curve

❸ คำนวณ Precision และ Recall (ต่อ 1 class) ที่ threshold เดียวกัน

❹ สร้าง Precision-Recall Curve และคำนวณ AP (ต่อ 1 class ที่ tIoU เดียวกัน)

$$AP = \int_0^1 Precision(Recall)\, dRecall$$

ตัวอย่าง

Class	AP@0.5
ยิงประตู	0.611
ทำฟาวล์	0.146

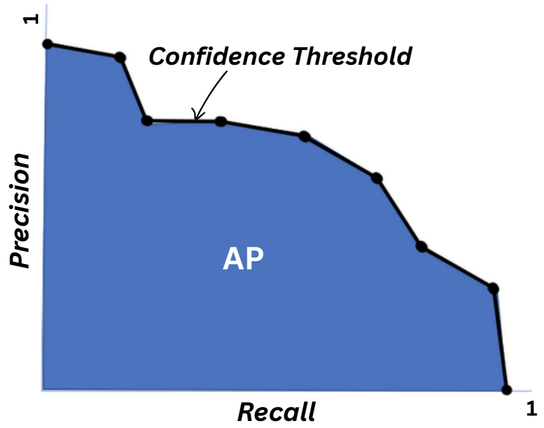

Evaluation Metrics สำหรับ Temporal Action Localization

Evaluate	หา ประเภท action และช่วงเวลาเริ่ม–จบ ได้แม่นยำหรือไม่
Metrics	**Mean Average Precision (mAP)** - ค่าเฉลี่ย AP ของทุกคลาส มักรายงานที่หลายระดับ tIoU เช่น mAP@0.5

5. mAP@tIoU (คำเฉลี่ยของ AP ทุก class)

$$mAP = \frac{\sum AP_i}{N}$$

มักมีช่วงค่าอยู่ในช่วง 0-1
ค่าสูง: ตรวจจับ Action ถูกและช่วงเวลาแม่นยำ 👍
ค่าต่ำ: ตรวจจับผิด/ไม่ครบ หรือช่วงเวลาไม่ตรง Ground Truth

ตัวอย่าง

Class	AP@0.5
ยิงปะตู	0.611
ทำฟาวล์	0.146

$$mAP@0.5 = \frac{0.611 + 0.146}{2}$$
$$= 0.3785 = 37.9\%$$

ตัวอย่างงาน Temporal Action Localization

ค้นหา
ช่วงยิงประตูหรือทำฟาวล์ในฟุตบอล

ค้นหา
ช่วงที่ผู้สูงอายุล้มจากกล้อง CCTV

ค้นหา
ช่วงที่เกิดอุบัติเหตุในวิดีโอจราจร

ประเภทของงานวิดีโอ

1. Video Classification
2. Temporal Action Segmentation
3. Temporal Action Localization
4. **Regression**

Regression

Classification Task

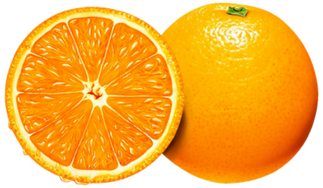

Apples or Oranges?

Cats or Dogs?

What type of building is this?

Regression Task

How expensive is this room?

How old is this man?

What is heart rate for this man?

Difference in Target

Classification Target
Fruit type (Apples, Oranges, etc.)
Animal (Cats, Dogs, etc.)
Building Type (Residential, Industrial, etc.)
Gender
Color

Regression Target
Property Value
Age
Heart rate
Test score
Income

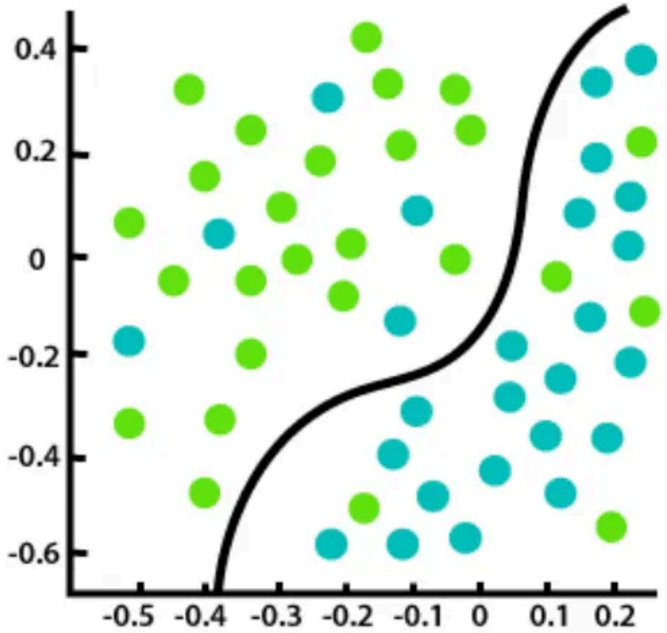

Classification

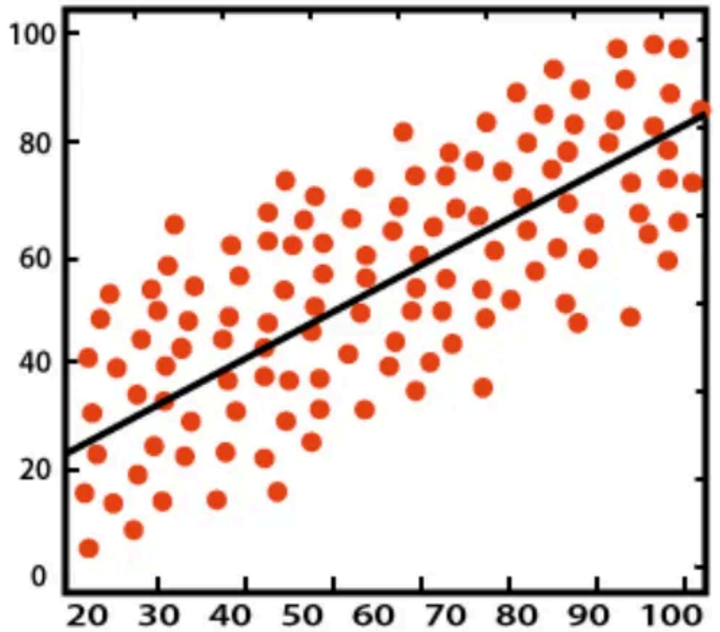

Regression

Regression Task

The California housing dataset

	MedInc	HouseAge	AveRooms	AveBedrms	Population	AveOccup	Latitude	Longitude	MedHouse Val
0	8.3252	41.0	6.984127	1.023810	322.0	2.555556	37.88	-122.23	4.526
1	8.3014	21.0	6.238137	0.971880	2401.0	2.109842	37.86	-122.22	3.585
...									

MedInc HouseAge AveRooms AveBedrms Population AveOccup Lat Long

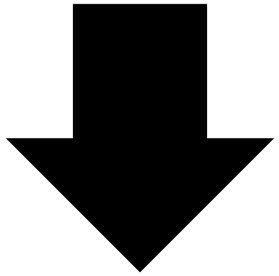

Linear Regression, Lasso Regression (L1 Regularization),
Ridge Regression (L2 Regularization), XGBoost, Neural Network

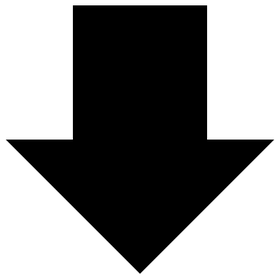

MedHouseVal (in 100k USD)

ตัวชี้วัดสำหรับงาน Regression แบ่งเป็น 2 กลุ่ม

ใช้วัดคนละมุม จึงไม่ควรใช้แทนกัน

1) กลุ่ม Error-Based Metrics

ทำนายผิดจากค่าจริงมากแค่ไหน?

วัดระยะห่างระหว่าง Prediction กับ Ground Truth เป็นหลัก

- **MAE** (Mean Absolute Error)
- **MSE** (Mean Squared Error)
- **RMSE** (Root Mean Square Error)

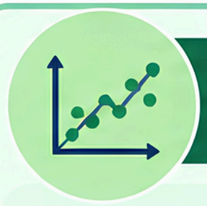

2) กลุ่ม Correlation-Based Metrics

ค่าทำนายเปลี่ยนแปลงสอดคล้องกับค่าจริงหรือไม่?

วัดทิศทางและความแน่นแฟ้นของความสัมพันธ์เชิงเส้น

- **Pearson Correlation (r)**

ตัวชี้วัดสำหรับงาน Regression แบ่งเป็น 2 กลุ่ม

ใช้วัดคนละมุม จึงไม่ควรใช้แทนกัน

1) กลุ่ม Error-Based Metrics

ทำนายผิดจากค่าจริงมากแค่ไหน?

วัดระยะห่างระหว่าง Prediction กับ Ground Truth เป็นหลัก

- **MAE** (Mean Absolute Error)
- **MSE** (Mean Squared Error)
- **RMSE** (Root Mean Square Error)

2) กลุ่ม Correlation-Based Metrics

ค่าทำนายเปลี่ยนแปลงสอดคล้องกับค่าจริงหรือไม่?

วัดทิศทางและความแน่นแฟ้นของความสัมพันธ์เชิงเส้น

- **Pearson Correlation (r)**

Regression Metrics

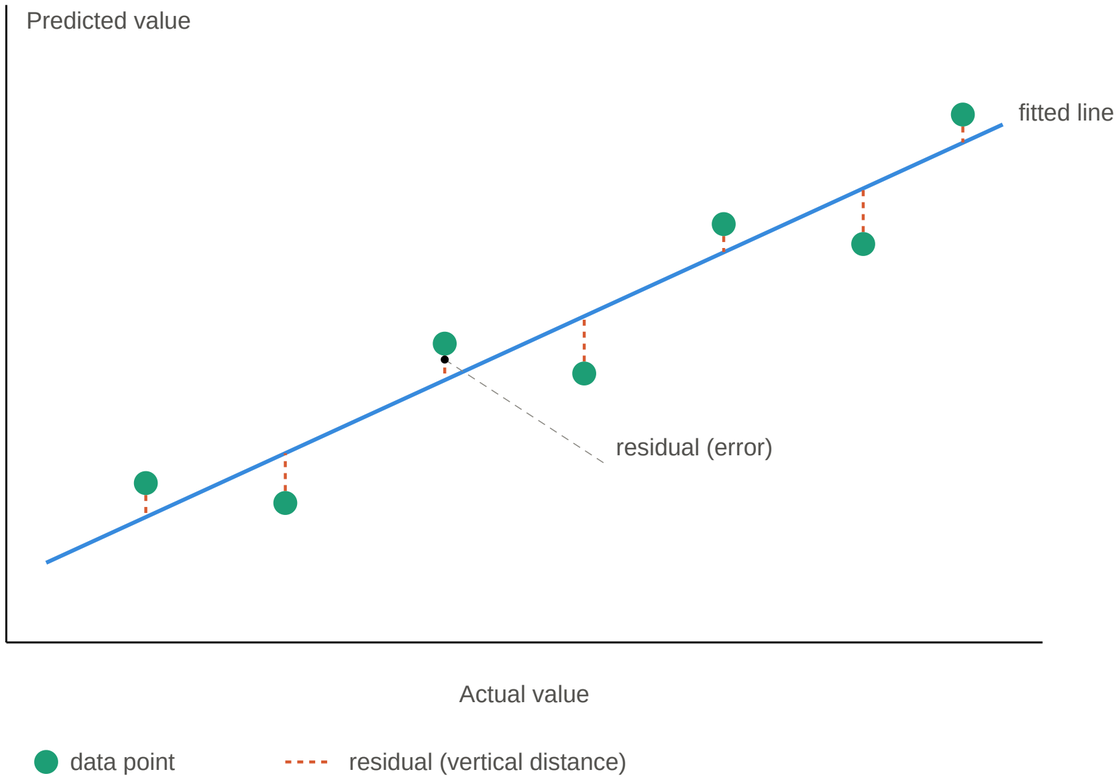

เราสามารถหา Error ได้โดยการนำค่าที่ทำนายได้มาหักลบกับค่าความจริง

$$Actual - Predicted$$

โดยทั่วไปแล้วจะมี Loss Function ที่นิยมใช้ดังต่อไปนี้

- Mean Absolute Error
- Mean Squared Error
- Root Mean Squared Error

Mean Absolute Error

	Prediction A	Prediction B	Prediction C	Prediction D	Prediction E	Prediction F	Prediction G
Actual	50	55	60	65	70	75	80
Predicted	55	47	66	61	77	70	102
Absolute Diff	5	8	6	4	7	5	22

$$\mathrm{MAE} = \frac{1}{n}\sum_{i=1}^{n} |y_i - \hat{y}_i|$$

Mean Squared Error

	Prediction A	Prediction B	Prediction C	Prediction D	Prediction E	Prediction F	Prediction G
Actual	50	55	60	65	70	75	80
Predicted	55	47	66	61	77	70	102
Squared Diff	25	64	36	16	49	25	484

$$\text{MSE} = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

เปรียบเทียบความต่างระหว่าง MAE และ MSE

	Prediction A	Prediction B	Prediction C	Prediction D	Prediction E	Prediction F	Prediction G
Actual	50	55	60	65	70	75	80
Predicted	55	47	66	61	77	70	102
Absolute Diff	5	8	6	4	7	5	22
Squared Diff	25	64	36	16	49	25	484

MAE = 8.14; MSE = 99.86

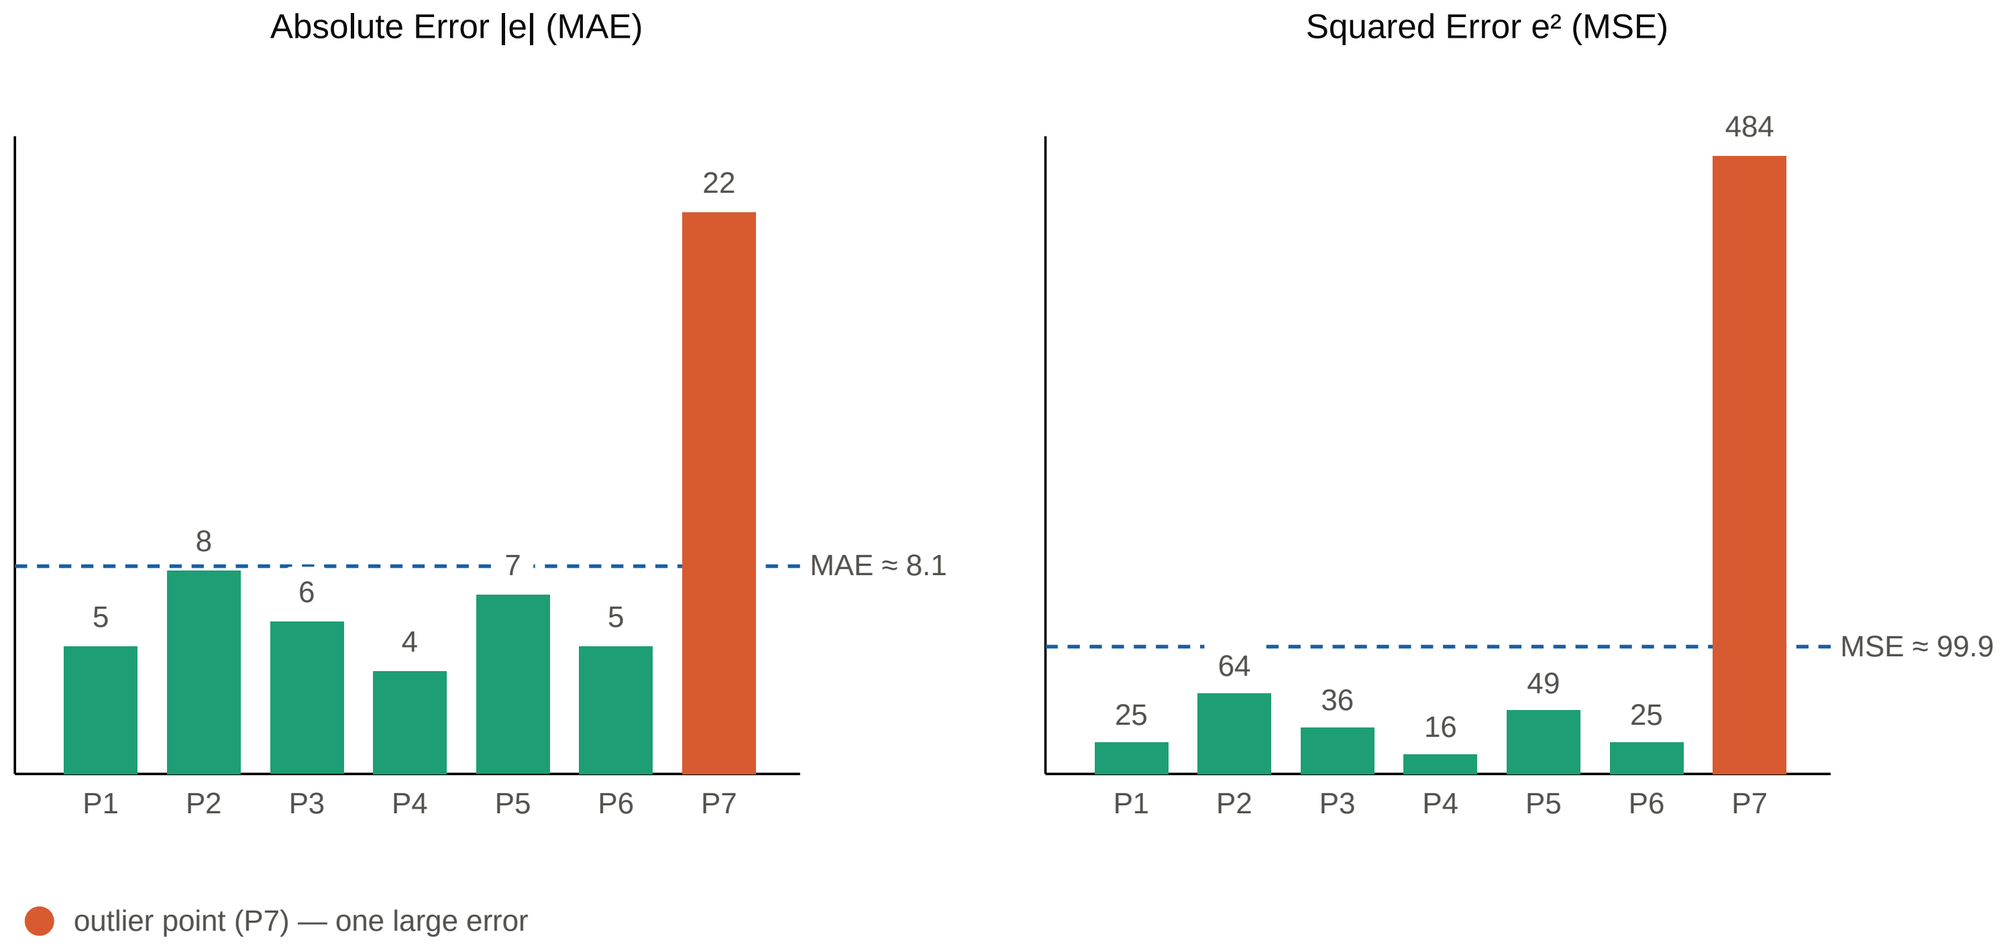
Absolute Error |e| (MAE)
5
8
6
4
7
5
22
MAE ≈ 8.1
P1
P2
P3
P4
P5
P6
P7
Squared Error e² (MSE)
25
64
36
16
49
25
484
MSE ≈ 99.9
P1
P2
P3
P4
P5
P6
P7
outlier point (P7) — one large error

Root Mean Squared Error

	Prediction A	Prediction B	Prediction C	Prediction D	Prediction E	Prediction F	Prediction G
Actual	50	55	60	65	70	75	80
Predicted	55	47	66	61	77	70	102
Squared Diff	25	64	36	16	49	25	484

$$\text{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

MAE = 8.14

MSE = 99.86

RMSE = 9.99

1 ข้อจำกัดของ MAE, MSE และ RMSE

เมื่อความผิดพลาดเฉลี่ยเท่ากัน รูปแบบความผิดพลาดอาจแตกต่างกันมาก

MODEL A ผิดเล็กน้อยทุกภาพ

ขนาดความผิดพลาดสัมบูรณ์ (kg)

MAE	MSE	RMSE
1 kg	1 kg²	1 kg

MODEL B ทำนายถูก 3 ภาพ แต่ผิดมาก 1 ภาพ

ขนาดความผิดพลาดสัมบูรณ์ (kg)

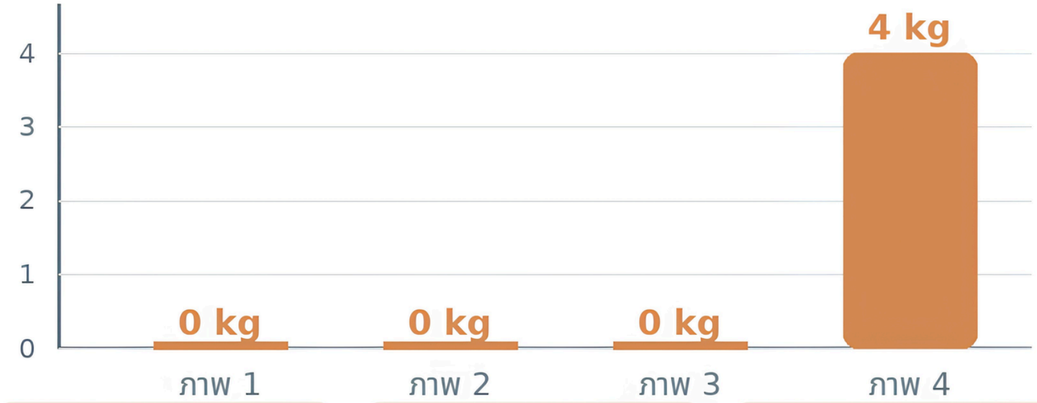

MAE	MSE	RMSE
1 kg	4 kg²	2 kg

ข้อสังเกตสำคัญ

MAE ของทั้งสองโมเดลเท่ากัน (1 kg) แต่ RMSE ของ Model B สูงกว่าเป็น 2 เท่า

เพราะ MSE/RMSE ให้ความสำคัญกับข้อผิดพลาดขนาดใหญ่ ขณะที่ MAE แสดงเพียงขนาดความผิดพลาดเฉลี่ย

MAE vs MSE vs RMSE

เปรียบเทียบ 3 ช่วงค่า Target สำหรับงาน Image Regression

ตัวอย่างข้อมูล 4 ภาพ: ข้อผิดพลาด = [0, 0, 0, e] → MAE = |e|/4, MSE = e²/4, RMSE = |e|/2

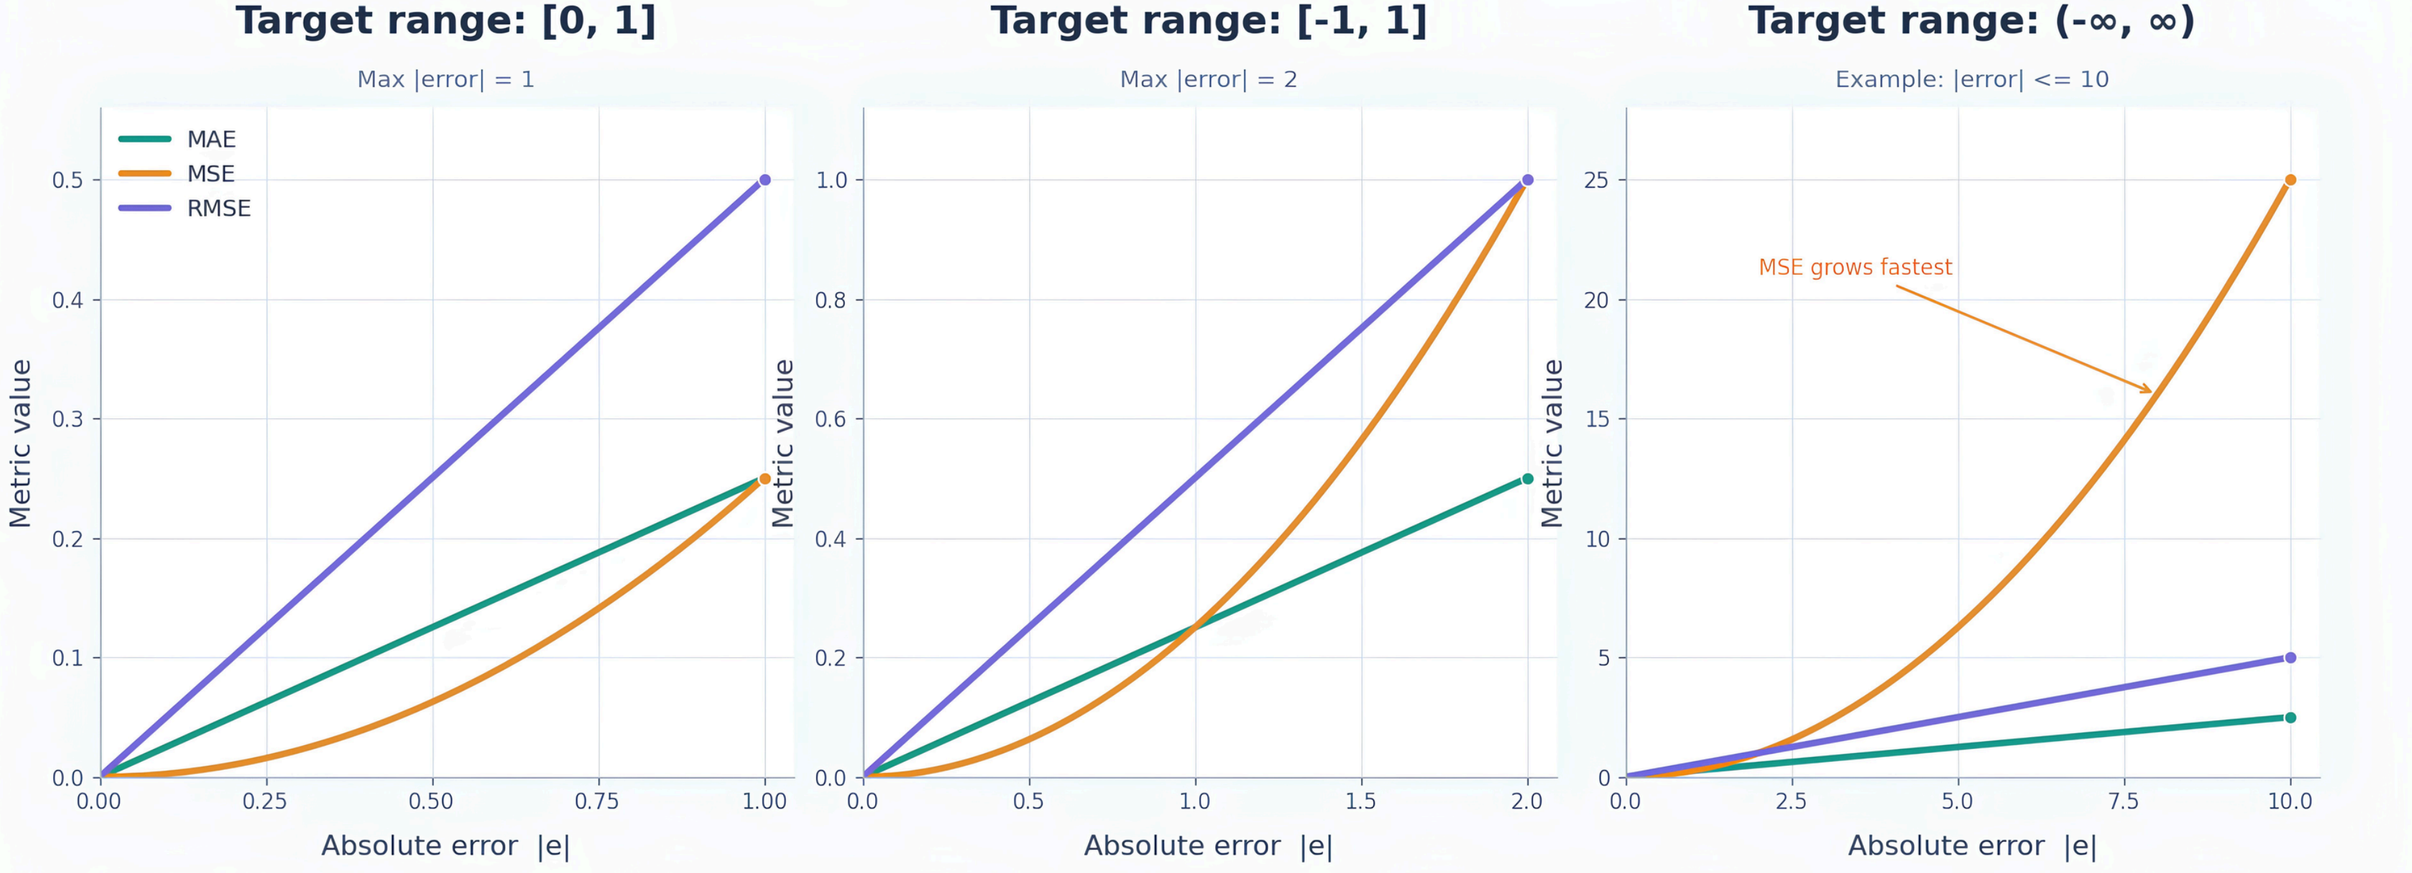

1) ข้อดีและข้อเสียของ MAE, MSE, RMSE

Metric	ข้อดี	ข้อจำกัด	เหมาะเมื่อ
MAE	• เข้าใจง่าย • หน่วยเดียวกับค่าจริง • ทนต่อ outlier ได้ดีกว่า MSE/RMSE	• ไม่เน้นลงโทษความผิดพลาดขนาดใหญ่เป็นพิเศษ	• ต้องการดูความผิดพลาดเฉลี่ยทั่วไป
MSE	• ลงโทษ error ขนาดใหญ่แรง • นิยมใช้เป็น loss	• ไวต่อ outlier มาก • หน่วยเป็นกำลังสอง ตีความยาก	• ต้องการให้โมเดลสนใจกรณีผิดมาก
RMSE	• หน่วยเดียวกับค่าจริง • ยังสะท้อน error ขนาดใหญ่	• ยังไวต่อ outlier และให้ลำดับโมเดลเหมือน MSE	• ใช้รายงานผลให้ตีความง่าย

MSE และ RMSE ไม่ได้แทนกันในแง่การตีความ: MSE เหมาะกับ optimization ส่วน RMSE เหมาะกับการรายงานผล

เมื่อ Error ต่ำกว่า แต่ Correlation กลับต่ำกว่า

Image Regression | MAE & RMSE vs Pearson Correlation (r)

น้ำหนักจริง (Ground Truth) **46, 48, 50, 52, 54 kg** ข้อมูลตัวอย่าง 5 ภาพ

MODEL A

Error ต่ำกว่า | Correlation ต่ำ

Prediction (kg): 50, 51, 50, 51, 50

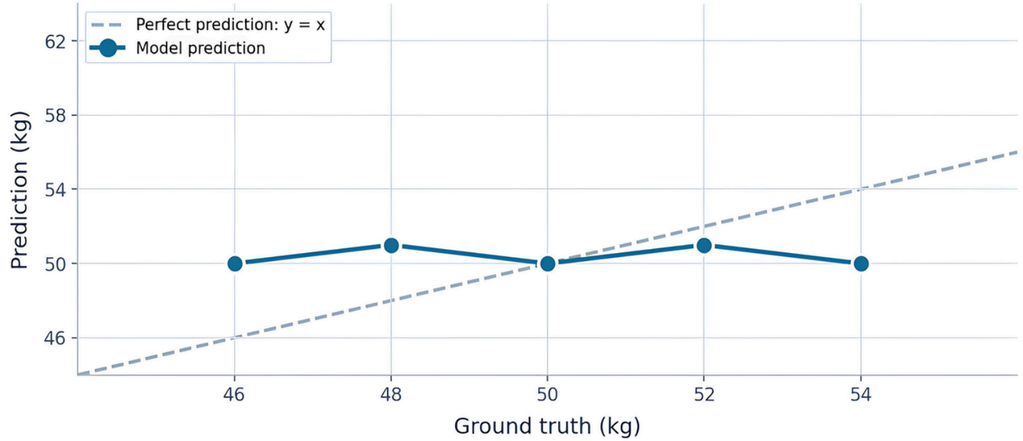

PERFORMANCE METRICS

MAE	RMSE	Pearson r
2.40 kg	2.90 kg	0.00

เกือบทำนายเป็นค่าคงที่ (~50 kg) จึงติดตามแนวโน้มไม่ดี

MODEL B

Error สูงกว่า | Correlation สูง

Prediction (kg): 54, 56, 58, 60, 62

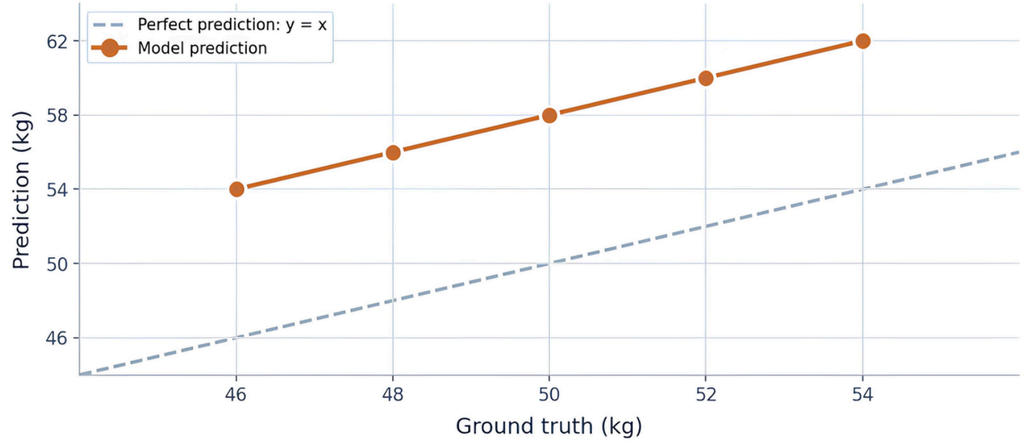

PERFORMANCE METRICS

MAE	RMSE	Pearson r
8.00 kg	8.00 kg	1.00

ทำนายสูงกว่าค่าจริง 8 kg ทุกภาพ แต่แนวโน้มตรงกัน

บทเรียนสำคัญ MAE / RMSE วัดว่า “ผิดไปเท่าไร” Pearson r วัดว่า “สัมพันธ์เชิงเส้นดีเพียงใด”

Pearson r = 1 ไม่ได้แปลว่าทำนายแม่นยำ | ควรรายงาน Error และ Correlation ควบคู่กัน

ตัวชี้วัดสำหรับงาน Regression แบ่งเป็น 2 กลุ่ม

ใช้วัดคนละมุม จึงไม่ควรใช้แทนกัน

1) กลุ่ม Error-Based Metrics

ทำนายผิดจากค่าจริงมากแค่ไหน?

วัดระยะห่างระหว่าง Prediction กับ Ground Truth เป็นหลัก

- **MAE** (Mean Absolute Error)
- **MSE** (Mean Squared Error)
- **RMSE** (Root Mean Square Error)

2) กลุ่ม Correlation-Based Metrics

ค่าทำนายเปลี่ยนแปลงสอดคล้องกับค่าจริงหรือไม่?

วัดทิศทางและความแน่นแฟ้นของความสัมพันธ์เชิงเส้น

- **Pearson Correlation (r)**

Pearson Correlation Coefficient

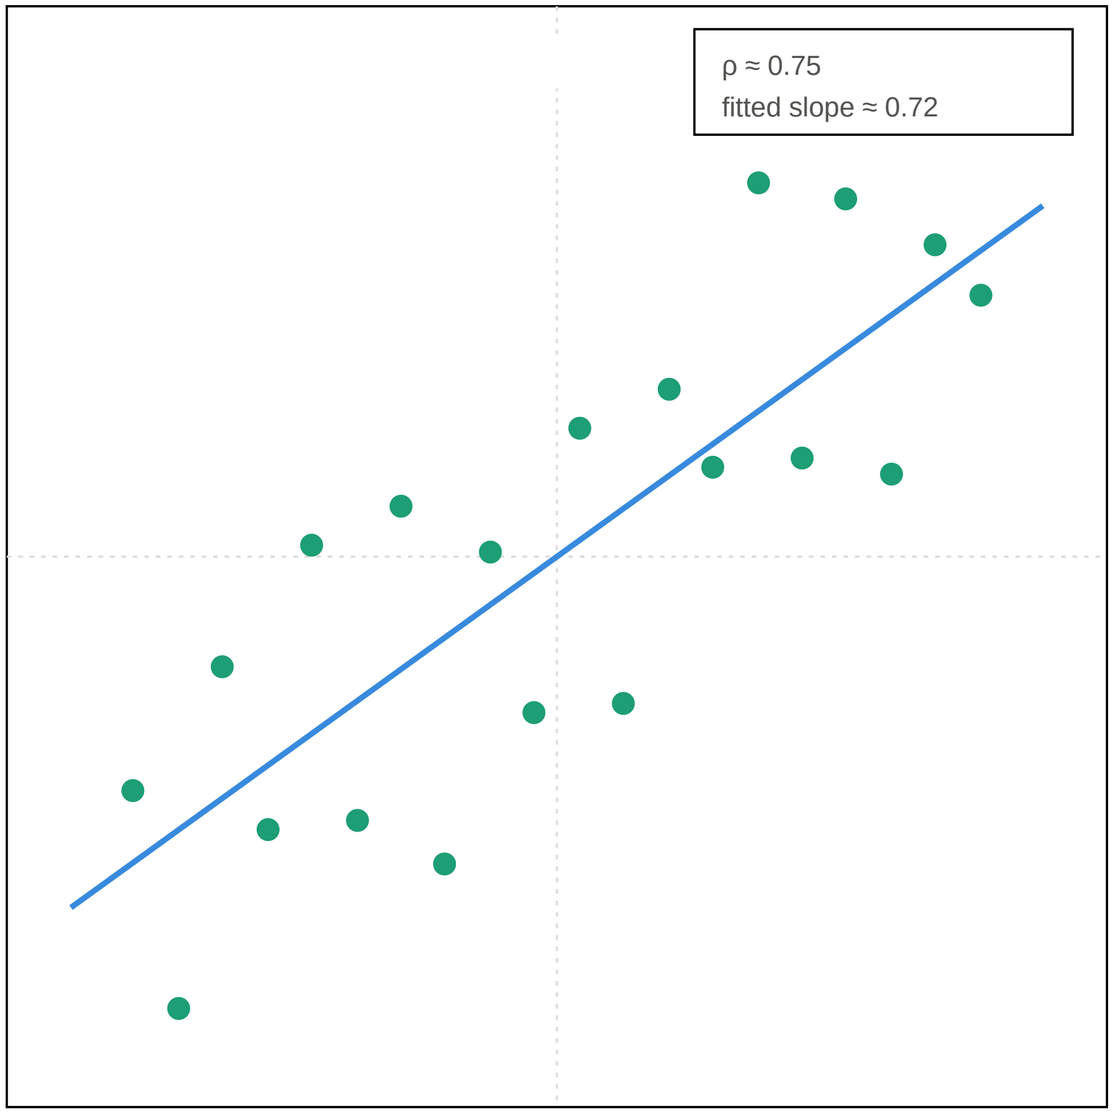

การวัด Performance ของ Regression Model ด้วย Loss Function อย่างเดียวนั้นอาจไม่เพียงพอเนื่องด้วยการวัด Loss นั้นเป็นการวัดประสิทธภาพในเชิงความแม่นยำ แต่อาจไม่ได้บอกถึงความสอดคล้องกันระหว่าค่าทำนายและค่าความจริง

$$\rho = \frac{\sum_{i=1}^{n}(x_i - \hat{x})(y_i - \hat{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \hat{x})^2 \sum_{i=1}^{n}(y_i - \hat{y})^2}}$$

Pearson correlation (r หรือ ρ) คืออะไร?

เป็นค่าที่บอก **“ความสัมพันธ์เชิงเส้นตรง (linear relationship)”** ระหว่างตัวแปรสองตัว
โดยมีค่าอยู่ในช่วง −1 ถึง 1

ρ = −1 (perfect negative)

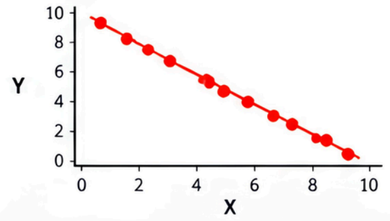

ความสัมพันธ์เชิงเส้นตรงเชิงลบอย่างสมบูรณ์
X เพิ่ม → Y ลด อย่างเป็นเส้นตรง

ρ = −0.5

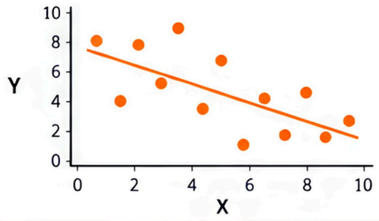

ความสัมพันธ์เชิงลบปานกลาง
X เพิ่ม → Y มีแนวโน้มลดลง
แต่มีความกระจายของข้อมูล

ρ = −0.2 (weak)

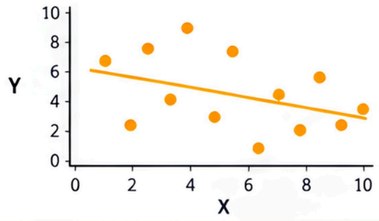

ความสัมพันธ์เชิงลบอ่อน
X เพิ่ม → Y มีแนวโน้มลดลงเล็กน้อย
ข้อมูลกระจายมาก

ρ = 0 (none)

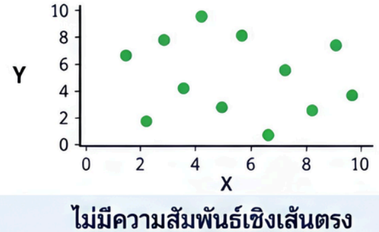

ไม่มีความสัมพันธ์เชิงเส้นตรง
X และ Y ไม่สัมพันธ์กัน
(เป็นการกระจายแบบสุ่ม)

ρ = 0.2 (weak)

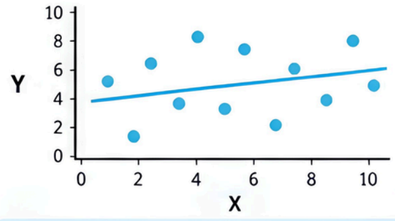

ความสัมพันธ์เชิงบวกอ่อน
X เพิ่ม → Y มีแนวโน้มเพิ่มขึ้นเส้นน้อย
ข้อมูลกระจายมาก

ρ = 0.5

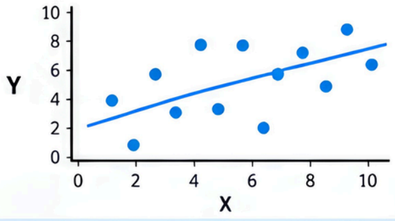

ความสัมพันธ์เชิงบวกปานกลาง
X เพิ่ม → Y มีแนวโน้มเพิ่มขึ้น
แต่มีความกระจายของข้อมูล

ρ = 1 (perfect positive)

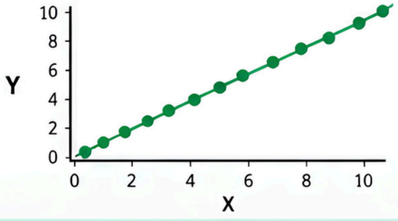

ความสัมพันธ์เชิงเส้นตรงเชิงบวกอย่างสมบูรณ์
X เพิ่ม → Y เพิ่ม อย่างเป็นเส้นตรง

ค่า Pearson correlation (ρ)

- **ค่าอยู่ในช่วง −1 ถึง 1**
- **บอกความสัมพันธ์เชิงเส้นตรง** (linear relationship)
- **ค่าบวก**: X และ Y เปลี่ยนไปในทิศทางเดียวกัน
- **ค่าลบ**: X และ Y เปลี่ยนไปในทิศทางตรงข้ามกัน
- **ค่าเข้าใกล้ 1 หรือ −1**: ความสัมพันธ์แข็งแรงขึ้น
- **ค่าใกล้ 0**: ไม่มีความสัมพันธ์เชิงเส้นตรง

การตีความค่า ρ (โดยทั่วไป)

ช่วงค่า ρ	การตีความ
1.0	ความสัมพันธ์เชิงบวกอย่างสมบูรณ์
0.7 – 0.9	ความสัมพันธ์เชิงบวกสูง
0.3 – 0.6	ความสัมพันธ์เชิงบวกปานกลาง
0.0 – 0.2	ความสัมพันธ์เชิงบวกอ่อน
0	ไม่มีความสัมพันธ์เชิงเส้นตรง
−0.2 – 0.0	ความสัมพันธ์เชิงลบอ่อน
−0.6 – −0.3	ความสัมพันธ์เชิงลบปานกลาง
−0.9 – −0.7	ความสัมพันธ์เชิงลบสูง
−1.0	ความสัมพันธ์เชิงลบอย่างสมบูรณ์

ข้อควรระวัง

- Pearson correlation วัดได้เฉพาะ “ความสัมพันธ์เชิงเส้นตรง”
- ค่า ρ ใกล้ 0 ไม่ได้หมายความว่าไม่มีความสัมพันธ์ อาจมี “ความสัมพันธ์แบบไม่เป็นเส้นตรง” (non-linear) ได้ เช่น รูปตัว U, U คว่ำ หรือแบบอื่น ๆ

2) ทำไมต้องใช้ Pearson Correlation เพิ่ม?

ตัวอย่าง: สองโมเดลที่มีความสัมพันธ์เชิงเส้นเหมือนกัน แต่ความคลาดเคลื่อนต่างกัน

Model A : ใกล้ค่าจริง

ค่าจริง: [10, 20, 30, 40]
ค่าทำนาย: [11, 19, 31, 39]

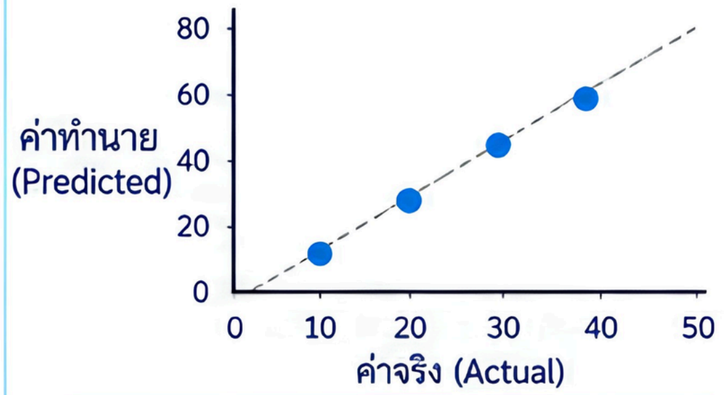

MAE = 1
RMSE = 1
r ≈ 0.997

Model B : สเกลผิด 2 เท่า

ค่าจริง: [10, 20, 30, 40]
ค่าทำนาย: [20, 40, 60, 80] (สเกล 2 เท่า)

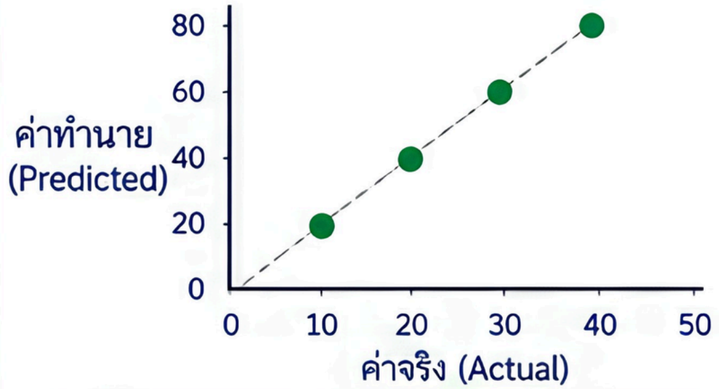

MAE = 25
RMSE = 27.4
r = 1.000

Pearson r สูง ไม่ได้แปลว่าทำนายแม่นเสมอไป
เพราะ r ไม่ตรวจจับ bias หรือ scale error โดยตรง

ตัวชี้วัดสำหรับงาน Regression แบ่งเป็น 2 กลุ่ม

ใช้วัดคนละมุม จึงไม่ควรใช้แทนกัน

1) กลุ่ม Error-Based Metrics

ทำนายผิดจากค่าจริงมากแค่ไหน?

วัดระยะห่างระหว่าง Prediction กับ Ground Truth เป็นหลัก

- **MAE** (Mean Absolute Error)
- **MSE** (Mean Squared Error)
- **RMSE** (Root Mean Square Error)

2) กลุ่ม Correlation-Based Metrics

ค่าทำนายเปลี่ยนแปลงสอดคล้องกับค่าจริงหรือไม่?

วัดทิศทางและความแน่นแฟ้นของความสัมพันธ์เชิงเส้น

- **Pearson Correlation (r)**

Metric	สิ่งที่วัด	ค่าที่ดีที่สุด
MAE	ขนาดความผิดพลาดเฉลี่ย	**0**
MSE	ค่าเฉลี่ยความผิดพลาดกำลังสอง	**0**
RMSE	ขนาดความผิดพลาดแบบ Root Mean Square	**0**
Pearson r	ความสัมพันธ์เชิงเส้นระหว่างค่าจริงกับค่าทำนาย	**+1**

สรุป

MAE, MSE, RMSE ใช้วัด**ความคลาดเคลื่อนของค่าทำนาย** ส่วน **Pearson r** ใช้วัด**ความสัมพันธ์เชิงเส้น**
ดังนั้นตัวชี้วัดทั้ง 2 กลุ่มให้ข้อมูลคนละด้านและควรใช้ร่วมกัน

Retrieval-Augmented Generation

Retrieval-Augmented Generation (RAG)

RAG คือ ระบบที่ค้นข้อมูลจากแหล่งภายนอกมาเป็น context ก่อนให้ LLM สร้างคำตอบ

RAG ทำงานเป็นลำดับแบบนี้

? **Query** คำถามจากผู้ใช้

⌕ **Retrieve** ค้น chunk ที่เกี่ยวข้อง โดยดึงมาเป็นจำนวน Top-K

✓ **Answer** ตอบคำถามจากหลักฐานกำกับ

คำถามสำคัญ: ค้นดีแค่ไหน และตอบเกาะหลักฐานแค่ไหน?

Google search engine

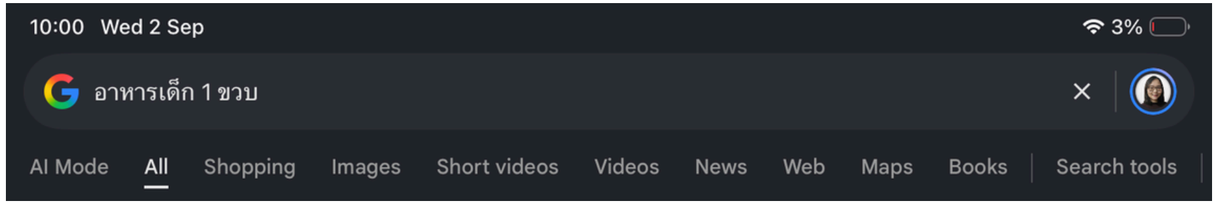

ปกติเราสนใจแค่3-5ผลการค้นหาเท่านั้น ไม่สนใจผลการค้นหาท้ายๆ ในโลก LLM สำหรับการตอบคำถามก็เช่นกัน

Retrieval-Augmented Generation (RAG)

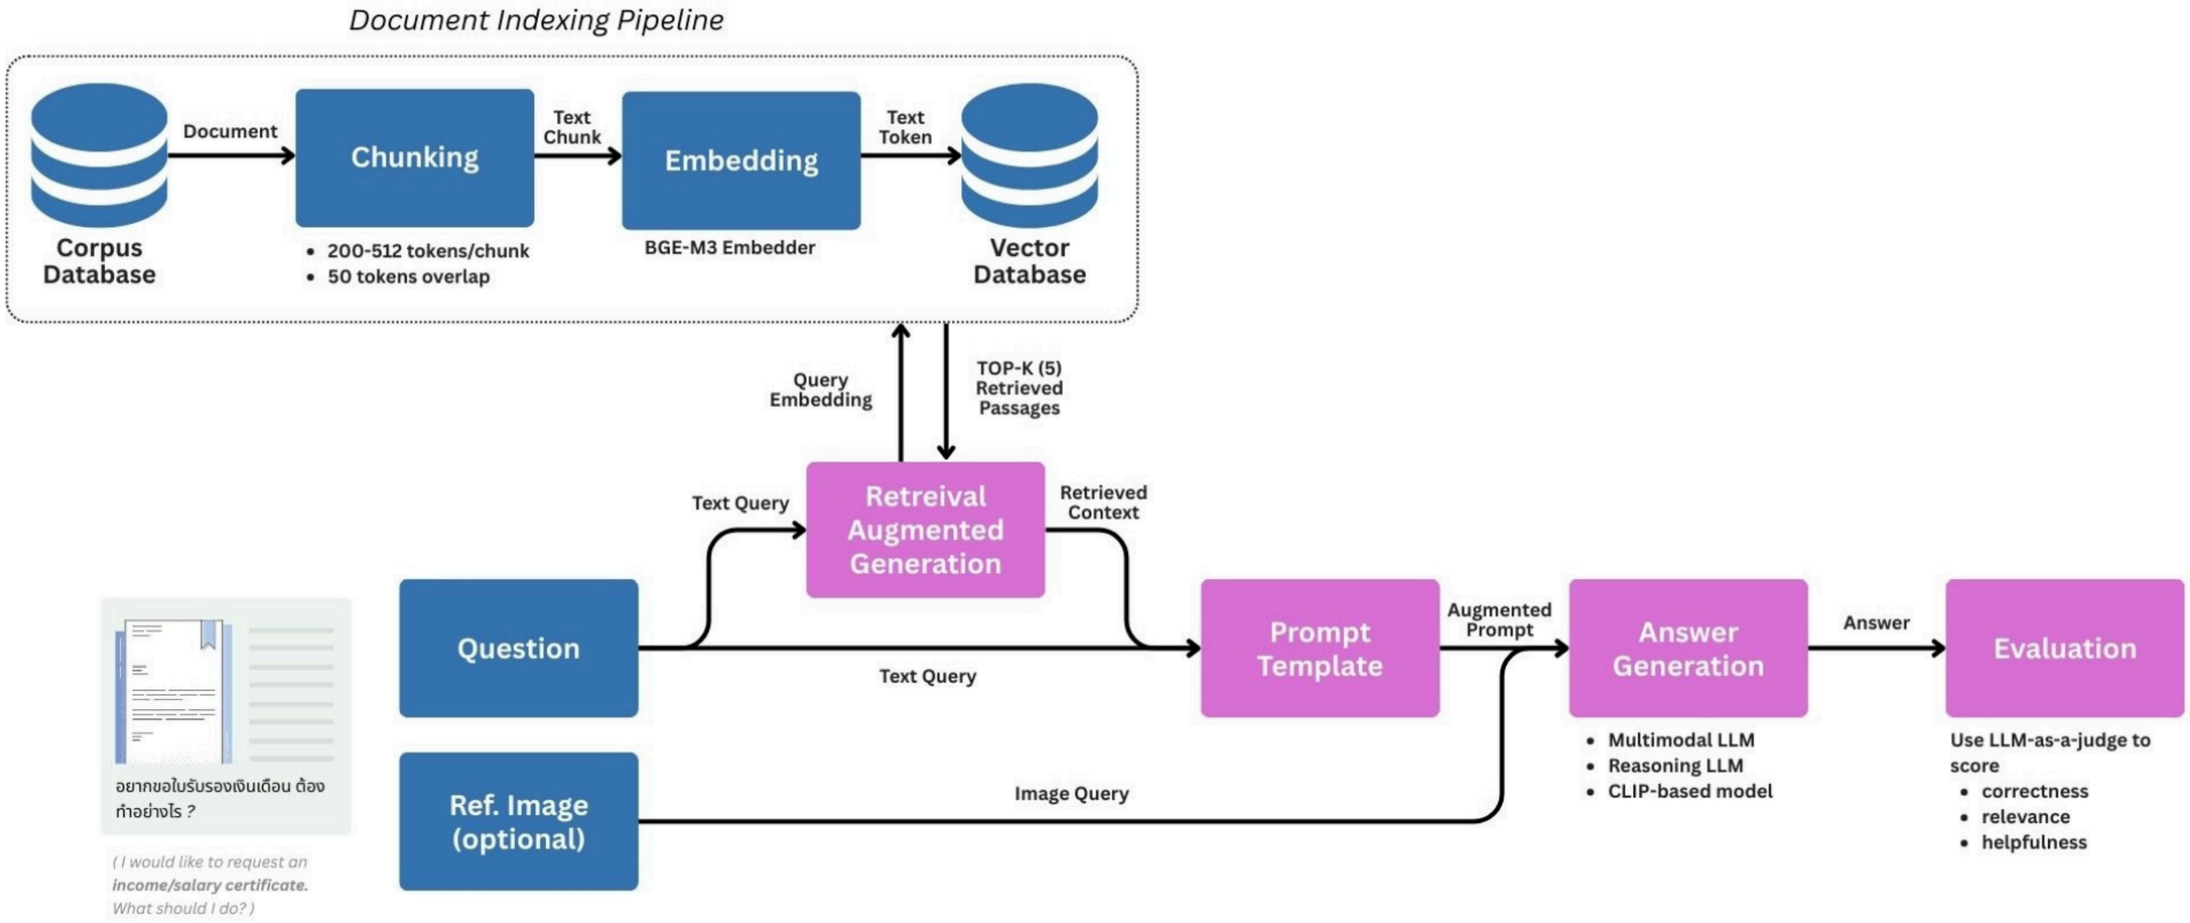

Fig. 1. Overview of the proposed Thai HR-VQA RAG pipeline.

Retrieval-Augmented Generation (RAG)

ประเมิน RAG ให้แยก 2 ช่วง: หา evidence ให้เจอ และใช้ evidence ให้ถูก

1	**Retrieval**	ได้ context ที่เกี่ยวข้องไหม?
2	**Answering**	คำตอบมีหลักฐานรองรับไหม?
!	**Failure**	ผิด / หาย / เติมเกิน

[วิเคราะห์ปัญหาที่เกิดกับระบบ]

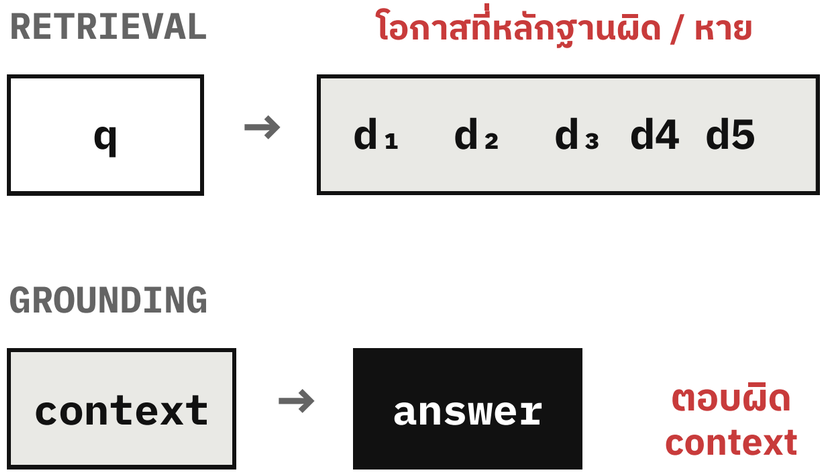

ถ้าวัดแค่ **คำตอบ** เราอาจไม่รู้ว่าระบบมีปัญหาตรงไหน

Retrieval-Augmented Generation (RAG)

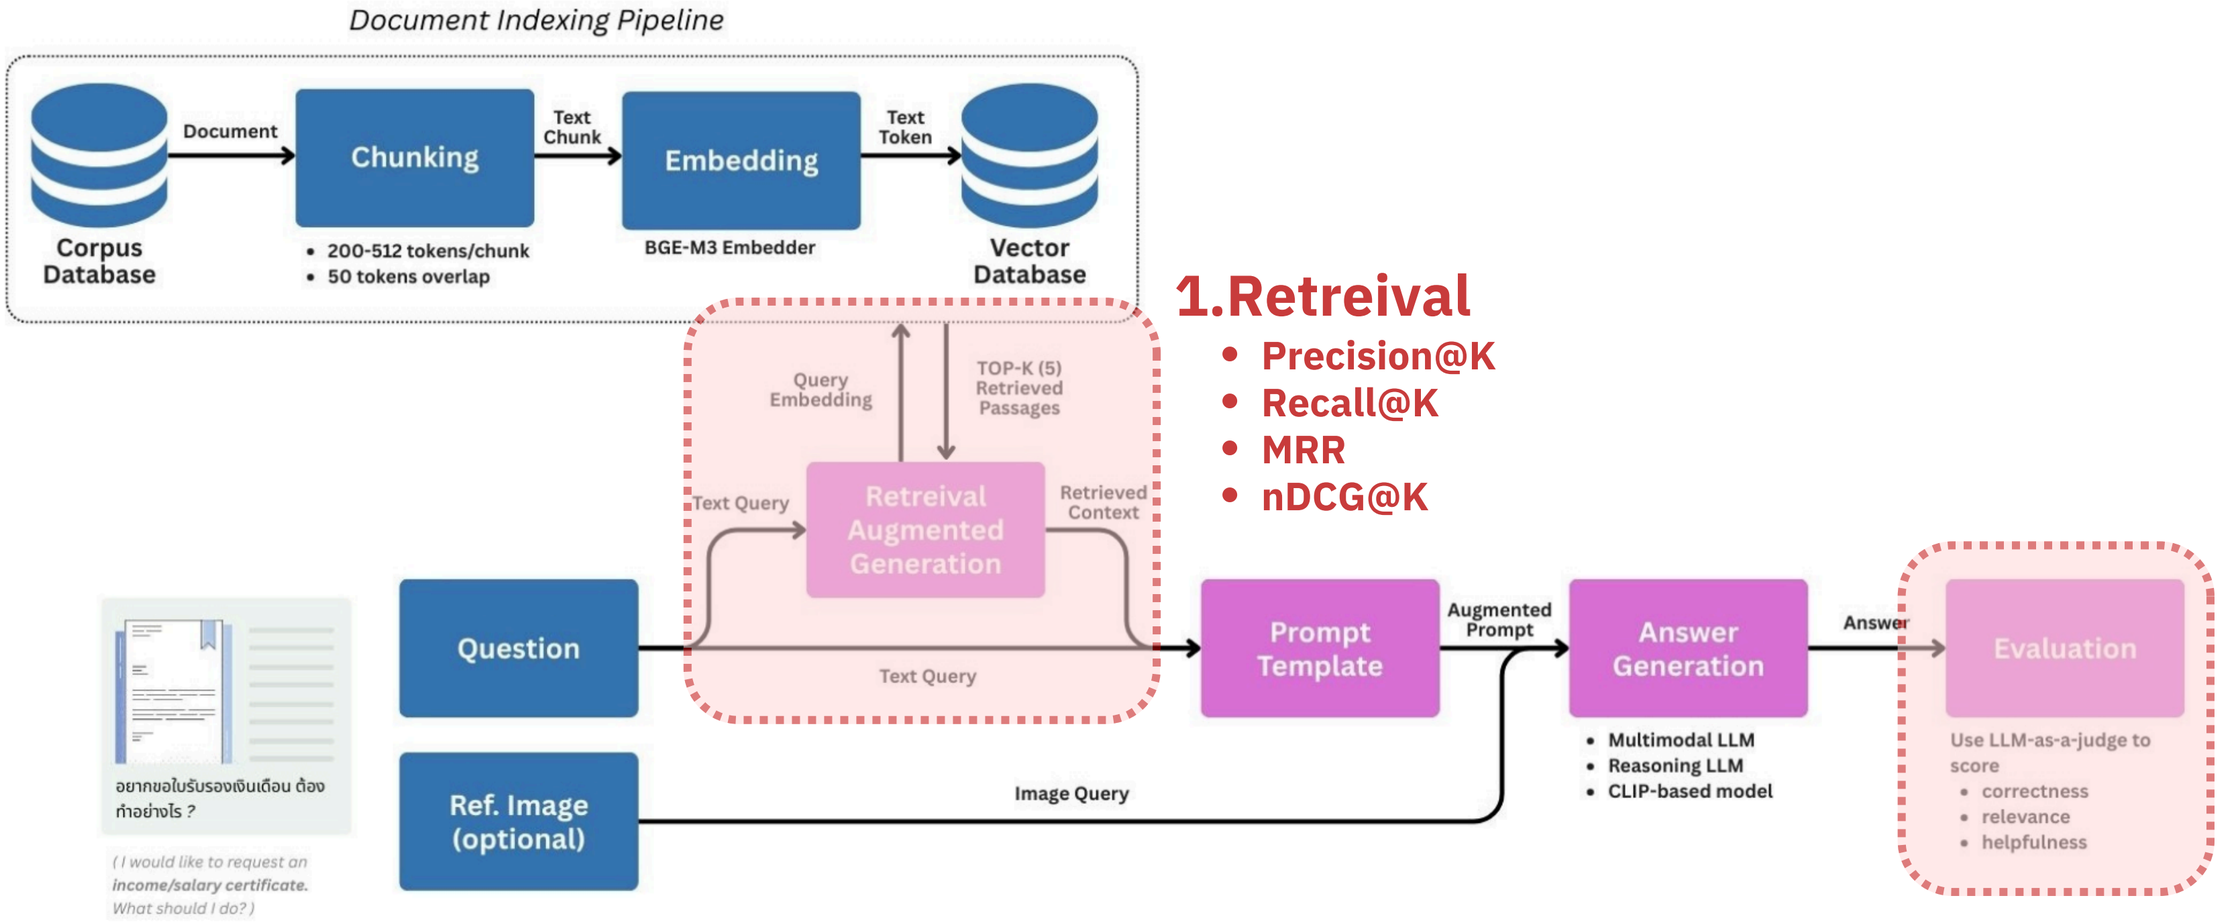

Fig. 1. Overview of the proposed Thai HR-VQA RAG pipeline.

1.Retreival

- Precision@K
- Recall@K
- MRR
- nDCG@K

2.Answering

- LLM as a Judge

Pre-requistic

ก่อนคำนวณ เราจะใช้ query เดียวกัน และเรียกสิ่งต่าง ๆ ด้วยสัญลักษณ์ชุดเดียว

ตัวอย่าง query และ ranked list

q	**Query**	ระบบนี้รองรับผู้ใช้กี่คนต่อ batch?
d_i	**Ranked docs**	$d_1 \dots d_k$ พร้อม rel_i

rel_i = relevance grade
R = relevant docs ทั้งหมด

Recall@K

$$Recall@K(q) = \frac{\text{จำนวนเอกสาร relevant ที่พบ ใน Top-K}}{\text{จำนวนเอกสาร relevant ทั้งหมดของ query}}$$

Query	Top-5 Documents Retrieved	Relevant Documents (Ground Truth)	Relevant Found in Top-5	Recall@5
Q1	D7, D2, **D3**, D10, D4	D3	D3	$1/1 = 1.00$
Q2	D12, **D4**, D8, D1, D9	D4, D5	D4	$1/2 = 0.50$
Q3	D6, D9, D13, D14, D15	D20	ไม่พบ	$0/1 = 0.00$
Q4	**D1**, D8, **D2**, D9, D10	D1, D2, D3	D1, D2	$2/3 \approx 0.67$
Q5	D4, D6, D7, D8, **D5**	D5	D5	$1/1 = 1.00$

$$\text{Mean Recall@5} = \frac{1.00 + 0.50 + 0.00 + 0.67 + 1.00}{5} = 0.634 \approx 0.63$$

Recall@K วัดว่า**จากเอกสารที่เกี่ยวข้องทั้งหมด ระบบสามารถค้นพบภายในผลลัพธ์ Top-K ได้มากเพียงใด** ค่า Recall สูงหมายถึงระบบพลาดเอกสารสำคัญน้อยลง โดย Recall@K จะไม่ลดลงเมื่อเพิ่ม K แต่ผลลัพธ์ที่เพิ่มขึ้นอาจมีเอกสารไม่เกี่ยวข้องมากขึ้น ซึ่งต้องพิจารณาร่วมกับ Precision@K

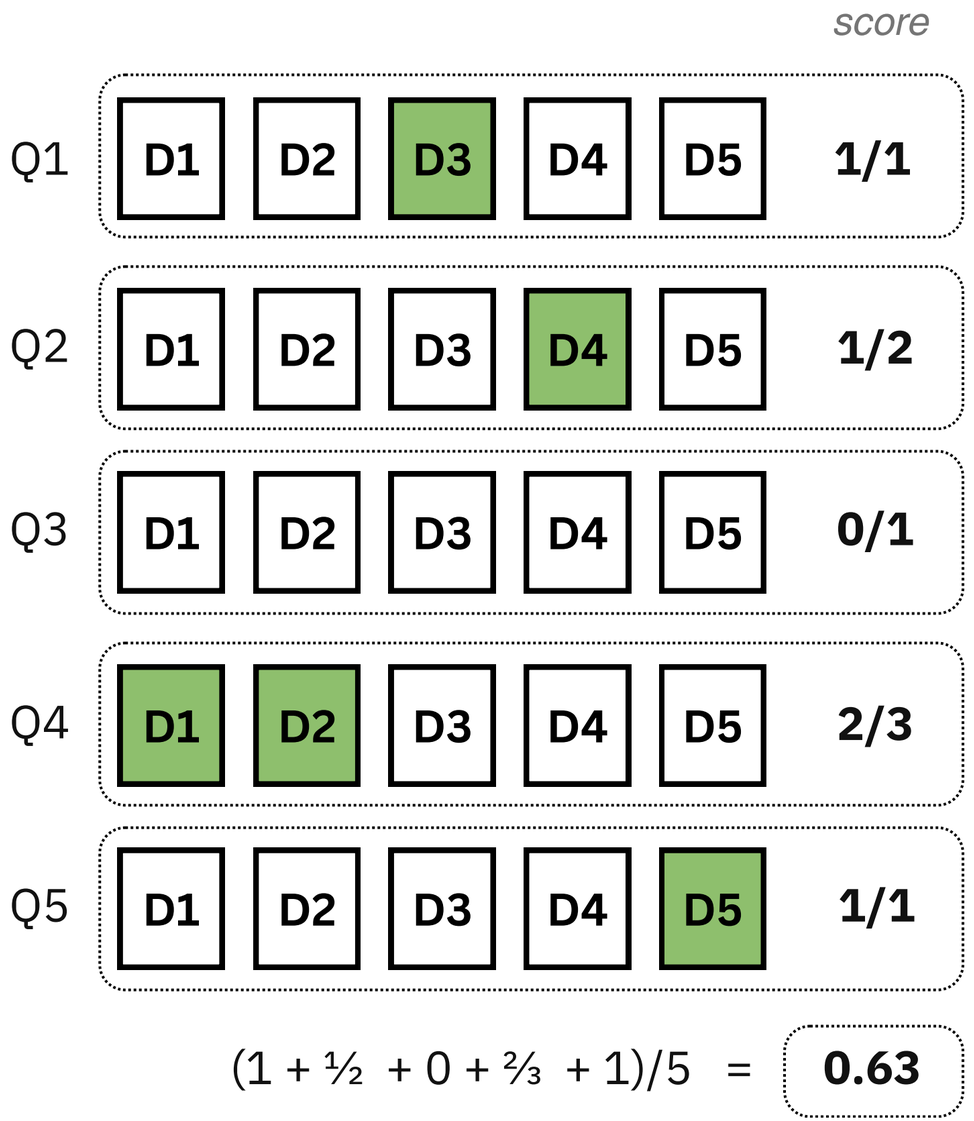

Precision@K

$$\text{Precision@K} = \frac{\text{จำนวนเอกสาร Relevant ที่พบ ใน Top-K}}{K}$$

Query	Top-5 Documents Retrieved	Relevant Documents (Ground Truth)	Relevant Found in Top-5	Precision@5
Q1	D7, D2, **D3**, D10, D4	D3	D3	$1/5 = 0.20$
Q2	D12, **D4**, D8, D1, D9	D4, D5	D4	$1/5 = 0.20$
Q3	D6, D9, D13, D14, D15	D20	ไม่พบ	$0/5 = 0.00$
Q4	**D1**, D8, **D2**, D9, D10	D1, D2, D3	D1, D2	$2/5 = 0.40$
Q5	D4, D6, D7, D8, **D5**	D5	D5	$1/5 = 0.20$

$$\text{Mean Precision@5} = \frac{0.20 + 0.20 + 0.00 + 0.40 + 0.20}{5} = 0.20$$

ในขณะเดียวกัน PrecisionK **จะมองว่าในการค้นหาทั้งหมด มีเอกสารที่เสียเปล่าคิดเป็นกี่เปอร์เซนต์** ดังนั้น การตั้งค่า K มากเกินไปก็จะทำให้คะแนน drop ลงอย่างชัดเจน metric นี้จึงช่วยคุม คุณภาพในการเลือกคำตอบให้ตรงกับเฉลยได้ดี

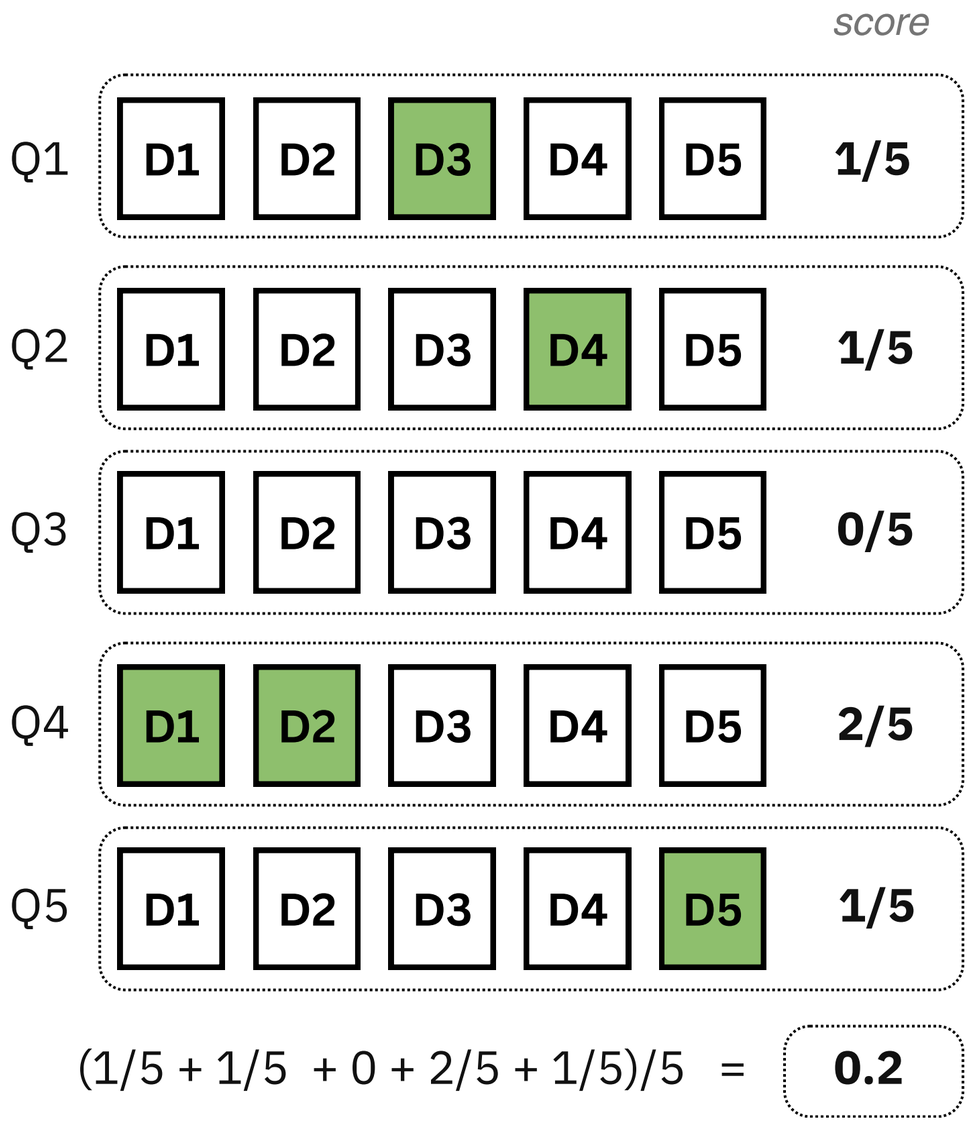

MRR
(mean reciprocal rank)

$$MRR = \frac{1}{|U|}\sum_{u=1}^{|U|}\frac{1}{\text{rank}_u}$$

| U | = จำนวนเอกสาร (queries)
rankU = **ตำแหน่งแรก**ของรายการที่เกี่ยวข้อง

Query	Top-5 Documents Retrieved	Relevant Document(s)	Position of 1st Relevant	Reciprocal Rank
Q1	D7, D2, D3, D10, D4	D3	3	1/3 ≈ 0.333
Q2	D12, D4, D8, D5, D1	D4, D5	2	1/2 = 0.5
Q3	D6, D9, D13, D14, D15	D20	– (not in top-5)	0

$$MRR = \frac{1}{3}(\frac{1}{3}+\frac{1}{2}+0) = \frac{1}{3}\cdot(0.333+0.5+0) = \frac{0.833}{3} \approx 0.278$$

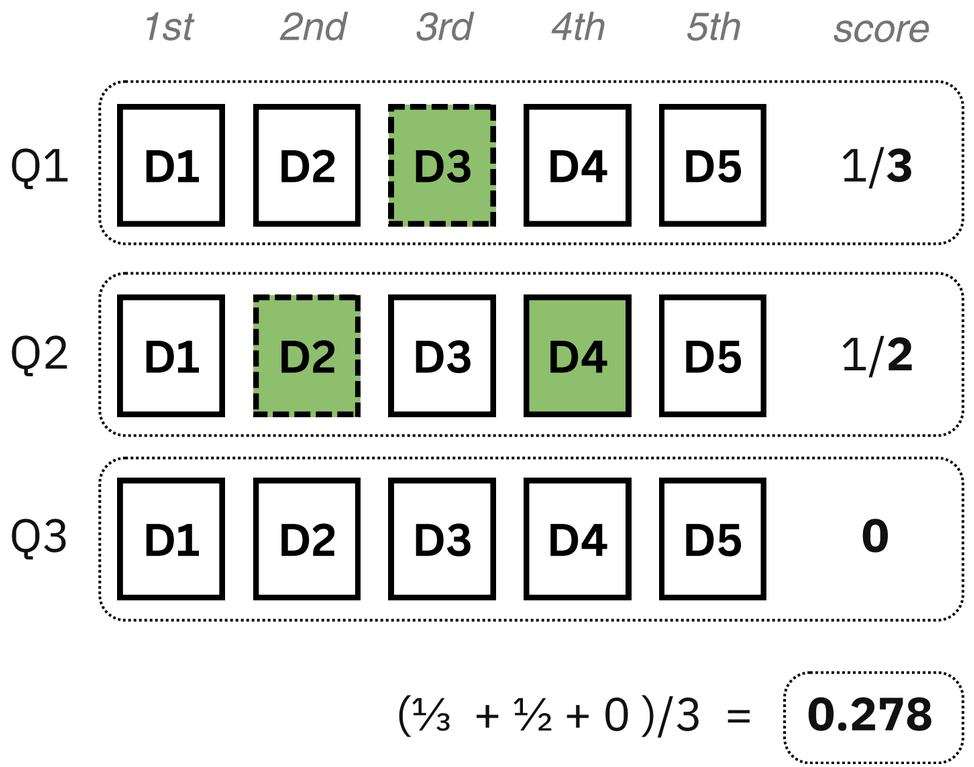

คุณภาพของการค้นหาเอกสารที่ดีคือ เจอ**ข้อมูลได้เร็ว และมีความถูกต้องที่สุด** ดังนั้น MRR จึงไม่เหมาะกับการวัดบริบทของคำตอบทั้งหมดแต่เหมาะมากกับการวัดว่าระบบค้นหาได้ดีเพียงใด

nDCG

(normalized DCG)

Discounted Cumulative Gain

ค่าเฉลี่ยการกระจายของผลการค้นหา

$$\mathrm{DCG@k} = \sum_{i=1}^{k} \frac{2^{\mathrm{rel}_i} - 1}{\log_2(i+1)}$$

currrent dcg
(2 x rel) - 1

ideal dcg
log2(index+1)

(rel) = relevance score ข้อมูลเกี่ยวข้องกับโจทย์ไหม (0-3)
C = สัมประสิทธิ์ของ**ตำแหน่งที่ดึงข้อมูล (ยิ่งมี top-k เยอะตัวหารจะยิ่งมาก)**

อันดับ	rel	2^{rel}−1	$\log_2(i+1)$	ส่วนที่สะสม DCG
1	**3**	7	1.0	7.00
2	0	0	1.58	0
3	**2**	3	2.0	1.50
4	0	0	2.32	0
5	**1**	1	2.58	0.39

$$DCG@5 \approx 7 + 0 + 1.5 + 0 + 0.39 = 8.89$$

iDCG (ideal dcg)

คำนวน dcg ใหม่ ภายใตโอกาสี่จะเกิดคะแนนสูงที่สุด มีการเรียงลำดับ passage ใหม่ตาม rel score ที่ได้มากไปหาน้อย

อันดับ *i*	rel_i	2^{rel_i} − 1	$\log_2(i+1)$	ส่วนเพิ่มของ DCG = (2^{rel_i} − 1) / $\log_2(i+1)$
1	3	7	1.0000	7.0000
2	2	3	1.58496	1.8928
3	1	1	2.00000	0.5000
4	0	0	2.32193	0
5	0	0	2.58496	0

$$iDCG@5 = 7 + 1.8928 + 0.5 = 9.3928$$

$$\mathrm{nDCG@k} = \frac{\mathrm{DCG@k}}{\mathrm{IDCG@k}} = \frac{8.89}{9.3928} = 0.946$$

ค่าที่ได้เหมาะกับงานที่มี **passage หลายตัวในเอกสาร** เพราะมีการ weight ระหว่างคะแนนเฉลี่ยปัจุบัน กับคะแนนเฉลี่ยในเคสที่เรียงลำดับการ retreive. ได้ดีที่สุดไว้แล้ว

nDCG

ยกตัวอย่างกับชุดคำถามเดียว (Q1)

สมมติให้ relative score

3	2	1	0
เกี่ยวข้องมาก	เกี่ยวข้องบางส่วน	เกี่ยวข้องน้อยมาก	ไม่เกี่ยวเลย

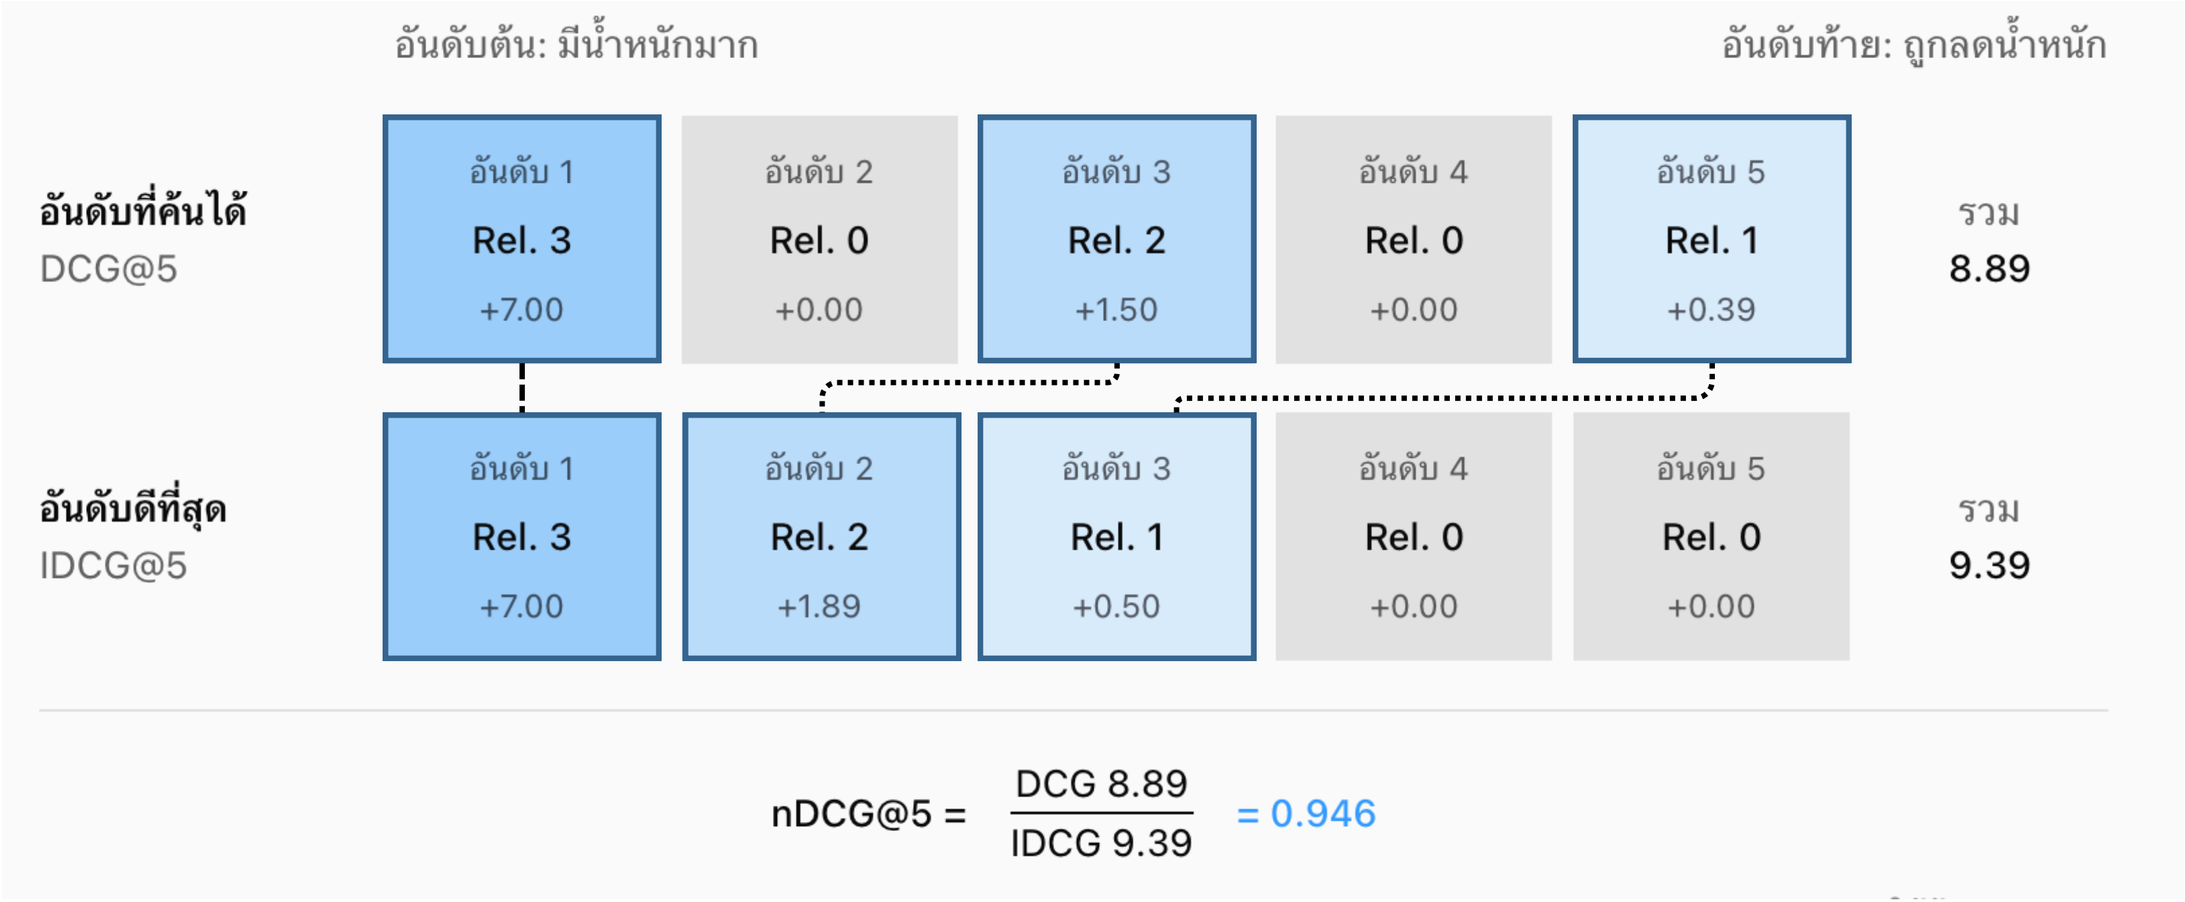

Rank-Eval

rank_eval is a library of fast ranking evaluation metrics implemented in Python, leveraging Numba for high-speed vector operations and automatic parallelization.

It allows you to compare different runs, perform statistical tests, and export a LaTeX table for your scientific publications.

We strongly incourage you to check the example folder to learn how to use rank_eval in just a few minutes.

```python
from rank_eval import Qrels, Run, evaluate

qrels = Qrels()
qrels.add_multi(
    q_ids=["q_1", "q_2"],
    doc_ids=[
        ["doc_12", "doc_25"],  # q_1 relevant documents
        ["doc_11", "doc_2"],  # q_2 relevant documents
    ],
    scores=[
        [5, 3],  # q_1 relevance judgements
        [6, 1],  # q_2 relevance judgements
    ],
)

run = Run()
run.add_multi(
    q_ids=["q_1", "q_2"],
    doc_ids=[
        ["doc_12", "doc_23", "doc_25", "doc_36", "doc_32", "doc_35"],
        ["doc_12", "doc_11", "doc_25", "doc_36", "doc_2",  "doc_35"],
    ],
    scores=[
        [0.9, 0.8, 0.7, 0.6, 0.5, 0.4],
        [0.9, 0.8, 0.7, 0.6, 0.5, 0.4],
    ],
)
```

Available metrics

- Mean Reciprocal Rank (MRR)
- Mean Average Precision (MAP)
- Normalized Discounted Cumulative Gain (NDCG)

LLM-as-a-Judge

คือการใช้ LLM ประเมินคุณภาพคำตอบตามเกณฑ์ เช่น ความถูกต้อง ความเกี่ยวข้อง และความเป็นประโยชน์ เพื่อวัดคุณภาพของคำตอบปลายทางที่ Retrieval Metrics ไม่สามารถสะท้อนได้โดยตรง

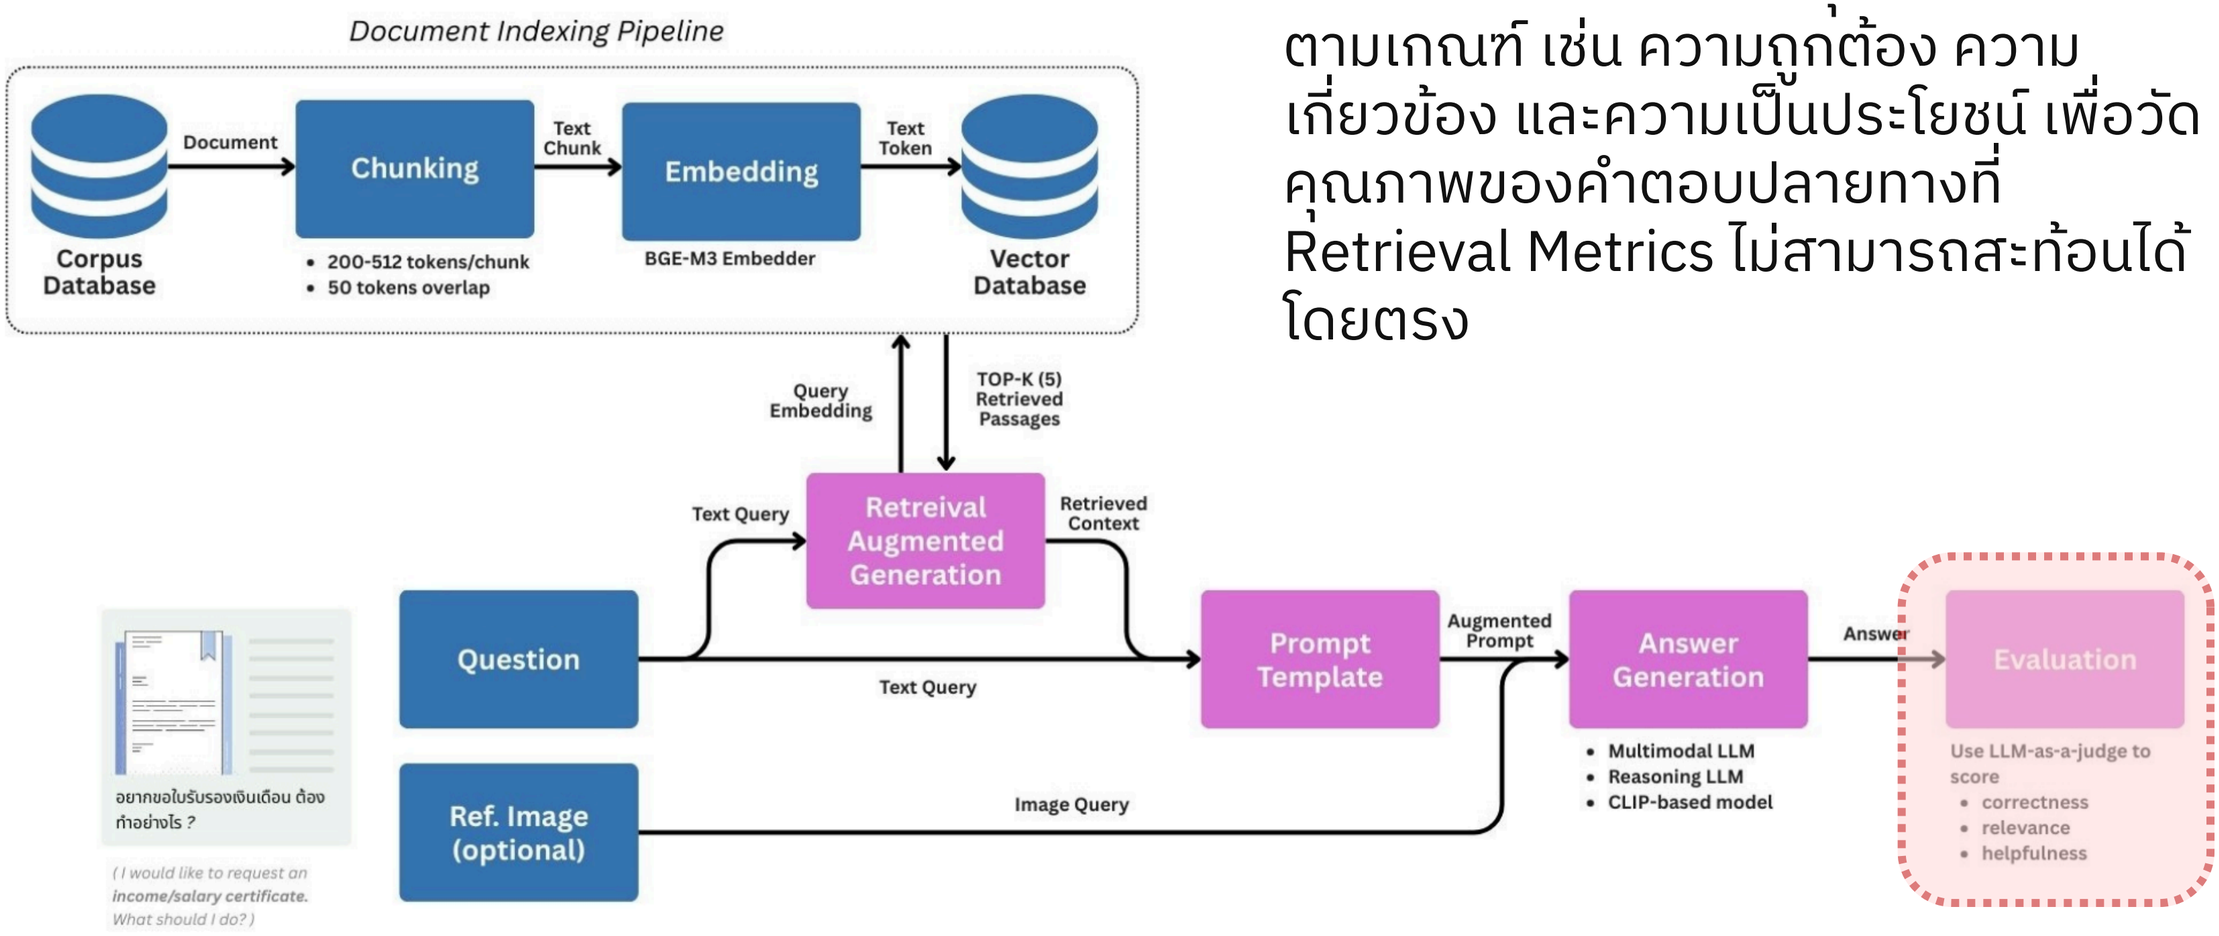

Fig. 1. Overview of the proposed Thai HR-VQA RAG pipeline.

2.Answering

- **LLM as a Judge**

LLM-as-a-Judge

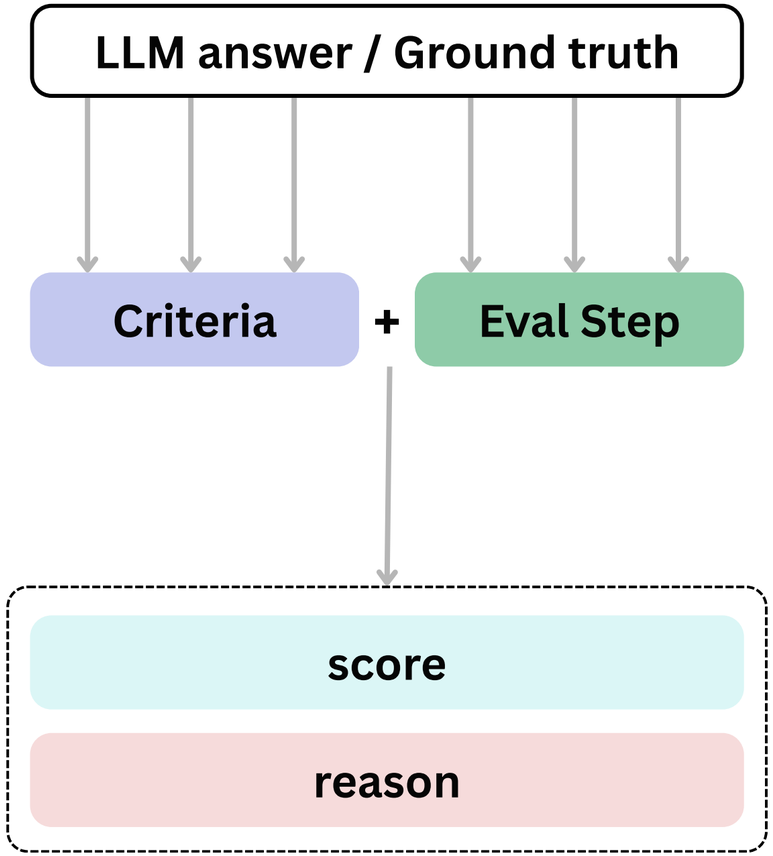


```
Evaluating 1 test case(s) in parallel ————————————————————————————————————————
    🎯 Evaluating test case #0 ———————————————————————————————————————————————

**************************************************
Correctness (GEval) Verbose Logs
**************************************************

Criteria:
Determine if the 'actual output' is correct based on the 'expected output'.

Evaluation Steps:
[
    "Compare the actual output against the expected output for exact match in content
    "Check if the actual output meets all functional requirements outlined in the exp
    "Evaluate any discrepancies between the actual output and expected output for acc
    "Confirm that the actual output maintains the quality standards defined by the ex
]

Rubric:
None

Score: 0.6063751335390813
Reason: The actual output partially aligns with the expected output by mentioning a p
symptoms and advising to see a doctor if symptoms worsen or don't improve. However, i
as the range of illnesses (e.g., pneumonia, COVID-19) and additional symptoms (e.g.,
pain) that warrant medical attention, which are present in the expected output. This
comprehensive response.

==========================================================================
```

Evaluation: LLM-as-a-Judge with a Clear Rubric

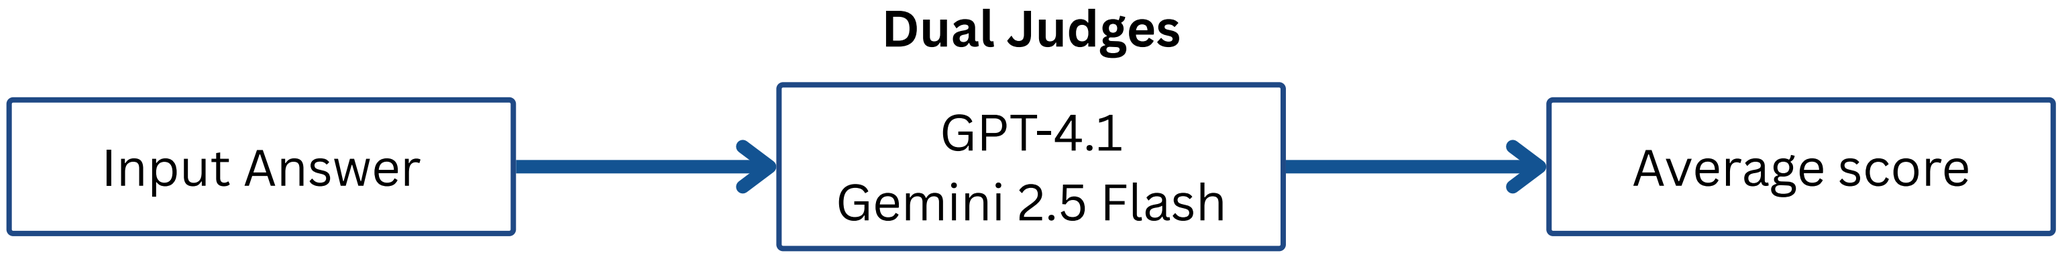

Correctness (C)	Relevance (R)	Helpfulness (H)
0.17	0.10	0.11

- Metrics evaluated on 0–1 scale. base on GEval
- Dual judges reduce single-model bias.
- Scale: 6 models × 226 questions.

ทำไม เราถึงสามารถยอมรับผลการประเมินของ LLM ได้?

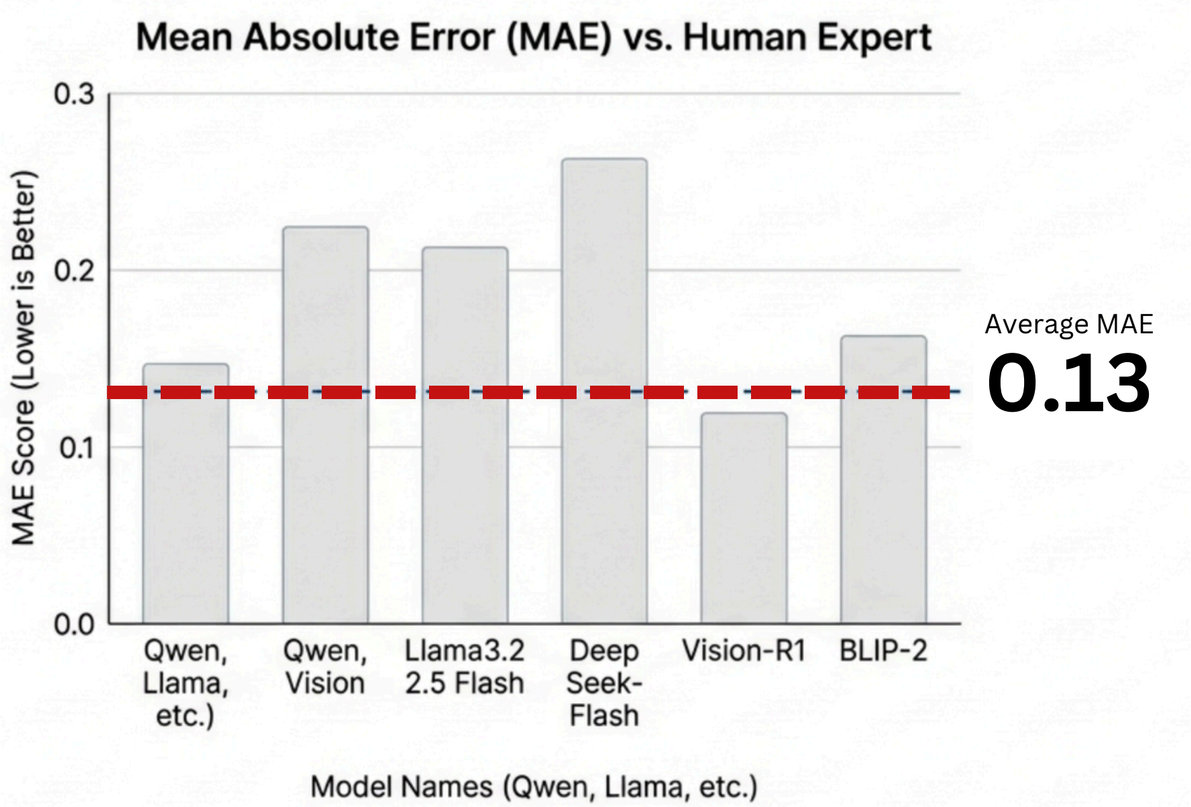

- Human experts rated a balanced subset of 40 questions.
- Low average disagreement (0.13) indicates practical reliability.
- Targeted human review used for edge cases.

ทำไม เราถึงสามารถยอมรับผลการประเมินของ LLM ได้?

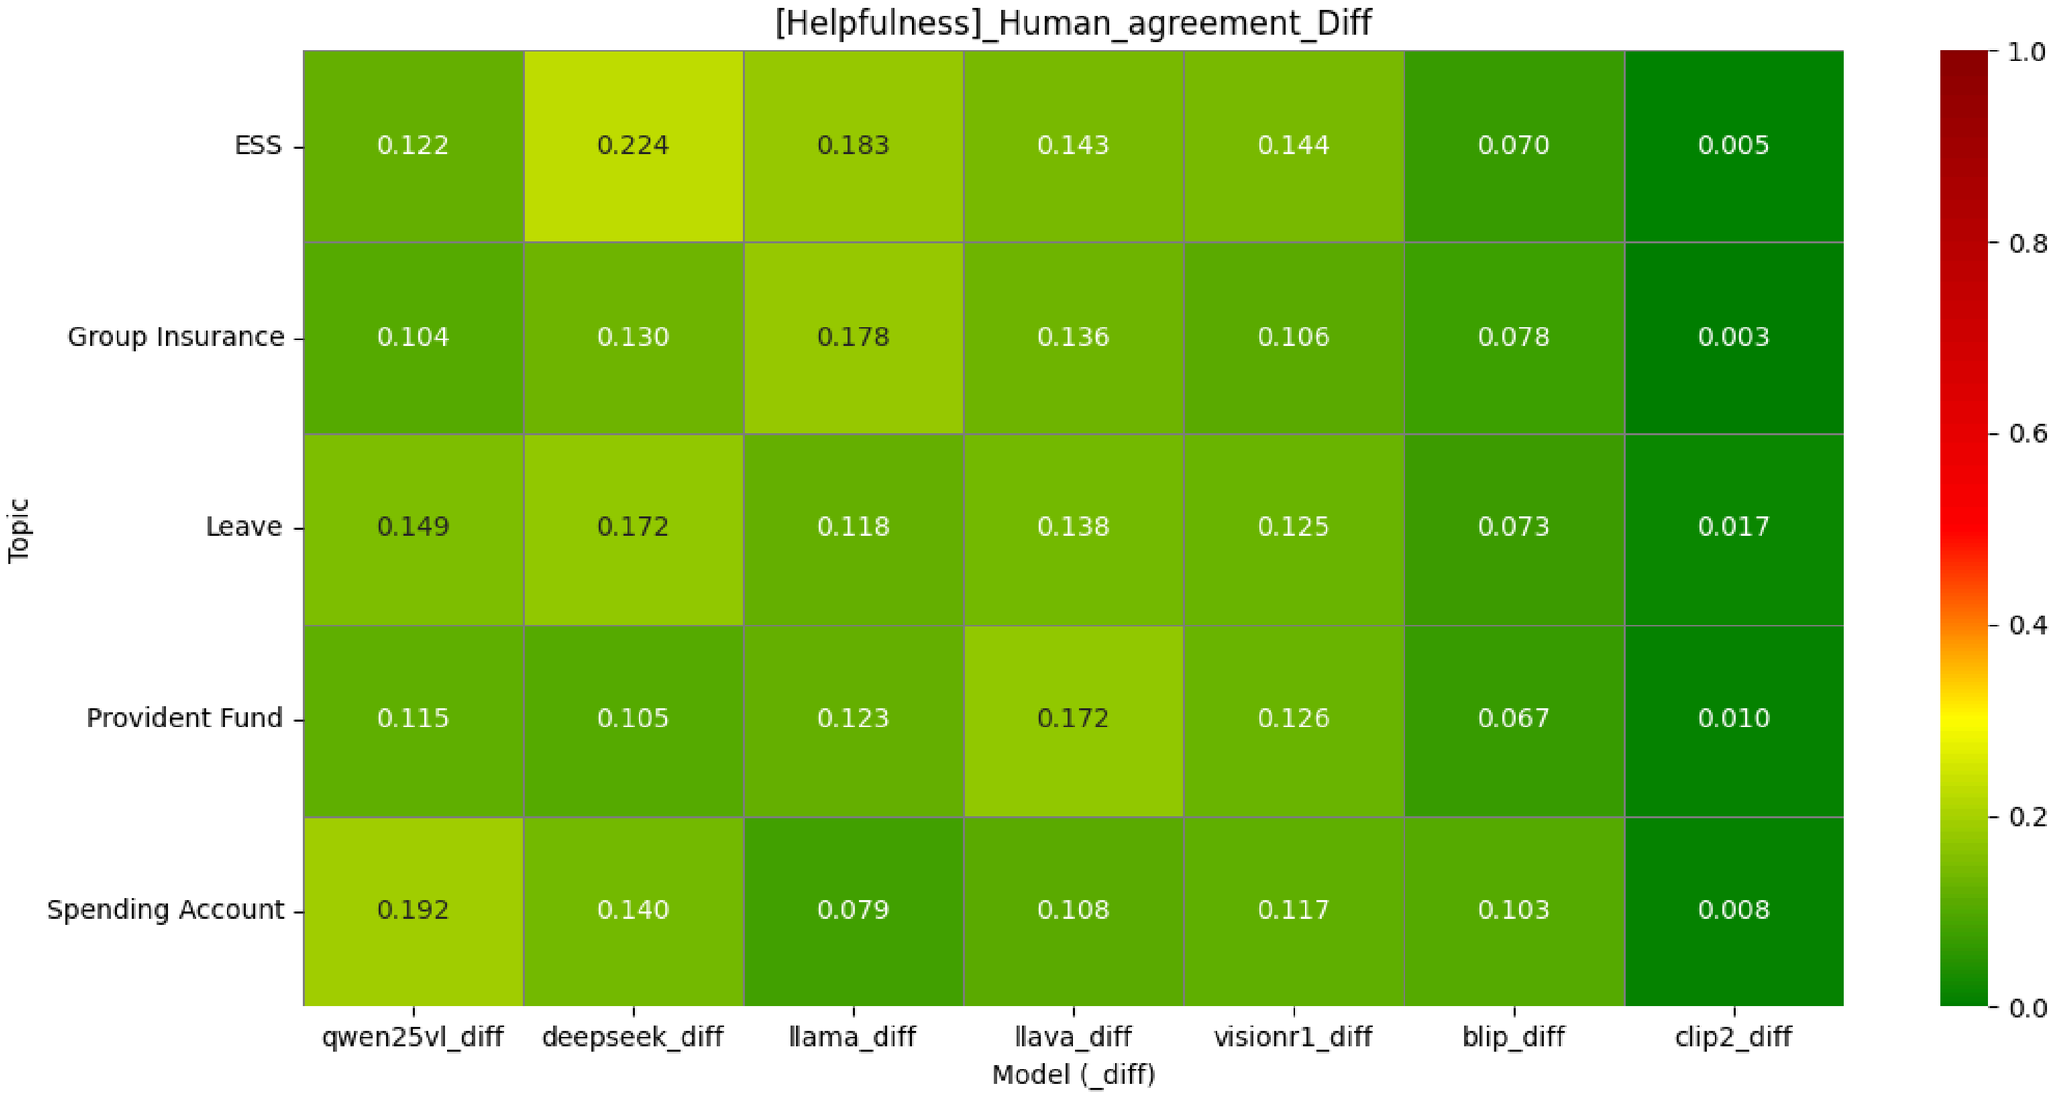

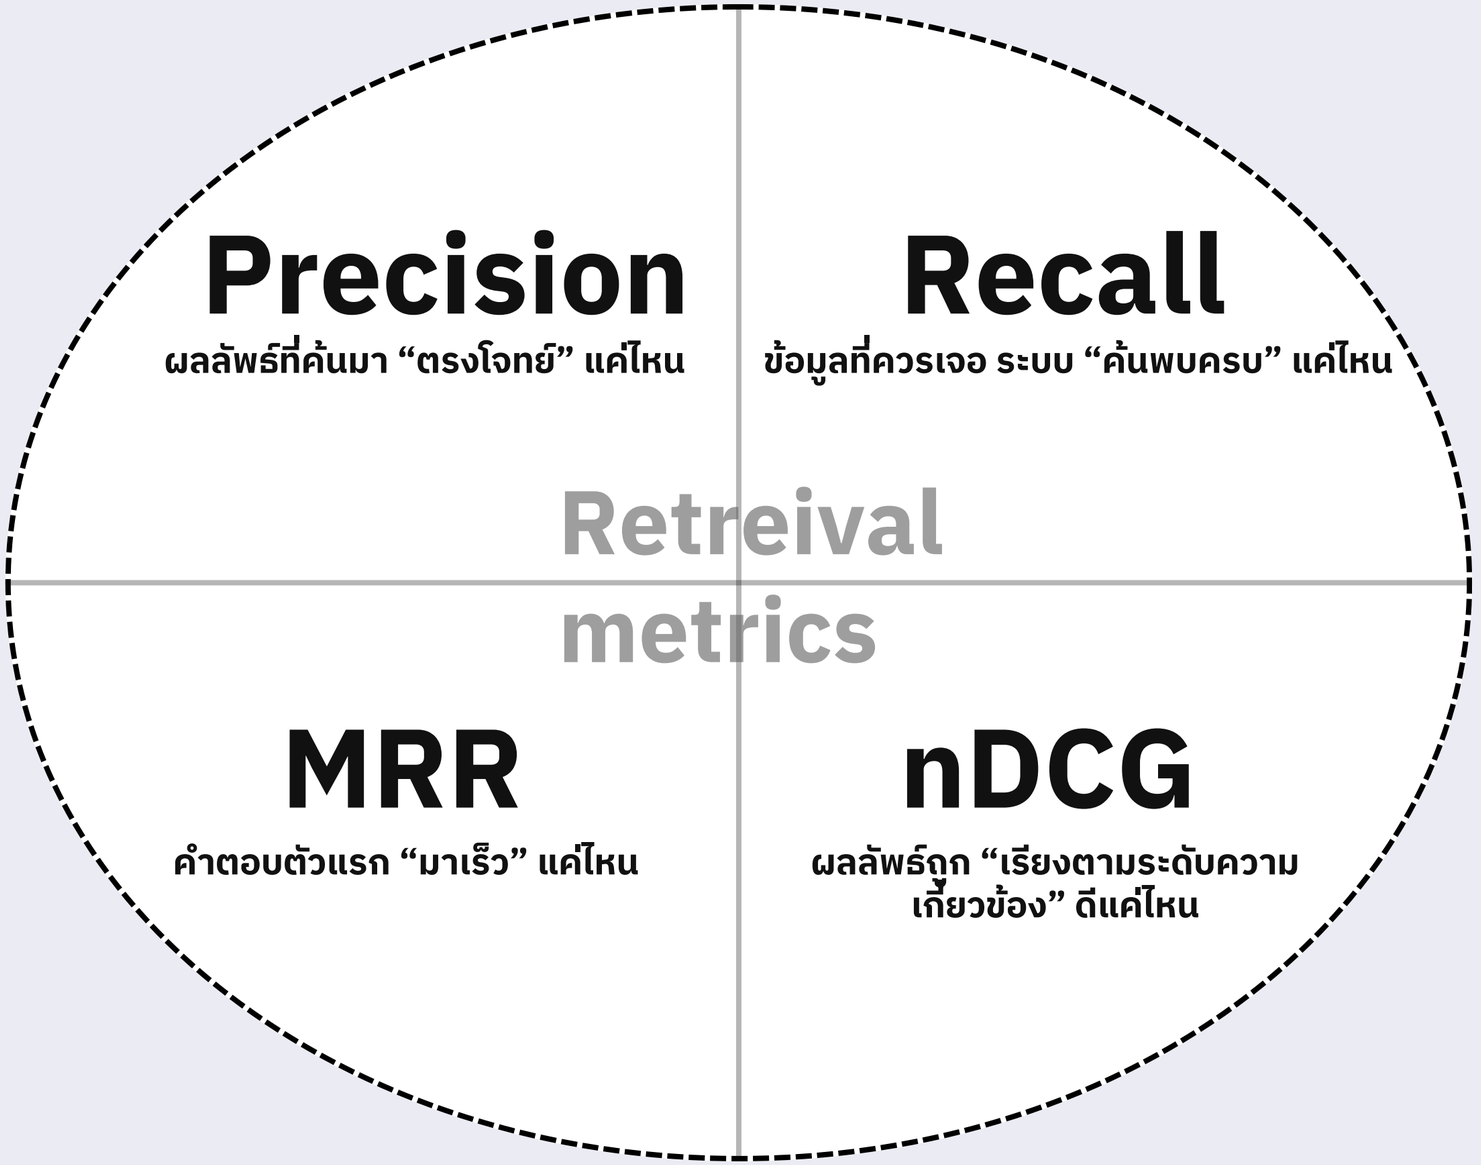

Answering matrics **LLM-as-a-Judge**

คำตอบสุดท้าย “ถูกต้อง ตรงประเด็น และมีประโยชน์” แค่ไหน

THANK YOU

ANY QUESTIONS?